

---

# Masterarbeit

Ableitung von Bewegungsmodellen für Anwendungen in der  
Schüttgutsortierung mittels Machine Learning

**Tobias Hornberger**

20. Dezember 2018

---

Referent: Prof. Dr.-Ing. Uwe D. Hanebeck

Korreferent: Prof. Dr.-Ing. Thomas Längle

Betreuer: Dipl.-Inform. Florian Pfaff  
Georg Maier, M. Sc.  
Dr.-Ing. Benjamin Noack

---



## Zusammenfassung

Die Erweiterung von optischen Schüttgutsortierern mit Flächenkameras ermöglicht eine Verbesserung der Sortierqualität durch bessere Bewegungsprädiktion. Dafür wird ein Modell benötigt, das die Bewegung der einzelnen Schüttgutpartikel gut abbildet. Ein solches Bewegungsmodell zu bestimmen, ist aufwendig und verschiedene Bewegungsmodelle erreichen bei unterschiedlichen Schüttgütern variierende Qualität.

Im Rahmen dieser Arbeit wurden neuronale Netze eingesetzt, um Bewegungsmodelle für verschiedene Schüttgüter zu ermitteln. Dazu wurden mehrere Datensätze für ausgewählte Schüttgüter am modularen Schüttgutsortiersystem *TableSort* des Fraunhofer IOSBs in zwei Konfigurationen erfasst und für das Training vorverarbeitet. Es wurde ein für die Problemstellung passendes Datenaugmentierungsverfahren implementiert und geeignete Hyperparameter für das Training der verschiedenen Szenarien ermittelt.

Die Evaluation wurde sowohl auf den so ermittelten als auch auf bestehenden, mittels der *Diskrete-Elemente-Methode* simulierten Datensätzen durchgeführt. In allen Szenarien waren die Ergebnisse der neuronalen Netze vergleichbar oder besser als die der betrachteten Referenzverfahren. Insbesondere auf den Realdaten konnte eine Verbesserung der Sortierqualität im Vergleich zu den Referenzverfahren erzielt werden.



## Abstract

The addition of area scan cameras to optical sorters for bulk material enables an improvement in sorting quality by better predicting particle movement. This requires a model that accurately describes the movement of individual bulk material particles. Determining such a motion model is complex and the performance of different motion models depends strongly on the nature of the examined bulk material.

In this thesis, neural networks were trained to generate motion models for different bulk materials. For this purpose, several datasets of selected bulk materials were collected on the Fraunhofer IOSB's experimental optical sorter *TableSort* and preprocessed for training. These datasets were collected using two different configurations of the sorter. A data augmentation method suitable for the problem was implemented and the hyperparameters for the training of the different scenarios were optimized.

The evaluation was carried out both on the datasets obtained in this way as well as on existing ones that were simulated using the discrete element method. In all scenarios the neural networks performed comparable to or better than the reference methods. In particular, an improvement compared to the reference methods was achieved on the collected data.



# **Eidesstattliche Erklärung**

Hiermit erkläre ich, die vorliegende Masterarbeit selbstständig angefertigt zu haben.  
Die verwendeten Quellen sind im Text gekennzeichnet und im Literaturverzeichnis aufgeführt.

Karlsruhe, 20. Dezember 2018

---

Tobias Hornberger



# Inhaltsverzeichnis

<b>Abbildungsverzeichnis</b>	<b>III</b>
<b>Notation</b>	<b>v</b>
<b>1 Einleitung</b>	<b>1</b>
1.1 Motivation . . . . .	1
1.2 Aufbau der Arbeit . . . . .	3
<b>2 Grundlagen</b>	<b>5</b>
2.1 Neuronale Netze . . . . .	5
2.1.1 Perzepron . . . . .	6
2.1.2 Feedforward Netze . . . . .	7
2.1.3 Aktivierungsfunktionen . . . . .	8
2.1.4 Performance-Maß . . . . .	10
2.1.5 Regularisierung . . . . .	12
2.2 TableSort System . . . . .	13
2.3 Stand der Technik . . . . .	16
<b>3 Datenverarbeitung</b>	<b>19</b>
3.1 Eigene Aufnahmen . . . . .	19
3.2 Datenpipeline . . . . .	20
3.3 Simulierte Daten . . . . .	23
3.4 Datenformatierung . . . . .	25
3.5 Datenumfang . . . . .	29
3.6 Datenaugmentierung . . . . .	31
<b>4 Umsetzung und Implementierung</b>	<b>33</b>
4.1 Software . . . . .	33
4.2 Code-Struktur . . . . .	33
4.3 Hyperparameter . . . . .	34
4.4 Hyperparameter-Tuning . . . . .	39

## Inhaltsverzeichnis

---

<b>5 Evaluation</b>	<b>43</b>
5.1 Vergleichsmodelle . . . . .	43
5.2 Next Step . . . . .	47
5.3 Separator . . . . .	48
5.4 Zusammenfassung und Diskussion . . . . .	54
<b>6 Fazit und Ausblick</b>	<b>57</b>
<b>Literatur</b>	<b>59</b>
<b>A Anhang</b>	<b>63</b>

# Abbildungsverzeichnis

1.1	Fehlseparierung bei konventionellen optischen Schüttgutsortierern. Übersetzt aus [Pfa18]	2
1.2	Visualisierung einer Probleminstanz eines NextStep-Netzes	4
1.3	Visualisierung einer Probleminstanz eines Separator-Netzes	4
2.1	Schematischer Aufbau eines Perzeptrons	6
2.2	Vergleich zwischen einem linear separierbaren und einem nicht linear separierbaren Problem. Angepasst von [WAZ11].	7
2.3	Schaubild der Ausgabe einer ReLU.	9
2.4	Visualisierung von Modellen mit unterschiedlichen Kapazitäten.	11
2.5	Beispiel für die Dropout-Regularisierung [SHK+14].	14
2.6	TableSort Schüttgutsortiersystem [Fra17].	15
2.7	Schematische Darstellung des <i>TableSort</i> -Systems nach [PKP+17].	15
3.1	Verschiedene Schüttgüter.	20
3.2	Verschiedene Schüttgüter auf dem Förderband.	21
3.3	Verschiedene Schüttgüter auf der Rutsche.	21
3.4	Bayer-Matrix auf einem Sensor [WC06].	22
3.5	Visualisierung der DEM-Simulation, übersetzt aus [Pfa18].	25
3.6	Beispiel Feature-Label-Paar NextStep	26
3.7	Geometrische Bestimmung der Labels, nach [Pfa18].	27
3.8	Beispiel Feature-Label-Paar Separator	28
3.9	Balkendiagramm zur Verteilung der Bilder.	30
3.10	Balkendiagramm zur Verteilung der Tracks.	30
3.11	Visualisierung der Datenaugmentierung	32
4.1	Skizzierter Trainingsablauf eines neuronalen Netzes.	35
4.2	Skizzierte Ablauf der Evaluation eines neuronalen Netzes.	35
4.3	Architektur eines neuronales Netzes für die NextStep-Prädiktion	41
4.4	Architektur eines neuronales Netzes für die Separator-Prädiktion	41

## Abbildungsverzeichnis

---

5.1	Visualisierung der Ergebnisse für die realen und simulierten Kugeln mit NextStep-Netzen . . . . .	49
5.2	Fehlerhistogramm für die NextStep-Ergebnisse der selbst aufgenommenen Kugeln auf dem Förderband . . . . .	50
5.3	Visualisierung der Ergebnisse für die Plättchen aus der DEM-Simulation	52
5.4	Visualisierung der Ergebnisse für den Weizenkörnern-Datensatz von den selbst gesammelten Daten. . . . .	53
A.1	Boxplots für die NextStep-Ergebnisse Kugeln auf dem Förderband aus dem selbst aufgenommenen Datensatz. . . . .	63
A.2	Boxplots für die NextStep-Ergebnisse der Pfefferkörner auf dem Förderband aus dem selbst aufgenommenen Datensatz. . . . .	64
A.3	Boxplots für die NextStep-Ergebnisse der Zylinder auf dem Förderband aus dem selbst aufgenommenen Datensatz. . . . .	64
A.4	Boxplots für die NextStep-Ergebnisse der Zylinder auf dem Förderband aus dem selbst aufgenommenen Datensatz. . . . .	65
A.5	Boxplots für die NextStep-Ergebnisse der Kugeln auf der Rutsche aus dem selbst aufgenommenen Datensatz. . . . .	65
A.6	Boxplots für die NextStep-Ergebnisse der Pfefferkörner auf der Rutsche aus dem selbst aufgenommenen Datensatz. . . . .	66
A.7	Boxplots für die NextStep-Ergebnisse der Kugeln auf dem Förderband aus dem DEM-Datensatz. . . . .	66
A.8	Boxplots für die NextStep-Ergebnisse der Plättchen auf dem Förderband aus dem DEM-Datensatz. . . . .	67
A.9	Visualisierung der Ergebnisse für die Kugeln aus dem selbst aufgenommenen Datensatz. . . . .	68
A.10	Visualisierung der Ergebnisse für die Pfefferkörner aus dem selbst aufgenommenen Datensatz. . . . .	69
A.11	Visualisierung der Ergebnisse für die Zylinder aus dem selbst aufgenommenen Datensatz. . . . .	70
A.12	Visualisierung der Ergebnisse für die Weizenkörner aus dem selbst aufgenommenen Datensatz. . . . .	71
A.13	Visualisierung der Ergebnisse für die Kugeln auf der Rutsche aus dem selbst aufgenommenen Datensatz. . . . .	72
A.14	Visualisierung der Ergebnisse für die Pfefferkörner auf der Rutsche aus dem selbst aufgenommenen Datensatz. . . . .	73
A.15	Visualisierung der Ergebnisse für die Kugeln aus der DEM-Simulation.	74
A.16	Visualisierung der Ergebnisse für die Plättchen aus der DEM-Simulation.	75

# Notation

## Konventionen

$x$	Skalar
$\underline{x}$	Vektor
$x_k$	Der $k$ -te Eintrag des Vektors $\underline{x}$
$\underline{x}_t$	Vektor $\underline{x}$ zum Zeitschritt $t$
$\dot{x}$	Erste zeitliche Ableitung von $x$
$\ddot{x}$	Zweite zeitliche Ableitung von $x$
$x$ bzw. $y$	Koordinate entlang der $x$ - beziehungsweise $y$ -Achse
$a(\cdot)$	Funktion
$\underline{a}(\cdot)$	Funktion, die einen Vektor als Ergebnis hat
$e$	Eulersche Zahl
$\mathbf{A}$	Matrix
$\mathbf{0}$	Nullmatrix

## Allgemeine Abkürzungen

PNG	Portable Network Graphics
CSV	Comma Separated Values
JSON	JavaScript Object Notation
RGB-Farbraum	„Rot Grün Blau“-Farbraum
HSV-Farbraum	„Hue Saturation Value“-Farbraum
MSE	Mean Square Error
RMSE	Root Mean Square Error
DEM	Diskrete-Elemente-Methode
MTT	Multi-Target-Tracking

### **Abgekürzte Namen verschiedener Bewegungsmodelle**

NN	Neuronales Netz
CV	Constant Velocity
CVBC	Bias-Corrected Constant Velocity
CA	Constant Acceleration
AA	Average Acceleration
IA	Identical Acceleration

## KAPITEL 1

# Einleitung

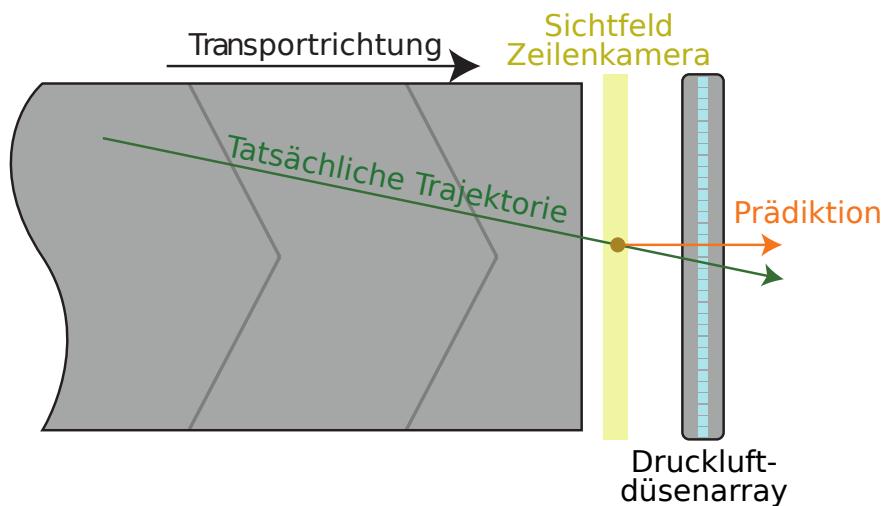
Schüttgüter und ihr Transport sind aus unserer modernen, globalisierten Welt nicht mehr wegzudenken. Als Schüttgüter werden solche Materialien bezeichnet, die lose in großen Mengen transportiert werden. Dazu gehören Lebensmittel wie Getreide, Kaffeebohnen oder Zucker, aber auch Bergbauerzeugnisse, wie zum Beispiel Erze oder Kohle. Auch Rohstoffe in Pellet-Form und Granulate zählen zu dieser Kategorie [Sch09]. Laut dem Seefrachtbericht der Vereinten Nationen wurden im Jahr 2017 insgesamt 3196 Millionen Tonnen von den volumenmäßig wichtigsten Schüttgütern Eisenerze, Kohle und Getreide verschifft [UC18, Unterabschnitt 1.A.2]. Der Anteil, der für die Verarbeitung von Schüttgutmaterialien verwendeten Energie am globalen Energieverbrauch, wird mit 10 % angegeben [Dur12, Abschnitt 1.2]. In Zeiten der globalen Erwärmung ist der verantwortungsvolle Umgang mit Energie ein wichtiges Thema und eine effizientere Sortierung von Schüttgütern kann dazu beitragen. Für das Sortieren solcher Schüttgüter gibt es verschiedene Methoden, wie zum Beispiel der Einsatz von Sieben, Magneten oder Flotationszellen. Diese Sortiermethoden basieren auf unterschiedlichen physikalischen Eigenschaften der Schüttgutpartikel. Im Rahmen dieser Arbeit wird die optische Schüttgutsortierung behandelt, die stattdessen anhand der optischen Eigenschaften der einzelnen Schüttgutpartikel sortiert. In den letzten Jahren haben neuronale Netze für einige beeindruckende Fortschritte in verschiedenen Forschungsfeldern gesorgt, wie zum Beispiel in den Bereichen der Bildverarbeitung und der Spracherkennung. Um die Qualität der Schüttgutsortierung zu steigern, wird im Rahmen dieser Arbeit der Einsatz von neuronalen Netzen für die Bewegungsprädiktion der einzelnen Partikel erprobt.

### 1.1 Motivation

Der Großteil der heute in der Industrie eingesetzten optischen Schüttgutsortierer verwendet Zeilenkameras. Dabei muss die Annahme getroffen werden, dass die

Schüttgutpartikel keinerlei Geschwindigkeit orthogonal zur Transportrichtung haben, weil diese nicht erfasst werden kann. In Abbildung 1.1 ist dargestellt wie es zu einer Fehlseparierung kommen kann, wenn diese Annahme verletzt wird.

Durch den Einsatz von Flächenkameras ist es möglich, die Position eines Partikels auf dem Förderband zu mehreren Zeitpunkten zu bestimmen. Basierend auf diesen Informationen sollen die Trajektorien der einzelnen Partikel vorhergesagt werden. Diese sollen dazu verwendet werden, die Sortierqualität zu steigern. Im Rahmen des *TrackSort*-Projekts, einer Kooperation zwischen dem Lehrstuhl für Intelligente Sensor-Aktor-Systeme (ISAS) des Karlsruher Instituts für Technologie und dem Fraunhofer-Institut für Optronik, Systemtechnik und Bildauswertung (IOSB), wurde die Verbesserung der Schüttgutsortierung durch den Einsatz von Trackingverfahren basierend auf den Daten von Flächenkameras betrachtet.



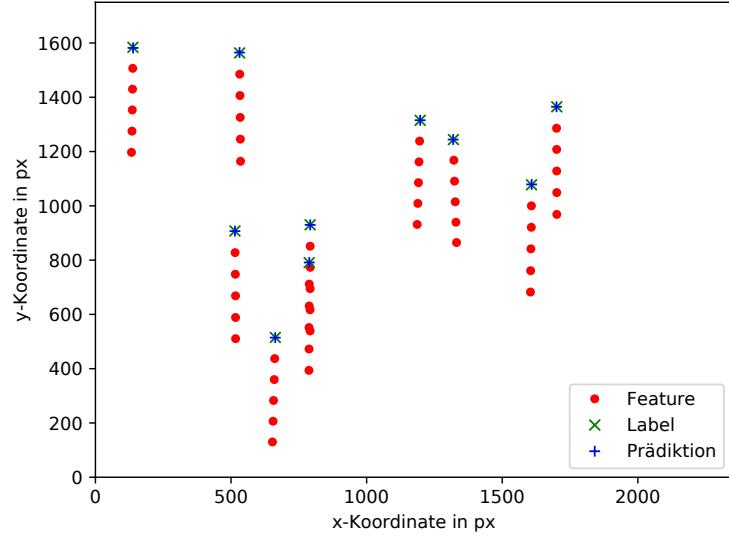
**Abbildung 1.1:** Darstellung einer Fehlseparierung durch die Annahme, dass es keine Bewegung orthogonal zur Transportrichtung gibt. Übersetzt aus [Pfa18].

Um die zukünftigen Trajektorien der Partikel aus den vergangenen Positionen vorherzusagen, existieren verschiedene Bewegungsmodelle. Diese liefern für unterschiedliche Situationen mit unterschiedlichen Bandgeschwindigkeiten, Schüttguttypen oder Prädiktionsdistanzen unterschiedlich gute Ergebnisse. Mittels neuronaler Netze können komplexe, nichtlineare Muster aus bestehenden Daten gelernt werden, ohne dass diese explizit angegeben werden müssen. Es ist also denkbar, dass sie in der Lage sind, die Bewegungen des Schüttguts zu lernen. Die für den Einsatz von neuronalen Netzen essenziellen Daten in ausreichender Menge zu sammeln, ist definitiv möglich. In dieser Arbeit soll nun erforscht werden, inwiefern der Einsatz von neuronalen Netzen zu einer Verbesserung gegenüber den bestehenden Ergebnissen führt. Dabei wird exemplarisch mit Daten von einem kleineren Schüttgutsortierer des Fraunhofer IOSBs gearbeitet.

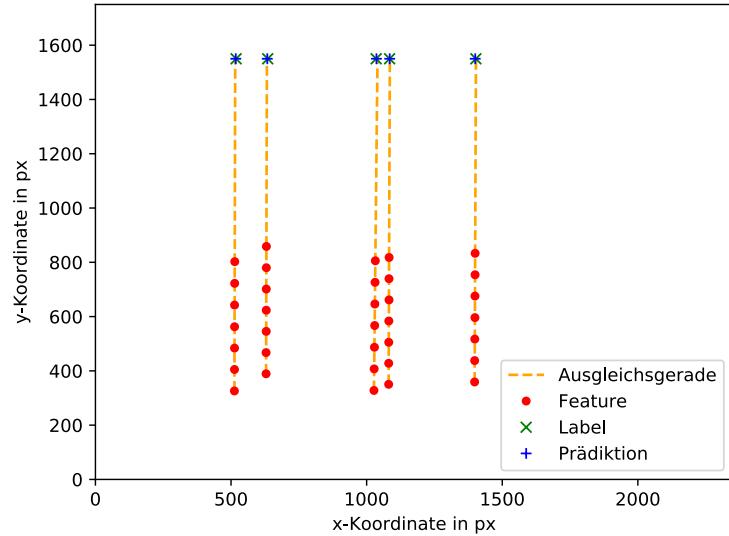
Zu diesem Zweck sollen im Rahmen dieser Arbeit zwei verschiedene Prädiktionsprobleme durch neuronale Netze gelöst werden. Einerseits soll vorhergesagt werden, an welcher Position sich ein Teilchen im nächsten Zeitschritt befinden wird. Solche Netze werden von hier an als NextStep-Netze bezeichnet. Die Visualisierung einer Probleminstanz mit dem dazugehörigen Label und einer von einem Netz generierten Prädiktion ist in Abbildung 1.2 zu sehen. Dies hilft dabei, das Zuordnungsproblem für Multi-Target-Tracking zu lösen. Andererseits soll vorhergesagt werden, an welcher Position und wann ein Teilchen das Druckluftdüsenarray passieren wird. Diese Problemstellung wird von sogenannten Separator-Netzen gelöst. Die Visualisierung einer Probleminstanz mit dem dazugehörigen Label und einer von einem Netz generierten Prädiktion ist in Abbildung 1.3 zu sehen. Die Qualität dieser Prädiktion ist ausschlaggebend für den Erfolg der Separation.

## 1.2 Aufbau der Arbeit

Nachdem im ersten Kapitel eine kurze Einführung und Motivation für das Thema gegeben wurde, ist Kapitel 2 den theoretischen Grundlagen gewidmet, die für das Verständnis der restlichen Arbeit notwendig sind. Dabei wird zu Beginn auf die Funktionsweise von neuronalen Netzen eingegangen, bevor die Funktionsweise und der Aufbau des *TableSort*-Schüttgutsortierers beschrieben werden. Am Ende des Grundlagenkapitels wird auf den aktuellen Stand der Technik eingegangen und erklärt, wie die Bewegungsprädiktion, die im Rahmen dieser Arbeit mittels neuronaler Netze durchgeführt werden wird, aktuell funktioniert. Kapitel 3 beschreibt die Daten, die dafür verwendet werden, woher sie stammen, wie sie verarbeitet wurden und in welcher Form sie in die neuronalen Netze eingegeben werden. Auch wird in diesem Kapitel auf die bereits existierenden Datensätze eingegangen, die mittels der *Diskrete-Elemente-Methode* Schüttgut simuliert wurde, und das verwendete Daten-augmentierungsverfahren beschrieben. Danach wird auf den Umfang der verwendeten Daten eingegangen. In Kapitel 4 wird die Implementierung der Arbeit thematisiert. Dabei wird zunächst auf die verwendete Software eingegangen, bevor die Struktur des Codes beschrieben wird. Es werden die für das Training und die Evaluation relevanten Hyperparameter beschrieben und die Optimierung derselben erläutert. Kapitel 5 beschäftigt sich mit der Evaluation der Ergebnisse. Erst werden die verwendeten Bewegungsmodelle vorgestellt, die dann im NextStep-Fall und im Separator-Fall mit den Ergebnissen der neuronalen Netze verglichen werden. Schließlich werden diese Ergebnisse diskutiert. Den Abschluss der Arbeit stellt Kapitel 6 dar, in dem die Ergebnisse der Arbeit noch einmal zusammengefasst werden und ein Ausblick darauf gegeben wird, was in der Zukunft denkbare Fortführungen wären.



**Abbildung 1.2:** Visualisierung einer Probleminstanz eines NextStep-Netzes. Die Transportrichtung ist entlang der y-Achse. Die Features sind die zeitlich aufeinanderfolgenden, beobachteten Positionen eines Partikels. Die Prädiktion ist die Vorhersage des Netzes, wo das Partikel im nächsten Zeitschritt sein wird. Das Label ist die tatsächliche Position des entsprechenden Partikels im nächsten Zeitschritt.



**Abbildung 1.3:** Visualisierung einer Probleminstanz eines Separator-Netzes. Wie in Abbildung 1.2 ist die Transportrichtung entlang der y-Achse. Die Features sind erneut die beobachteten Positionen eines Partikels. Die Prädiktion ist die vom Netz vorhergesagte Position, wo das Partikel das Druckluftdüsenarray passieren wird. Das Labels ist die tatsächliche Position, wo das Partikel das Druckluftdüsenarray passiert. Der Zeitpunkt, an dem das Druckluftdüsenarray passiert wird, ist nicht abgebildet.

## KAPITEL 2

# Grundlagen

In diesem Kapitel wird eine kurze Einführung in die für das Verständnis der restlichen Arbeit benötigten Themengebiete gegeben. Primär werden zunächst allgemein neuronale Netze und einige ihrer spezielleren Aspekte betrachtet, bevor ein kurzer Blick auf das bei den Experimenten verwendete Schüttgutsortiersystem *TableSort* geworfen wird. Am Ende des Kapitels wird auf den aktuellen Stand der Technik eingegangen. Die Ausführungen zu den neuronalen Netzen sind, wo nicht anders angemerkt, basierend auf [GBC16], [Mur12] und [Nie15].

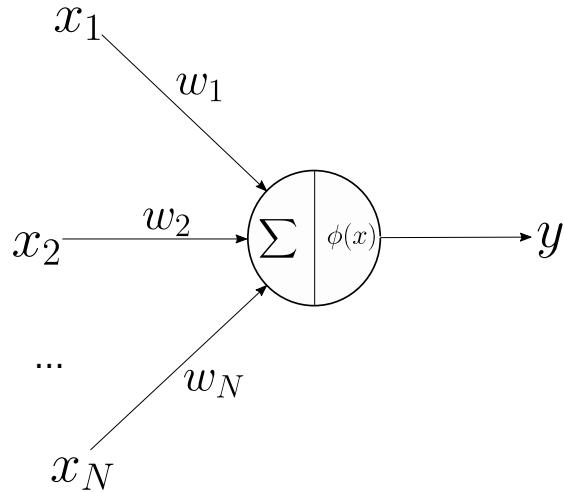
## 2.1 Neuronale Netze

Als neuronale Netze bezeichnet man in der Informatik Systeme aus künstlichen Neuronen, die heute eine wichtige Rolle im Feld des maschinellen Lernens einnehmen. Manchmal werden sie korrekter als *künstliche neuronale Netze* bezeichnet, um sie von *natürlichen neuronalen Netzen* wie dem menschlichen Gehirn zu unterscheiden, nach deren biologischem Vorbild sie modelliert sind. Neuronale Netze sind ein mächtiges Werkzeug. Aufgrund ihrer Fähigkeit komplexe, nichtlineare Muster und Zusammenhänge in Daten ohne explizite Vorgaben zu lernen, eröffnen sie in vielen Forschungsrichtungen neue Möglichkeiten.

Die Grundsteine des Feldes wurden bereits 1943 von Warren McCulloch und Walter Pitts gelegt [MP43], als sie ein Neuronenmodell vorschlugen, mit dem sich logische arithmetische Funktionen berechnen lassen. Zwischenzeitlich gab es einige Phasen von relativ geringer Aufmerksamkeit der wissenschaftlichen Gemeinschaft. Erst als um das Jahr 2010 einige herausragende Ergebnisse, unter anderem im Feld der Sprach- und Bilderkennung, mittels neuronaler Netze erzielt wurden, wurde das Interesse an dem Feld neu entfacht.

### 2.1.1 Perzeptron

Die kleinste Einheit eines neuronalen Netzes ist das Perzeptron, wie es 1958 von Frank Rosenblatt in [Ros58] beschrieben wurde. Es ist ein künstliches Neuron, das eine Reihe an Eingaben entgegen nimmt und einen einzelnen Wert  $y$  ausgibt.



**Abbildung 2.1:** Aufbau eines Perzeptions: Die Eingaben  $x_i$  werden gewichtet mit  $w_i$  aufsummiert und nach Anwendung der Aktivierungsfunktion  $\phi$  als  $y$  ausgegeben.

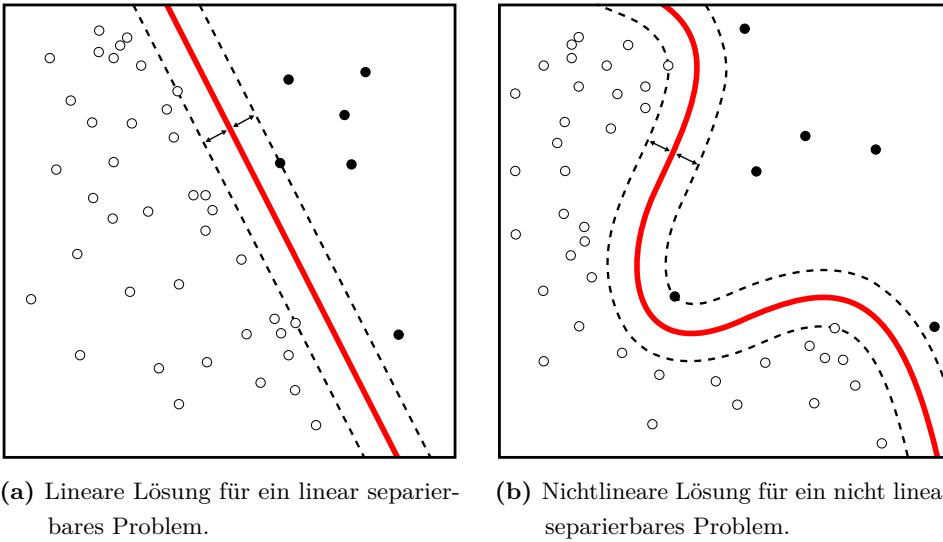
Wie in Abbildung 2.1 zu sehen ist, haben die einzelnen Eingaben  $x_i$  jeweils eine Gewichtung  $w_i$ . Es existiert ein Schwellwert oder *bias*, der normalerweise durch eine zusätzliche Eingabe  $x_{m+1}$  mit dem Eingabewert +1 und dem dazugehörigen Gewicht  $w_{m+1}$  modelliert wird. Den Ausgabewert  $y$  erhält man dadurch, dass man die gewichteten Eingaben aufsummieren und in die Aktivierungsfunktion  $\phi$  des Perzeptions gibt. Mathematisch ist die Ausgabe eines Perzeptions somit wie folgt definiert:

$$y = \phi\left(\sum_{i=0}^m w_i x_i\right).$$

Mehr Details über verschiedene Aktivierungsfunktionen, die für solch ein Perzeptron benutzt werden können, ist in Unterabschnitt 2.1.3 zu finden. Beim Lernen werden die Gewichte  $w_i$  so angepasst, dass die gewünschte Ausgabe für die jeweilige Eingabe erreicht wird. Bei der Auswertung verändern sich die Gewichte nicht mehr. Ein einzelnes Perzeptron mit zwei Eingängen kann zur Darstellung der logischen Operatoren AND, OR und NOT genutzt werden.

Ein Perzeptron mit linearer Aktivierungsfunktion ist jedoch nur ein linearer Klassifikator und kann dementsprechend nur linear separierbare Probleme, wie das Problem in Abbildung 2.2a, lösen. Linear nicht separierbare Probleme, wie zum Beispiel der XOR-Operator oder das in Abbildung 2.2b gezeigte Problem, können nicht korrekt

abbildet werden. Dies haben Marvin Minsky und Seymour Papert 1969 in ihrem einflussreichen Buch *Perceptrons: an introduction to computational geometry* beschrieben [GBC16, Unterabschnitt 1.2.1]. Solche nicht linear separierbare Probleme können jedoch gelöst werden, wenn mehrere Perzeptrons hintereinandergeschaltet werden.



**Abbildung 2.2:** Vergleich zwischen einem linear separierbaren und einem nicht linear separierbaren Problem. Angepasst von [WAZ11].

### 2.1.2 Feedforward Netze

Um die Limitation auf lineare Klassifikation eines einzelnen Perzeptrons zu überwinden, können mehrere solche Perzeptrons hintereinandergeschaltet werden. Die einfachste Möglichkeit dies zu tun wird als Feedforward Netz bezeichnet. Mit diesem Begriff beschreibt man ein neuronales Netz, zwischen dessen Knoten keine Kreise beziehungsweise Schleifen existieren. Die Informationen wandern in der Verarbeitungsrichtung von den Eingabeneuronen zu den Ausgabeneuronen. Für gewöhnlich sind die einzelnen Knoten in Schichten, sogenannten Layers, organisiert. Auf ein Eingabe- oder auch Input Layer folgen eine Menge an sogenannten Hidden Layers. Den Abschluss bildet das Ausgabe- oder auch Output Layer. Die Neuronen eines einzelnen Hidden Layers sind meist mit uniform bezüglich ihrer Verbindungen zum vorherigen und zum nächsten Layer und verwenden identische Aktivierungsfunktionen, wie sie in Abschnitt 2.1.3 beschrieben sind.

Durch das Hintereinanderschalten von mehreren Layers von Neuronen mit nichtlinearen Aktivierungsfunktionen können auch Probleme, die nicht linear-separierbar sind, gelöst werden. Tatsächlich sind solche neuronalen Netze bewiesenermaßen uni-

verselle Funktionsapproximatoren – sie können mit endlich vielen Neuronen in den Hidden Layers beliebige kontinuierliche Funktionen auf kompakten Subsets von  $\mathbb{R}^n$  approximieren [GBC16, Unterabschnitt 6.4.1]. Das heißt zwar, dass es theoretisch für jede solche Funktion ein Netz gibt, das sie beschreiben kann, in der Praxis muss man dieses Netz aber finden und dann auch trainieren können.

Über die in der Arbeit verwendeten Netze hinaus gibt es viele weitere Unterkategorien von neuronalen Netzen, die in verschiedensten Bereichen Verwendung finden. Convolutional Neural Networks zeichnen sich durch eine spezielle Struktur aus sogenannten Convolutional Layers aus, die als Feature Extractor fungieren. Diese Art von Netz findet unter anderem in der Bildverarbeitung Anwendung. Ein Netz, in dem Kreise beziehungsweise Schleifen existieren, bezeichnet man als *Rekurrentes Neuronales Netz*. Diese Netze werden vor allem dann eingesetzt, wenn die zeitliche Abfolge der Eingaben relevant ist, da sie im Gegensatz zu Feedforward Netzen einen internen Zustand halten.

### 2.1.3 Aktivierungsfunktionen

Es gibt verschiedene Aktivierungsfunktionen, die für den Einsatz in neuronalen Netzen in Frage kommen. Sie sind notwendig, da ohne eine Nicht-Linearität das Netz in eine lineare Regression kollabiert, die dann wiederum nicht in der Lage ist nicht-lineare Funktionen darzustellen. Sowohl die Aktivierungsfunktion als auch ihre Ableitung sollte schnell zu berechnen sein, da dies im Rahmen des Trainings mit dem Backpropagation Algorithmus häufig geschieht und sonst beträchtlicher Rechenaufwand entsteht.

In der Vergangenheit wurden einige verschiedene Aktivierungsfunktionen verwendet. Jede dieser Funktionen stellt eine Nicht-Linearität dar und nimmt eine einzelne Zahl, wendet eine bestimmte, festgelegte mathematische Operation auf diese an und gibt das Ergebnis zurück. Historisch ist häufig die Sigmoid-Funktion  $\sigma(x)$  verwendet worden, die folgendermaßen definiert ist:

$$\sigma(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{e^{x+1}}.$$

In der Praxis jedoch haben sich einige Nachteile der Sigmoid-Funktion und artverwandter Funktionen gezeigt. Der schwerwiegendste davon ist die sogenannte Saturierung, dass die Ableitung der Sigmoid-Funktion für betragsmäßig große Eingaben beinahe 0 ist. Das sorgt für einen langsamen Lernprozess. In letzter Zeit haben sich sogenannte *Rectified Linear Units*, oder kurz ReLUs, durchgesetzt. Diese sind folgendermaßen definiert:

$$f(x) = \max(0, x),$$

$$f'(x) = \begin{cases} 0 & , \text{ falls } x < 0 \\ 1 & , \text{ falls } x > 0 \end{cases}.$$

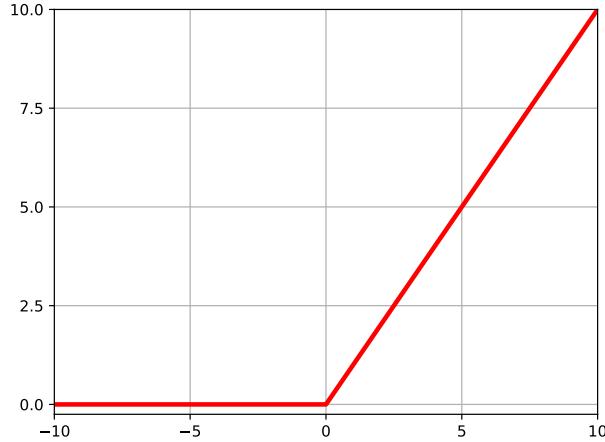


Abbildung 2.3: Schaubild der Ausgabe einer ReLU.

Abbildung 2.3 zeigt das Schaubild einer solchen ReLU. Die Aktivierung von ReLUs ist ein einfacher Schwellwert, der weit weniger rechenintensiv ist als die aufwendigen Exponentialfunktionen von Sigmoid und tanh. In der Praxis hat sich zudem gezeigt, dass ReLUs oft deutlich schneller konvergieren als Sigmoid- oder tanh-Neuronen, da sie kein Problem mit Saturierung haben. Krizhevsky et al. haben in ihrem Paper [KSH12] einen Geschwindigkeitsgewinn um Faktor 6 feststellen können.

Ein Problem, das mit ReLUs jedoch existiert ist, dass einzelne Neuronen während dem Training „absterben“ können, falls sie irgendwann in dem Bereich landen, in dem der Gradient 0 ist. Diese Neuronen sind dann für jeden beliebigen Input inaktiv und können niemals wieder etwas zur Ausgabe des Netzes beitragen. Durch die Wahl einer geeigneten Lernrate oder den Einsatz sogenannter Leaky ReLUs lässt sich dies jedoch vermeiden. Leaky ReLUs haben im Gegensatz zu normalen ReLUs eine kleine positive Steigung im negativen Bereich.

$$f(x) = \begin{cases} x & , \text{ falls } x > 0 \\ 0.01x & , \text{ falls } x \leq 0 \end{cases}$$

Je nachdem, welche Aufgabe das neuronale Netz erfüllen soll, können unterschiedliche Aktivierungsfunktionen für das Output Layer Sinn ergeben. Häufig genutzt ist die *Softmax*-Funktion für Klassifikation, da sie eine Wahrscheinlichkeitsfunktion als

Ausgabe hat. Für Regression benutzt man lineare Aktivierungsfunktionen für das Output Layer.

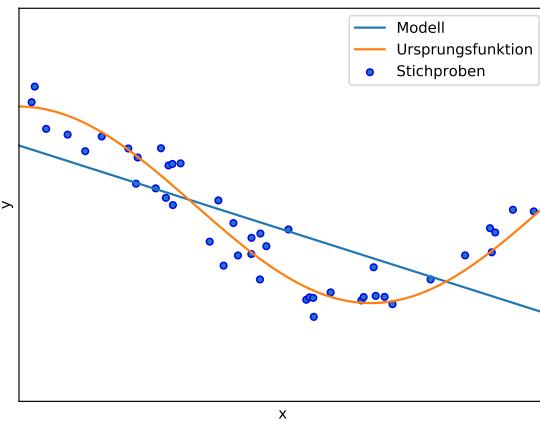
### 2.1.4 Performance-Maß

Neuronale Netze werden in der Regel danach bewertet, wie gut sie mit unbekannten Daten umgehen können. Trainingsdaten bezeichnen dabei die Daten, die während dem Trainings dazu benutzt werden, die einzelnen Gewichte des Netzes anzupassen. Testdaten sind ein von den Trainingsdaten disjunktes Datenset, auf denen die Qualität der Ausgaben des Netzes überprüft wird. Diese Eigenschaft von Trainingsdaten auf unabhängige Testdaten schließen zu können wird Generalisierung genannt.

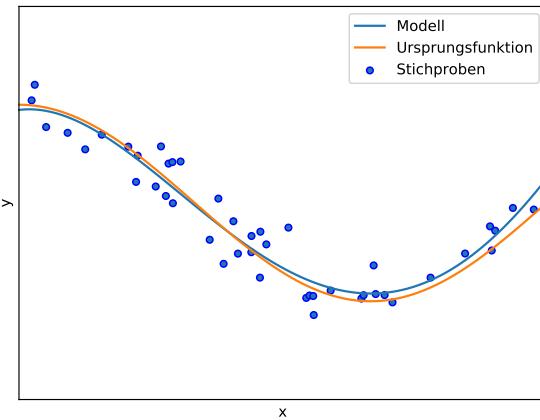
Als Overfitting bezeichnet man es, wenn ein gelerntes Modell sich zu sehr an den zum gegebenen Training betrachteten Datensatz anpasst und dafür in Kauf nimmt, zusätzliche oder zukünftige Daten schlechter zu repräsentieren. Das Modell wird also schlechter darin zu generalisieren. Speziell im Feld der neuronalen Netze ist Overfitting meist daran zu erkennen, dass sich die Qualität der Ausgaben des Netzes auf dem Trainingsdatenset weiter verbessert, während sie auf dem Testdatenset schlechter wird. Dies kann zum Beispiel der Fall sein, wenn das Modell Rauschen in den Trainingsdaten als Teil der zugrundeliegenden Struktur interpretiert.

Dem Overfitting gegenüber steht das Underfitting. Als Underfitting bezeichnet man wenn das Netz nicht in der Lage ist eine ausreichend gute Performance auf den Trainingsdaten zu erreichen. Das kann passieren, wenn das Modell nicht ausreichend komplex ist, um die zugrundeliegende Struktur der Daten abzubilden. Sowohl Overfitting als auch Underfitting hängen mit der Kapazität eines Netzes zusammen. Ist die Kapazität zu gering, kann es sein, dass das Netz daran scheitert die Trainingsdaten zu lernen. Ist die Kapazität zu groß, so kann es passieren, dass das Netz gewissermaßen die Trainingsdaten einfach auswendig lernt. Dies ist beispielhaft in Abbildung 2.4 zu sehen. Aus der zugrundeliegenden Cosinus Funktion werden Stichproben mit einem Rauschterm entnommen. Stellvertretend für das Lernen mit neuronalen Netzen wird hier lineare Regression benutzt, um die Parameter eines Polynoms zu lernen. Die Kapazität des Modells wird hier durch den Grad des Polynoms festgelegt.

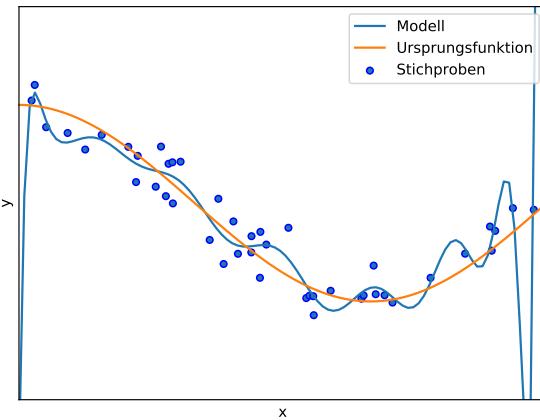
In Abbildung 2.4a wird ein Polynom mit dem Grad 1 gelernt. Die Kapazität ist zu niedrig und dementsprechend schafft das Modell es nicht die Stichproben akkurat zu repräsentieren. In Abbildung 2.4b ist der Grad des Polynoms 4. Das resultierende Modell ist eine gute Approximation der ursprünglichen Funktion. In Abbildung 2.4c ist der Grad des Polynoms mit 17 deutlich zu hoch. Man kann am resultierenden Modell erkennen, wie es dem Rauschen der Samples folgt und wie es an den Rändern des betrachteten Bereichs schnell divergiert.



(a) Underfitting mit Polynom von Grad 1



(b) Passendes Modell – ein Polynom von Grad 4



(c) Overfitting mit Polynom von Grad 17

**Abbildung 2.4:** Visualisierung von Modellen mit unterschiedlichen Kapazitäten.

Die beste Methode, um Overfitting zu vermeiden, ist es, mehr Trainingsdaten zu benutzen. In der Praxis kann dies oft umständlich, kostspielig oder sogar unmöglich sein, weshalb auf das Generieren von synthetischen Trainingsdaten, auch Datenaugmentierung genannt, zurückgegriffen wird. Auch der Einsatz von Regularisierungsverfahren kann helfen Overfitting zu verringern. Als letzter Schritt kann die Kapazität der Architektur gesenkt werden, zum Beispiel, indem die Anzahl der zur Verfügung stehenden Layer reduziert wird.

### 2.1.5 Regularisierung

Als Regularisierung bezeichnet man Techniken, die zur Vermeidung von Overfitting verwendet werden. Viele Techniken des maschinellen Lernens funktionieren so, dass sie den Fehler auf den Trainingsdaten reduzieren und damit potenziell indirekt auch den auf den Testdaten. Im Gegensatz dazu soll hier primär der Fehler auf den Testdaten reduziert werden, selbst wenn das zu schlechteren Ergebnissen auf den Trainingsdaten führt. Das Ziel ist also bessere Generalisierung.

Eine Möglichkeit ist, dass zur Loss-Funktion ein Regularisierungsterm  $R$  hinzugefügt wird, der die Kosten basierend auf der Komplexität des Modells erhöht.

$$\min_f \sum_{i=1}^m V(f(\underline{x}_i), \underline{y}_i) + \lambda R(f)$$

Dabei ist  $V$  die Loss-Funktion, beispielsweise *Mean-Square-Error* oder *Mean-Absolute-Error*.  $m$  ist die Anzahl der Feature-Label-Paare,  $\underline{x}_i$  ist ein Vektor, der die Eingabefeatures enthält und  $\underline{y}_i$  ist das dazugehörige Label. Die Funktion  $f$  ist in unserem Fall das neuronale Netz, das die Features entgegennimmt.  $\lambda$  ist ein Parameter, der die Gewichtung des Regularisierungsterms festlegt. Wählt man diesen Parameter zu klein, so kann es sein, dass das Modell trotz Regularisierung noch immer overfittet. Wählt man ihn zu groß, so kann es sein, dass das Modell das Problem nicht mehr korrekt abbildet und es zu Underfitting kommt.

Der Regularisierungsterm  $R$  wird so gewählt, dass er die Komplexität der Funktion  $f$  widerspiegelt. Ein gutes Maß für die Komplexität eines neuronalen Netzes sind die Gewichte zwischen den Neuronen. Beispiele für  $R$  wären zum Beispiel die  $L_1$ - oder die  $L_2$ -Regularisierung. Der entscheidende Unterschied zwischen den beiden ist der unterschiedlicher Strafterm, zu sehen in Gleichung (2.1) für  $L_1$  und Gleichung (2.2) für  $L_2$ . Die Fehlerfunktion ist jeweils MSE mit dazugehörigen Strafterm.  $\mathbf{W}_{j,k}$  ist

eine Matrix der Gewichte zwischen den einzelnen Neuronen.

$$J(X, Y) = \frac{1}{m} \sum_{i=1}^m (\underline{y}^{(i)} - \hat{\underline{y}}^{(i)})^2 + \sum_{j,k} (|\mathbf{W}_{j,k}|) \quad (2.1)$$

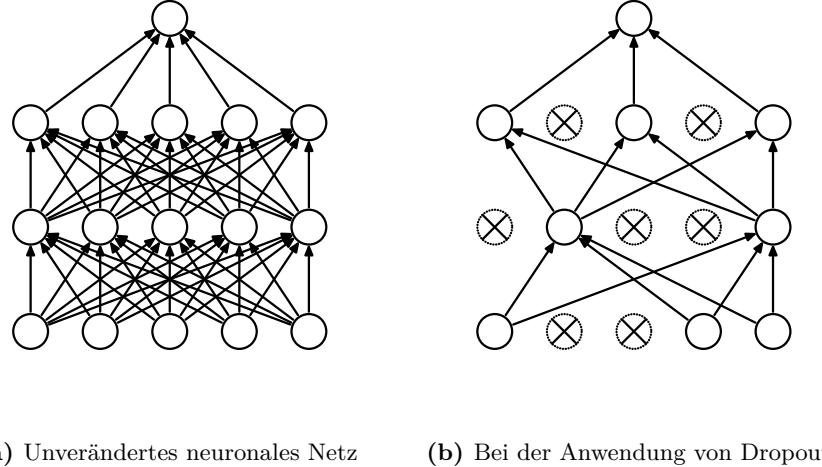
$$J(X, Y) = \frac{1}{m} \sum_{i=1}^m (\underline{y}^{(i)} - \hat{\underline{y}}^{(i)})^2 + \sum_{j,k} (\mathbf{W}_{j,k}^2) \quad (2.2)$$

Ein Regressionsmodell, das  $L_1$ -Regularisierung verwendet, wird auch als Lasso Regression bezeichnet, während ein Modell mit  $L_2$ -Regularisierung als Ridge Regression beschrieben werden kann. Vergleicht man die beiden Ansätze, so schrumpft die  $L_1$ -Norm weniger wichtige Gewichte auf 0, was zu dünn besetzten Gewichtsvektoren führt. Dies kann eine wünschenswerte Eigenschaft sein. Im Gegensatz dazu hat die  $L_2$ -Regularisierung den Vorteil, dass sie effizienter berechnen werden kann. Der Strafterm von  $L_2$  hat eine geschlossene Form und kann in Form einer Matrix angewendet werden, während die Funktion von  $L_1$  auf Grund des Betrags eine nicht-differenzierbare ist. Außerdem wird die Existenz von großen Gewichten stärker bestraft als bei der  $L_1$ -Regularisierung.

Eine weitere Regularisierungstechnik ist Dropout [SHK+14]. Dabei werden während dem Training eines neuronalen Netzes mit einer festgelegten Wahrscheinlichkeit zufällig Neuronen und die dazugehörigen Verbindungen abgeschaltet, wie in Abbildung 2.5 dargestellt. Dies soll insofern Overfitting vermeiden, dass es übermäßige Coadaption von mehreren Neuronen erschwert. Dropout als Technik wird insbesondere bei tiefen neuronalen Netzen mit einer hohen Anzahl von Hidden Layers eingesetzt. Als Early Stopping wird eine Technik bezeichnet, bei der die Regularisierung durch das frühzeitige Beenden des Trainings erreicht wird [GBC16, Kapitel 7.8]. Dabei wird versucht abzuschätzen, an welchem Punkt des Trainings eine Verbesserung der Ergebnisse auf dem Trainingsset zu Lasten der Ergebnisse auf dem Testset stattfindet.

## 2.2 TableSort System

Der *TableSort*-Schüttgutsortierer ist eine modulare Versuchsplattform, die konzipiert wurde, um neue Schüttgutsortierkonzepte in einem kleineren Rahmen experimentell erproben zu können. Industrielle Schüttgutsortieranlagen sind sehr groß und etwas an ihrer Konfiguration zu ändern ist sowohl zeitaufwendig als auch arbeitsintensiv. Daher ist es sinnvoll, eine Plattform zu haben, die flexibel und transportabel ist und leicht umgebaut werden kann. Das System ist im Rahmen des *TrackSort*-Projekts in Kooperation zwischen dem Fraunhofer IOSB, Abteilung Sichtprüfsysteme, und dem Lehrstuhl für Intelligente Sensor Aktor Systeme des Karlsruher Institut für Technologie entstanden [Dol15]. Es kann in zwei verschiedenen Transportkonfigurationen



(a) Unverändertes neuronales Netz      (b) Bei der Anwendung von Dropout.

**Abbildung 2.5:** Beispiel für die Dropout-Regularisierung [SHK+14].

benutzt werden. Einmal werden die Schüttgutpartikel mittels eines Förderbands beschleunigt. Diese Konfiguration ist in Abbildung 2.6 zu sehen. Dazu kommt die Möglichkeit, das Förderband durch eine Rutsche zu ersetzen, sodass die Schüttgutpartikel stattdessen durch die Schwerkraft beschleunigt werden.

Im Rahmen dieser Arbeit wurde die Flächenkamera-Konfiguration mit einem Ringlicht zur Beleuchtung verwendet. Schematisch ist der Ablauf der Schüttgutsortierung in Abbildung 2.7 zu sehen. Die Funktionsweise des Systems wird im Folgenden erklärt. Das zu sortierende Schüttgut wird durch einen Schwingförderer nach und nach über eine Rutsche auf das Förderband aufgebracht. Dort wird es in Richtung des Druckluftdüsenarrays beschleunigt. Auf das vom Ringlicht beleuchtete Ende des Förderbands ist die Flächenkamera gerichtet. Kurz nachdem die Schüttgutpartikel die Flugphase beginnen, passieren sie das Druckluftdüsenarray. Dort werden sie, basierend auf ihrer Klassifizierung durch die Verarbeitung der Bilddaten von der Kamera, aussortiert oder passieren gelassen.



Abbildung 2.6: TableSort Schüttgutsortiersystem [Fra17].

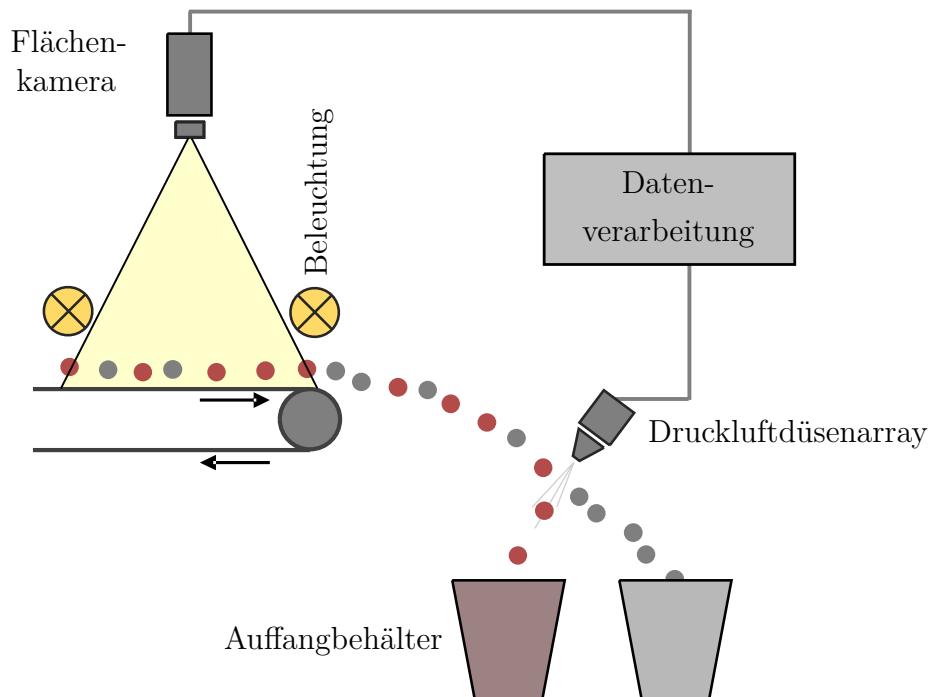


Abbildung 2.7: Schematische Darstellung des optischen Bandsortierers *TableSort* nach [PKP+17].

## 2.3 Stand der Technik

In dieser Arbeit geht es um die Prädiktion der Bewegung von Schüttgutpartikeln. Der Einsatz von verschiedenen Bewegungsmodellen ist erst für Schüttgutsortierer mit Flächenkamera sinnvoll. Eine Zeilenkamera liefert nur einen einzelnen Datenpunkt bezüglich Zeit und Position eines Partikels. Wie schon in Abbildung 1.1 dargestellt wurde, muss angenommen werden, dass es zu keinerlei Bewegung orthogonal zur Transportrichtung kommt. Für die Prädiktion des Zeitpunkts wird die durchschnittliche Zeit bestimmt, die ein Partikel von der Position der Zeilenkamera zur Position des Druckluftdüsenarrays benötigt und diese als konstanter Offset für jede Partikeldetektion angenommen.

Um den Separationsprozess durch den Einsatz von prädiktiven Tracking Methoden und Bewegungsmodellen zu verbessern, ist eine Assoziation der beobachteten Partikelpositionen zu tatsächlichen Tracks notwendig. Im Rahmen dieser Arbeit wird dieses Problem nicht betrachtet. Es wird direkt mit den assoziierten Trackdaten gearbeitet, obwohl dieser Assoziationsprozess noch Gegenstand aktueller Forschung ist.

Die grundlegenden Bewegungsmodelle aus der Tracking-Literatur, die in [Pfa18] beschrieben werden, sind einerseits das Constant Velocity Modell und andererseits das Constant Acceleration Modell. Das Constant Velocity Modell prädiziert die Bewegung eines Teilchens unter der Annahme, dass es sich mit einer konstanten Geschwindigkeit bewegt. Basierend auf den letzten zwei bekannten Positionen des Partikels wird dessen Geschwindigkeit entlang der beiden Achsen bestimmt und davon die zukünftige Bewegung abgeleitet. Diese Annahme ist jedoch nicht immer korrekt. Es kann unter anderem sein, dass bei einem Bandsortierer das Förderband nicht lang genug ist, um das Schüttgut komplett zu beruhigen. Dann haben die Teilchen eine Beschleunigung, die nicht 0 ist. Das Constant Acceleration Modell dahingegen prädiziert die Bewegung des Teilchens unter der Annahme, dass es sich mit einer konstanten Beschleunigung bewegt. Diese Beschleunigung wird anhand der letzten drei bekannten Positionen bestimmt. Anhand dieser Beschleunigung und der aktuellen Geschwindigkeit werden die zukünftigen Positionen abgeleitet.

In [Pfa18] werden weitere, szenariospezifische Bewegungsmodelle beschrieben. Bei dem sogenannten Bias-Corrected Constant Velocity Modell wird das Constant Velocity Modell als Grundlage genommen und ein Korrekturterm eingeführt. Basierend auf den zuvor beobachteten Schüttgutpartikeln wird ein durchschnittlicher temporaler Bias bestimmt, der von den zukünftigen Prädiktionen abgezogen wird. Die Annahme ist hier, dass die durchschnittliche Abweichung von zukünftigen Partikeln ähnlich zu dem der zuvor beobachteten Partikeln sein wird. Beim Identical Acceleration Modell wird

ebenfalls ein Korrekturterm benutzt, der im Gegensatz zum Bias-Corrected Constant Velocity Modell jedoch nicht absolut, sondern abhängig von der letzten bekannten Position des Partikels ist. Auf jedem der zuvor beobachteten Partikeln wird der Wert einer zusätzlichen Beschleunigung bestimmt, die zu einer optimalen Prädiktion führen würde, und dann der Durchschnitt dieser Beschleunigungen gebildet. Dieser wird dann als Korrekturterm auf ein Constant Velocity Modell addiert, sodass sich eine Formel ähnlich zu der des Constant Acceleration Modelles ergibt.

Um das Verhalten der Partikel, deren Geschwindigkeit sich der des Förderbands nähert ohne sie zu überschreiten, besser abzubilden als durch ein Constant Acceleration Modell, wird das Constant Acceleration with Limited Velocity Modell beschrieben. Dabei wird die Geschwindigkeit des Förderbands bestimmt und Partikel, die diese erreichen, ab diesem Zeitpunkt mit konstanter Geschwindigkeit weiter prädiziert. Es wurden zudem zwei Modelle, Constant Acceleration Disallowing Sign Change Modell und Ratio-Based Deceleration Modell, vorgestellt, die spezifisch konzipiert wurden, um die Bewegungsprädiktion orthogonal zur Transportrichtung zu verbessern. Im Constant Acceleration Disallowing Sign Change Modell wird verhindert, dass wenn die Bewegung des Partikels orthogonal zur Transportrichtung auf 0 gesunken ist, das Partikel sich dann weiter in die entgegengesetzte Richtung beschleunigt. Das Ratio-Based Deceleration Modell bestimmt das Verhältnis zwischen der Orthogonalgeschwindigkeit zum Beginn der Prädiktion und zu der am Ende für bereits beobachtete Partikel und schließt basierend darauf auf das Verhalten von zukünftigen Partikeln.



## KAPITEL 3

# Datenverarbeitung

Bei maschinellen Lernverfahren ist die Qualität und die Menge der zugrundeliegenden Daten sehr wichtig, da diese die Güte des Ergebnisses stark beeinflussen können. Im Rahmen dieser Masterarbeit wurden zweierlei Arten von Daten benutzt: Einerseits wurden am *TableSort*-Schüttgutsortierer des Fraunhofer IOSBs Aufnahmen gemacht, die dann über mehrere Arbeitsschritte in das richtige Datenformat übersetzt wurden. Zudem existieren Datensätze, die durch eine Simulation mittels der *Diskrete-Elemente-Methode* (DEM) entstanden sind. In diesem Kapitel soll nun beschrieben werden, woher diese Daten kommen, wie sie verarbeitet werden und in welcher Form sie dann letztendlich in die neuronalen Netze gegeben werden. Abschließend wird die Datenaugmentierung, die vorgenommen wurde, vorgestellt und erklärt.

## 3.1 Eigene Aufnahmen

In diesem Abschnitt soll beschrieben werden, welche Form die am Fraunhofer IOSB selbst aufgenommenen Daten haben und welche Konfigurationen bezüglich Schüttgut und Sortierer sie darstellen.

Zur Aufnahme der Daten wurde eine Bonito CL-400 200 FPS Kamera benutzt. Diese wurde, wie in Abbildung 2.6 dargestellt, oberhalb des Förderbandes beziehungsweise der Rutsche angebracht. Die Bilder, die von der Kamera aufgenommen werden, haben eine Auflösung von 2320x1726 Pixel [All14]. Anhand mehrerer Kalibrierungsbilder wurde bestimmt, dass 1 Pixel im Bild ungefähr 0.056 mm entspricht. Im weiteren Verlauf der Arbeit wird mit Pixeln (px) als der Einheit des Orts für die selbst aufgenommenen Bilder gearbeitet.

Aufgenommen wurden Daten von vier verschiedenen Schüttgütern: Kugeln, grüne Pfefferkörner, Zylinder und Weizenkörner. Diese Schüttgüter sind in Abbildung 3.1 in Schüsseln und in Abbildung 3.2 und 3.3 auf dem Förderband beziehungsweise auf der Rutsche zu sehen. Die Kugeln bestehen aus Holz und haben einen Durchmesser

von 5 mm. Die Zylinder bestehen ebenfalls aus Holz. Sie haben eine Länge von 9 mm und einen Durchmesser von 3 mm. Die Kugeln und der Pfeffer sowie die Zylinder und die Weizenkörner bilden jeweils Paare aus einem geometrischen Körper und einem echten Objekt, das grob dessen Form ähnelt.

Alle Schüttgüter wurden auf der Förderbandkonfiguration des *TableSort*-Systems aufgenommen. Zusätzlich wurden Kugeln und Pfefferkörner auf der Rutschenkonfiguration des *TableSort*-Systems aufgenommen.



(a) Kugeln.

(b) Pfefferkörner.

(c) Zylinder.

(d) Weizenkörner.

**Abbildung 3.1:** Verschiedene Schüttgüter.

## 3.2 Datenpipeline

Die Features, die für das Trainieren der Netze benutzt werden, sind die Koordinaten der Mittelpunkte der Partikel. Diese aus den aufgenommenen Bildern zu bestimmen, ist die Aufgabe dieser Pipeline. Diese Vorverarbeitung wird vor dem eigentlichen Training durchgeführt und die Ergebnisse abgespeichert.

Am Anfang davon stehen die Bilder, die die Bonito-Kamera in Form einer Bayer-Matrix aufnimmt, wie sie in Abbildung 3.4 zu sehen ist. Die Bilder werden in Batches von je 3500 Bildern gesammelt und in Bitmap-Dateien geschrieben. Auf Grund der Menge an Bildern und dem damit verbundenen Speicherbedarf wurden die Bilder



(a) Kugeln auf dem Förderband.



(b) Pfefferkörner auf dem Förderband.

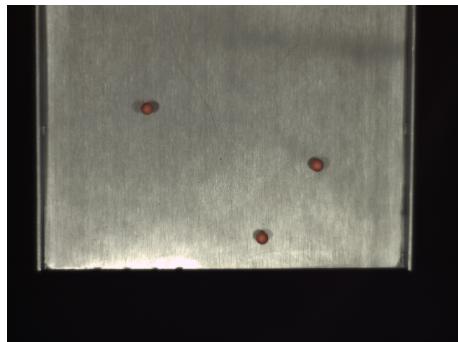


(c) Zylinder auf dem Förderband.

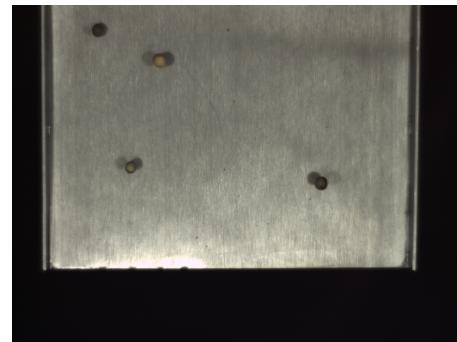


(d) Weizenkörner auf dem Förderband.

**Abbildung 3.2:** Verschiedene Schüttgüter auf dem Förderband.

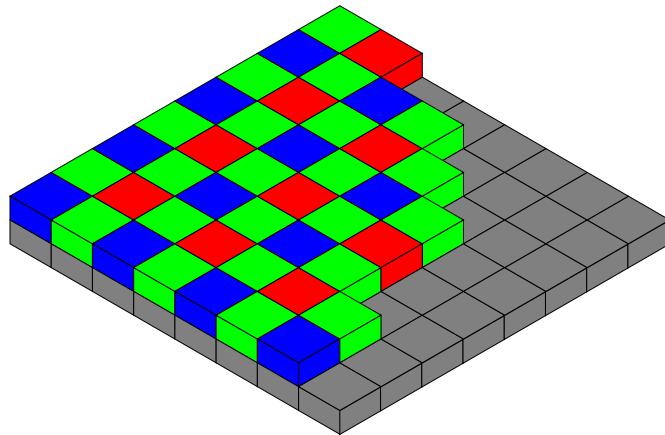


(a) Kugeln auf der Rutsche.



(b) Pfefferkörner auf der Rutsche.

**Abbildung 3.3:** Verschiedene Schüttgüter auf der Rutsche.



**Abbildung 3.4:** Bayer-Matrix auf einem Sensor [WC06].

zunächst in das PNG-Dateiformat übertragen. Danach werden die gebayerten Dateien zunächst durch einen Vorgang, der als *demosaicing* bezeichnet wird, als Farbbilder rekonstruiert. Dabei werden die ursprünglichen Farben für jeden Pixel mittels Interpolation über einen Rekonstruktionsfilter wieder hergestellt. Das geschieht mit einem Skript des Fraunhofer IOSB, das die Open Source Computer Vision Library OpenCV<sup>1</sup> benutzt. Dieses Skript wurde angepasst und dann damit die einzelnen Bilder in RGB-Farbbilder konvertiert. Auf diesen Bildern kann dann eine Segmentierung vorgenommen werden. Dafür wurde ebenfalls ein existierendes Skript des Fraunhofer IOSBs angepasst, in dem erneut die Computer Vision Library OpenCV benutzt wird. Für jede Sorte von Schüttgut wurde ein eigenes Parameterprofil von Hand optimiert. Ein solches Parameterprofil besteht aus einem oberen und unteren Grenzwert in jeder Komponente des HSV-Raums und einer minimalen Fläche, die ein Teilchen umfassen muss. Entsprechend der im Profil festgelegten Parameter werden für die einzelnen Bilder Masken angelegt, die angeben, ob die HSV-Werte der einzelnen Pixel innerhalb oder außerhalb der Grenzwerte liegen. Mit diesen Masken werden alle Konturen von Schüttgutpartikeln extrahiert. Die Konturen werden dann bezüglich der Plausibilität ihrer Größe und Form gefiltert. Im letzten Schritt wird nun der gewichtete Mittelpunkt der verbleibenden Konturen bestimmt und abgespeichert.

Das Ergebnis von diesem Segmentierungsskripts ist eine CSV-Datei für jeden Batch. Ein Beispiel für einen Ausschnitt aus solch einer Datei ist in Tabelle 3.1 zu sehen. Eine Zeile repräsentiert jeweils ein Bild aus dem Batch, also einen Zeitschritt. Zu Beginn jeder Zeile steht zunächst die Frame-Nummer, gefolgt von der Anzahl der detektierten Partikel und den Koordinaten der Mittelpunkte der detektierten Partikel, die aufgefüllt werden. Aus den Mittelpunkten in dieser CSV-Datei werden nun mittels des in MATLAB implementierten *Multi-Target-Tracking*-Algorithmus die in

---

<sup>1</sup> <https://opencv.org/>

dem Datensatz vorhandenen Tracks abgeleitet, die dann wiederum in einer neuen CSV-Datei gespeichert werden. Die detektierten Mittelpunkte werden jeweils einer Track-ID zugeordnet. Die einzelnen Tracks werden als Spaltenpaare dargestellt, mit jeweils einer Spalte für die x- und y-Koordinaten und einer Zeile für jeden Zeitschritt. Ein Ausschnitt aus einer solchen Datei ist in Tabelle 3.2 zu sehen. Dies ist der Zustand in dem die Daten dann im Programmcode für das Training und für die Evaluation geladen werden.

### 3.3 Simulierte Daten

Neben den selbst aufgenommenen Daten wurde im Rahmen dieser Arbeit auch mit einigen existierenden Datensätzen gearbeitet. In [PKEW+16] und [PPM+17] wird dargelegt, wie diese Datensätze basierend auf einer hochgenauen numerischen Simulation des *TableSort*-Systems mittels der Diskrete-Elemente-Methode erstellt wurden. Dabei werden anhand ihres Zustands und der relevanten physikalischen Gesetze die auf die einzelnen Elemente wirkenden Kräfte und deren Verhalten numerisch berechnet. In Abbildung 3.5 ist die virtuelle Nachbildung des Schüttgutsortierers zu sehen, auf dem die Simulation durchgeführt wurde. Die Positionsdaten in den Datensätzen waren ursprünglich mit einer Frequenz von 1000 Hz aufgelistet. Um jedoch Vergleichbarkeit mit den realen Daten zu erhalten, wurde diese Frequenz auf 200 Hz reduziert. Die Positionsangaben der Simulation werden in Metern angeben. Die Transportrichtung des Förderbandes ist entlang der x-Achse. Das Förderband erstreckt sich entlang der y-Achse von 0.0 m bis 0.18 m und entlang der x-Achse von 0.388 m bis 0.788 m.

Dennoch gibt es einige Unterschiede zwischen den selbst aufgenommenen und den simulierten Daten. Von diesen Unterschieden ist der schwerwiegendste, dass die Positionen der simulierten Partikel eine absolut verlässliche Ground Truth sind, die direkt aus der Simulation entnommen wurde. So verlässlich sind die Partikelpositionen bei den selbst aufgenommenen Daten nicht. Während den einzelnen in Sektion 3.2 beschrieben Schritten kann es zu Fehlern kommen, die sich durch die gesamte Pipeline fortpflanzen. In Ermangelung von idealen Kameras muss man von Ungenauigkeiten bei den Aufnahmen durch Bildrauschen ausgehen. Zudem kann die Segmentierung an einigen Stellen nicht präzise sein, indem z. B. ein Stück Schatten als Teil des Partikels interpretiert wird und dadurch den Mittelpunkt verschiebt. Bei einer Kollision von zwei Partikeln kann es dazu kommen, dass der *Multi-Target-Tracking*-Algorithmus die beiden Tracks vertauscht. Des Weiteren bewegt sich das Förderband in der Simulation mit  $1.5 \text{ m s}^{-1}$ , während Messungen am realen *TableSort*-System darauf hindeuten, dass das Förderband dort nur eine Geschwindigkeit von circa

**Tabelle 3.1:** Ausschnitt aus dem Ergebnis des Segmentierungsskripts

Frame	#MP	MP_1_x	MP_1_y	MP_2_x	MP_2_y	MP_3_x	MP_3_y
636	1	1222.9975	92.7641	NaN	NaN	NaN	NaN
637	1	1223.4063	182.9758	NaN	NaN	NaN	NaN
638	1	1223.6052	273.2425	NaN	NaN	NaN	NaN
639	1	1223.7067	364.0339	NaN	NaN	NaN	NaN
640	1	1224.0704	453.9057	NaN	NaN	NaN	NaN
641	2	1224.2051	544.5191	1692.4549	43.8822	NaN	NaN
642	2	1224.5793	634.7288	1696.6901	135.9595	NaN	NaN
643	2	1224.9082	726.0094	1700.451	229.1195	NaN	NaN
644	2	1225.2296	815.9663	1704.1472	321.2075	NaN	NaN
645	2	1225.4286	906.7078	1708.0593	414.2785	NaN	NaN
646	2	1225.7588	996.0286	1711.5309	506.0545	NaN	NaN
647	3	1226.0411	1086.5729	1714.8831	599.5417	961.8821	62.7111
648	3	1226.2337	1175.9271	1718.1401	691.6325	958.5526	154.3124
649	3	1226.2073	1265.7495	1721.6618	784.5927	955.3107	246.5241
650	3	1226.2543	1354.9362	1724.9158	876.7192	952.4919	338.1123
651	3	1226.2634	1444.5903	1728.3341	970.2909	949.2896	430.9692
652	3	1226.0845	1533.0901	1732.1745	1062.4624	946.3455	522.8667
653	3	1225.7319	1621.8461	1735.8759	1155.2937	943.3384	615.4545
654	2	1739.6714	1247.1867	940.2511	707.7306	NaN	NaN
655	2	1743.4279	1339.4146	937.2216	800.4557	NaN	NaN
656	2	1747.1525	1430.2501	934.5311	891.7249	NaN	NaN
657	2	1750.9771	1521.8102	931.6626	984.2284	NaN	NaN
658	2	1754.1491	1612.5565	928.7587	1076.4749	NaN	NaN
659	1	925.8463	1168.794	NaN	NaN	NaN	NaN
660	1	922.8752	1260.7461	NaN	NaN	NaN	NaN
661	1	920.2056	1352.8549	NaN	NaN	NaN	NaN
662	1	917.4051	1444.3431	NaN	NaN	NaN	NaN
663	1	914.6493	1535.5131	NaN	NaN	NaN	NaN
664	1	911.8565	1626.5341	NaN	NaN	NaN	NaN

**Tabelle 3.2:** Ausschnitt aus dem Ergebnis des *Multi-Target-Tracking*-Algorithmus

TrackID_4_X	TrackID_4_Y	TrackID_5_X	TrackID_5_Y	TrackID_6_X	TrackID_6_Y
1036.4613	82.3719	1899.9239	83.2049	1654.4423	50.6811
1033.0189	174.9809	1896.8142	171.3283	1655.3193	143.9749
1029.6167	266.4979	1893.5937	259.8098	1656.0221	237.1573
1026.3908	358.4831	1890.3912	348.1731	1656.8966	329.8636
1023.0203	449.6429	1887.1035	436.4588	1657.6308	423.1592
1019.5391	542.2334	1883.7761	525.1073	NaN	NaN
NaN	NaN	1880.2716	613.0896	NaN	NaN
NaN	NaN	1876.6054	701.9719	NaN	NaN
NaN	NaN	NaN	NaN	NaN	NaN

$1.1 \text{ m s}^{-1}$  erreicht. Ein weiterer Unterschied ist der Aufnahmebereich. Im Gegensatz zu den selbst aufgenommenen Daten, die nur Informationen zu den Bewegungen der Partikel im Bereich, auf den die Hochgeschwindigkeitskamera gerichtet ist, umfassen, befinden sich in den DEM-Datensätzen die Positionen der Teilchen über die gesamte Länge des Förderbandes. Das bedeutet auch, dass in den DEM-Datensätzen die Phase der Partikel bevor und während sie vom Förderband beruhigt werden, enthalten ist. Außerdem hat es zur Folge, dass die individuellen Tracks deutlich länger sind, also mehr Messungen enthalten. Bei der NextStep-Prädiktion sorgt das dafür, dass es insgesamt eine deutlich größere Anzahl an Feature-Label-Paaren gibt. Die Transportrichtung des Förderbandes ist ebenfalls nicht identisch. Während die selbst aufgenommenen Datensätze eine Bewegung entlang der y-Achse haben, bewegen sich die simulierten Partikel entlang der x-Achse.

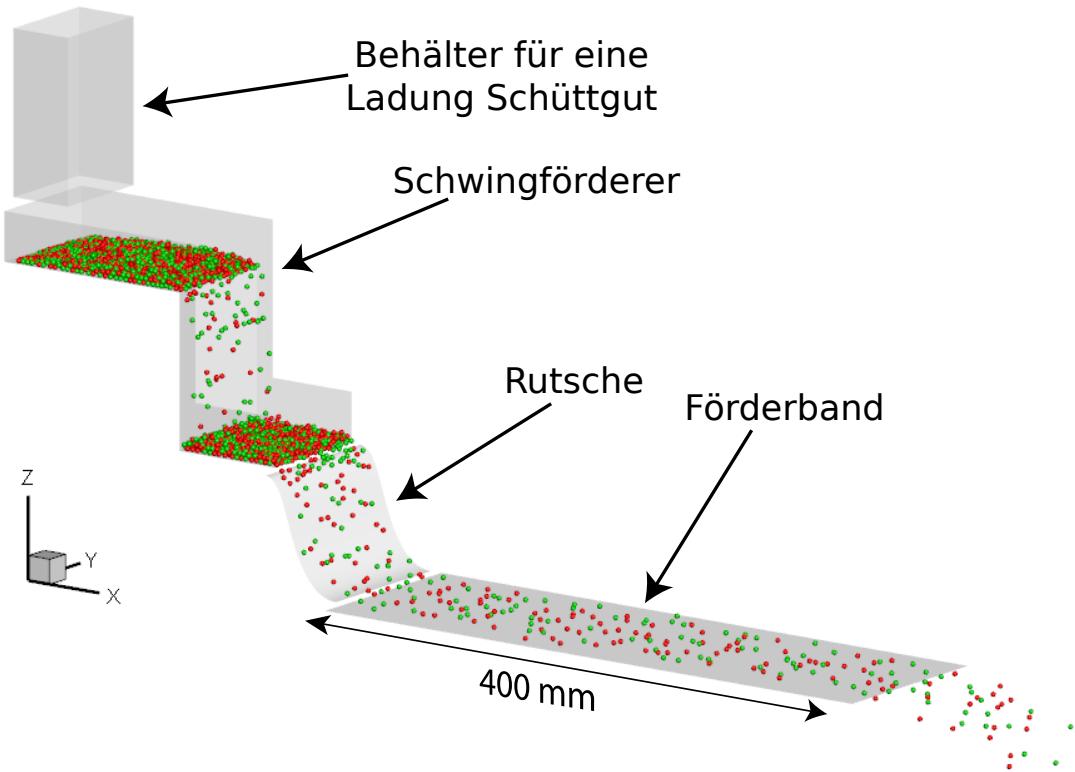


Abbildung 3.5: Visualisierung der DEM-Simulation, übersetzt aus [Pfa18].

## 3.4 Datenformatierung

Das Format, das die Daten annehmen, ist für die NextStep- und die Separator-Netze leicht unterschiedlich. Die Feature-Label-Paare der unterschiedlichen Anwendungen unterscheiden sich nur in den Labels. Die Eingangsdaten sind – abhängig von einem

TrackID 4 X	TrackID 4 Y
1036.4613	82.3719
1033.0189	174.9809
1029.6167	266.4979
1026.3908	358.483
1023.0203	449.6429
1019.5391	542.2334
1016.1206	633.1533
1012.8021	725.3765
1009.4512	816.8757
1006.0784	909.1367
1002.6553	1000.4947
999.3077	1092.9584
996.0751	1183.6545
992.8973	1274.7595
989.7239	1365.358
986.3243	1456.6952
982.8463	1546.6372
979.6845	1637.0949
NaN	NaN

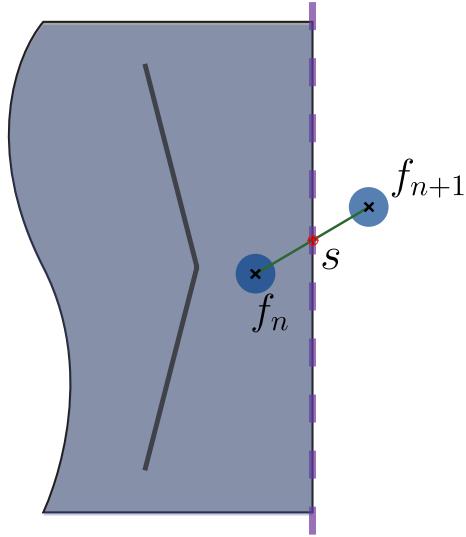
**Abbildung 3.6:** An diesem Ausschnitt eines Tracks wird beispielhaft mit FeatureSize 5 gezeigt, wie die einzelnen Feature-Label-Paare im NextStep-Fall entstehen. Der rote Rahmen markiert die 10 Features. Der blaue Rahmen markiert das dazugehörigen Label.

Hyperparameter – in beiden Fällen die Position des Partikels zu den letzten  $n$  Zeitschritten. Deshalb muss beim Format der Features kein Unterschied zwischen der Art der Aufgabe gemacht werden.  $n$  ist ein Hyperparameter und wird *FeatureSize* genannt. Die Features sind also ein  $2n$ -Tupel, bestehend aus  $n$  x-Koordinaten und  $n$  y-Koordinaten von den Mittelpunkten der  $n$  beobachteten Teilchen. Die Reihenfolge der Features ist für das neuronale Netz irrelevant, solange sie konsistent zwischen Training und Evaluation bleibt. In der umgesetzten Implementierung ist es so, dass zuerst die x-Koordinaten und dann die y-Koordinaten in chronologischer Reihenfolge aufgeregelt sind.

Die Labels, die das NextStep-Netz benutzt, sind 2-Tupel. Diese bestehen aus den x- und y-Koordinaten des Partikels im nächsten Zeitschritt. Wie in Abbildung 3.6 dargestellt, befinden diese sich in der nächsten Zeile nach den Features.

Die Labels des Separator-Netzes sind ebenfalls 2-Tupel. Im Gegensatz zu denen des

NextStep-Netze können diese nicht direkt aus der CSV-Datei ausgelesen werden, da sie nicht gemessen werden. Stattdessen müssen sie berechnet werden. Dies ist in Abbildung 3.7 dargestellt. Für jedes Partikel wird die letzte Position vor dem Überqueren des Druckluftdüsenarrays  $f_n$  und die erste Position nach dem Überqueren  $f_{n+1}$  bestimmt. In Abbildung 3.8 sind dies die blau markierten Einträge. Dabei wird die angenommen, dass die Geschwindigkeit des Partikels zwischen  $f_n$  und  $f_{n+1}$  konstant ist. Dies ist eine Approximation, die ebenfalls in [Pfa18] verwendet wird. Das erste Element eines jeden Labels ist die Koordinate entlang der Achse orthogonal zur Bewegungsrichtung des Förderbandes, wo das Partikel den Druckluftdüsenarray passiert. Diese erhalten wir, indem wir den Schnittpunkt  $s$  zwischen der Strecke  $f_n$  nach  $f_{n+1}$  und der Gerade des Druckluftdüsenarray bestimmen. Das zweite Element ist die Zeit, die das Partikel noch brauchen wird, bis es das Druckluftdüsenarray passiert. Sie wird in der Einheit Frames angegeben. Die ganzzahlige Komponente hiervon ist durch das Zählen der Messungen im Track zu bestimmen. Die Nachkommastelle wird bestimmt als das Verhältnis von der Distanz zwischen  $f_n$  und  $s$  zu der Distanz zwischen  $f_n$  und  $f_{n+1}$ .



**Abbildung 3.7:** Geometrische Bestimmung der Labels, nach [Pfa18]. Die Transportrichtung ist von links nach rechts.  $f_n$  ist die Position des Partikels im Zeitschritt  $n$ , dem letzten bevor es das Druckluftdüsenarray passiert.  $f_{n+1}$  ist die Position des Partikels im Zeitschritt  $n + 1$ , dem ersten nach dem Passieren des Arrays.  $s$  ist der Punkt an dem das Partikel das Druckluftdüsenarray passiert.

Damit die Fehler der beiden Labelelemente sich ähnlich auf den Gesamtgradienten auswirken, selbst wenn ihre Werte in sehr unterschiedliche Wertebereichen liegen

TrackID 4 X	TrackID 4 Y
1036.4613	82.3719
1033.0189	174.9809
1029.6167	266.4979
1026.3908	358.483
1023.0203	449.6429
1019.5391	542.2334
1016.1206	633.1533
1012.8021	725.3765
1009.4512	816.8757
1006.0784	909.1367
1002.6553	1000.4947
999.3077	1092.9584
996.0751	1183.6545
992.8973	1274.7595
989.7239	1365.358
986.3243	1456.6952
982.8463	1546.6372
979.6845	1637.0949
NaN	NaN

**Abbildung 3.8:** An diesem Ausschnitt eines Tracks wird beispielhaft mit FeatureSize 5 gezeigt, wie die einzelnen Feature-Label-Paare im Separator-Fall entstehen. Analog zu Abbildung 3.6 ist ein Featurevektor markiert. Die Labels unterscheiden sich allerdings zwischen dem NextStep- und dem Separator-Fall. Der Schnittpunkt mit dem Druckluftdüsenarray befindet sich zwischen den beiden blau markierten Messungen und kann dementsprechend nicht direkt abgelesen werden.

oder einfach unterschiedliche Einheiten haben, werden die Labels komponentenweise standardisiert. Dieses Problem würde zum Beispiel auftreten, wenn sich die Werte des einen Elements im Bereich zwischen 0 und 1700 bewegen, während die des Anderen zwischen 1 und 25 liegen, so wie es bei den Separator-Netzen der Fall sein kann. Bei dem NextStep-Fall wäre die Standardisierung nicht zwingend notwendig, sie wurde allerdings, um die Einheitlichkeit zu wahren, für beide Fälle implementiert. Für die Standardisierung wird von der jeweiligen Komponente der Mittelwert und die Standardabweichung berechnet. Im Anschluss wird vom jeweiligen Eintrag  $S$  der zugehörige Mittelwert  $\mu$  subtrahiert und durch die korrespondierende Standardabweichung  $\sigma$  dividiert.

$$S_{\text{neu}} = \frac{S - \mu}{\sigma}$$

Durch die Standardisierung wird jedes Label so skaliert, dass die beiden Elemente der Labels jeweils einen Erwartungswert von 0 und eine Standardabweichung von 1 haben. Die Ausgaben des Netzes müssen umgekehrt zurück in die ursprüngliche Skalierung gerechnet werden.

Im Code gibt es die Möglichkeit, unterschiedliche Label-Elemente unterschiedlich zu gewichten, indem Weighted Mean Squared Error als Fehlerfunktion verwendet werden kann. Von dieser Möglichkeit wird in den später vorgestellten Ergebnissen nicht Gebrauch gemacht, beziehungsweise den beiden Elementen wird jeweils das Gewicht 1.0 zugewiesen. Diese Option könnte nützlich sein, falls die Ansteuerung der Druckluftdüsen eine maximale Auflösung hat, jenseits derer eine bessere Zeitprädiktion keine Verbesserung der Sortierqualität mehr erzielt.

## 3.5 Datenumfang

Im Rahmen dieser Arbeit wurden insgesamt 247 951 Bilder aufgenommen. Davon waren 177 951 Bilder auf dem Förderband und 70 000 Bilder auf der Rutsche. Die Verteilung dieser Bilder ist in Abbildung 3.9 dargestellt.

Der *Multi-Target-Tracking*-Algorithmus wurde benutzt, um die Anzahl der Kugeln zu bestimmen. Auf dem Förderband wurden 7712 Tracks von Kugeln, 7170 Tracks von Pfefferkörnern, 19 200 Tracks von Zylindern, und 8702 Tracks von Weizenkörnern zugeordnet. Zudem wurden 5132 Tracks von Kugeln und 3609 Tracks von Pfefferkörnern auf der Rutsche zugeordnet.

Im DEM-Datensatz sind die Tracks von 3713 Kugeln und 4357 Plättchen enthalten. Die Verteilung der Tracks ist in Abbildung 3.10 zu sehen.

Die Feature-Label-Paare, die aus den Tracks extrahiert werden, müssen in ein Trainingsset und ein Testset aufgeteilt werden. In manchen Situationen wird noch ein drittes Set, das sogenannte Validierungsset, benötigt. Dies ist zum Beispiel beim Hyperparameter-Tuning der Fall.

Hierbei ist wichtig, dass das Testset eine gute Repräsentation des gesamten Datensets ist und ausreichend groß ist, um statistisch aussagekräftige Ergebnisse zu produzieren. Im Rahmen dieser Arbeit wurde meist eine Aufteilung im Verhältnis 90:10 zwischen Trainings- und Testset vorgenommen. Es ist jedoch möglich, beliebige andere Splits in der Hyperparameter-Datei festzulegen.

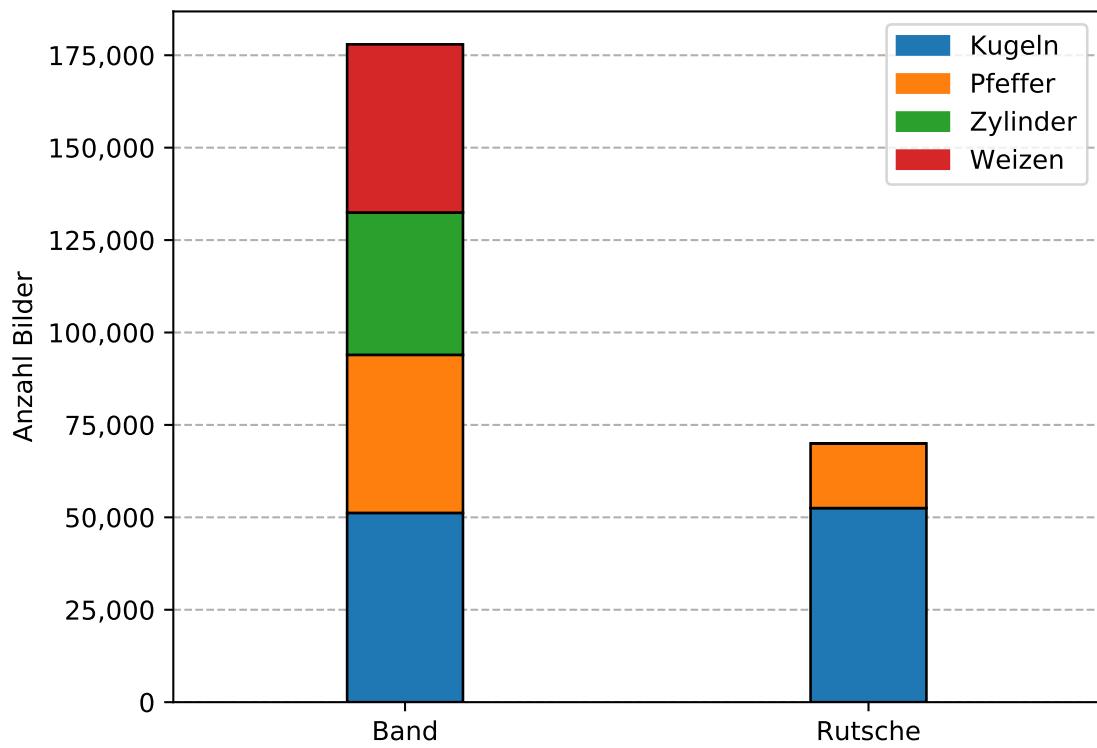


Abbildung 3.9: Balkendiagramm zur Verteilung der Bilder.

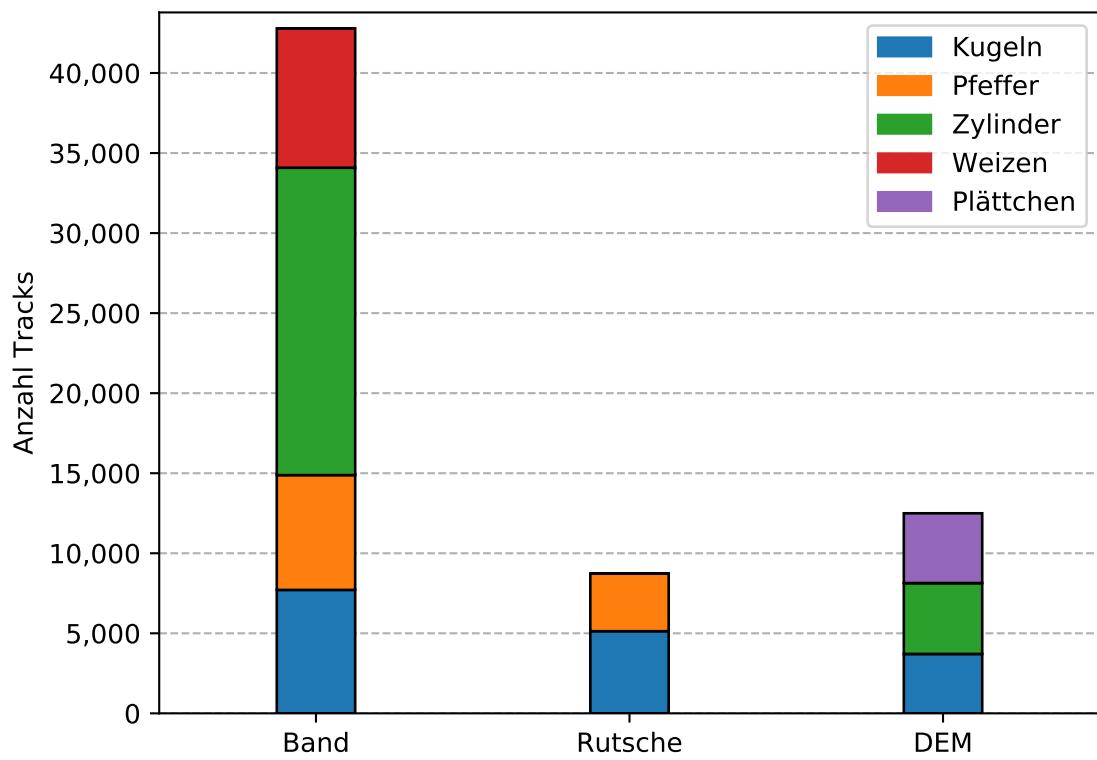


Abbildung 3.10: Balkendiagramm zur Verteilung der Tracks.

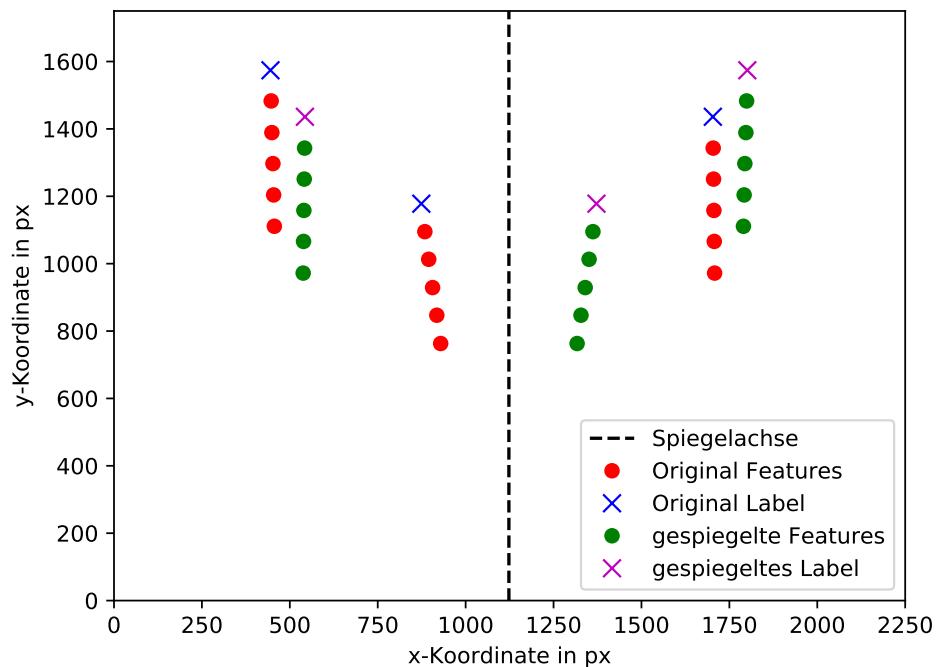
## 3.6 Datenaugmentierung

Als Datenaugmentierung oder auch Data Augmentation bezeichnet man Verfahren, die der eigenen Datenbasis Datenpunkte hinzufügen ohne zusätzliche Daten aufzunehmen [GBC16, Kapitel 7.4]. Man generiert aus den bestehenden Daten zusätzliche, synthetische Daten, die dann im Trainingsset eingesetzt werden können. Ausreichend viele Trainingsbeispiele zu haben ist notwendig, um mit neuronalen Netzen eine gute Performance zu erzielen. Die synthetischen Beispiele müssen jedoch konsistent mit den Originaldaten sein, da sie sonst die Qualität der Ausgabe des Netzes negativ beeinträchtigen können.

Für Netze, die in der Computer Vision eingesetzt werden, gibt es einige weit verbreitete Techniken, zum Beispiel Rotation, Translation, Spiegeln und das Ausschneiden von Teilbildern.

Für den gegebenen Fall mit den Mittelpunkten von Schüttgut-Partikeln als Features resultiert von diesen Techniken nur das Spiegeln in sinnvollen Daten. Eine beispielhafte Darstellung der vorgenommenen Datenaugmentierung ist in Abbildung 3.11 zu finden. Gespiegelt wird an der Mittellinie des Bands beziehungsweise der Rutsche, entlang der Bewegungsrichtung. Tracks, die eine gewisse Distanz zur Spiegelachse überschreiten, werden ausgenommen. Bei den selbst aufgenommenen Daten ist die Kamera nicht perfekt zentriert. Deshalb kann nicht ausgeschlossen werden, dass die gespiegelte Position eines Teilchens, das weit außen auf dem Förderband liegt, auf der gegenüberliegenden Seite bereits außerhalb des Förderbandes liegen würde. Solche unrealistischen Feature-Label-Paare dürfen nicht dem Trainingsset hinzugefügt werden.

Die Anwendung dieser Technik auf die vorhandenen Daten führt beinahe zu einer Verdoppelung der benutzbaren Feature-Label-Paare im Trainingsset, wovon ein positiver Effekt auf die Qualität der Ergebnisse zu erwarten ist.



**Abbildung 3.11:** Visualisierung der Datenaugmentierung durch Spiegelung an der Mittelachse.

## KAPITEL 4

# Umsetzung und Implementierung

In diesem Kapitel wird beschrieben, wie die neuronalen Netze, die für die Schüttgutprädiktion verwendet werden sollen, umgesetzt wurden. Dafür wird auf die verwendete Software eingegangen und die Struktur der Implementierung anhand eines Flussdiagramms betrachtet. Am Ende des Kapitels wird ein genauerer Blick auf die verwendeten Hyperparameter und deren Optimierung geworfen.

## 4.1 Software

Für die Umsetzung der neuronalen Netze wurde im Rahmen dieser Arbeit das Open Source Framework TensorFlow<sup>1</sup> verwendet. Es wurde die tensorflow-gpu Variante mittels pip in einer Python 3.6.5 virtuellen Umgebung installiert. Zu Beginn der Arbeit wurde die zum damaligen Zeitpunkt aktuelle TensorFlow Version 1.8 installiert, die zu einem späteren Zeitpunkt durch die Version 1.11 ersetzt wurde. Für den Umgang mit den Daten wurde die Python-Bibliothek *pandas* in der Version 0.23.1 genutzt. Weitere wichtige Software, die verwendet wurde, ist die Python-Bibliothek *matplotlib* in der Version 3.0.0, mit der die Visualisierung der Ergebnisse und die meisten Grafiken dieser Arbeit generiert wurden. Des Weiteren wurden die Python-Bindings von *OpenCV* in der Version 3.4.1.15 für die Verarbeitung der aufgenommen Bilder verwendet. Der als Grundlage verwendete *Multi-Target-Tracking*-Algorithmus ist in MATLAB implementiert worden. Deshalb sind Teile der Arbeit, die direkt darauf aufbauen, ebenfalls in MATLAB geschrieben.

## 4.2 Code-Struktur

Die grundlegende Struktur des Codes, der für das Training verantwortlich ist, ist in Abbildung 4.1 dargestellt. Aus der Hyperparameter-Datei werden die Hyperpara-

---

<sup>1</sup> <https://www.tensorflow.org/>

meter geladen und basierend darauf der TensorFlow Custom Estimator initialisiert. Außerdem werden die Daten aus den entsprechenden CSV-Dateien geladen und daraus jeweils ein *pandas DataFrame* mit den Feature-Label-Paaren des Trainingsssets und des Testsets generiert. In der Trainingsschleife wird dann ein Modell mit dem Trainingsset trainiert. Dies resultiert in dem trainierten Modell, das nun für die Prädiktion genutzt werden kann.

Der Ablauf der Evaluation ist in Abbildung 4.2 dargestellt. Um das aus dem Training resultierende Modell auszuwerten, werden die Feature-Label-Paare des Testsets benutzt. Dem trainierten Modell werden die Features als Eingabe gegeben, um die Prädiktionen zu erhalten. Am Ende steht als Ergebnis ein einzelnes *pandas DataFrame*, in dem alle Features, das zurücktransformierte Label, die Prädiktionen des Netzes und die Prädiktionen der verschiedenen Vergleichsmodelle jeweils für alle Feature-Label-Paare des Testsets enthalten sind. Hinzu kommen noch die Fehler aller dieser Prädiktionen, also die Differenz zwischen der Ground Truth aus dem Label, und den Prädiktionen selbst. Diese Fehler werden dann analysiert. Es werden Durchschnitt, Median und Quartile gebildet, welche dann mittels Boxplots und Histogrammen visualisiert werden. Diese Diagramme sind in Kapitel 5 zu finden.

### 4.3 Hyperparameter

Im Kontext des maschinellen Lernens bezeichnet man jene Variablen als Hyperparameter, die bereits vor dem Beginn des Trainings festgelegt sein müssen. Beispiele für solche Hyperparameter sind unter anderem die Netzarchitektur, wie die Anzahl der Layers und ihre jeweilige Größe oder die *FeatureSize*. Dieser Parameter legt fest, welche Form der Input des Netzes annimmt. Auch Parameter, die festlegen wie das Netz lernt – also Lernrate oder die Anzahl der Epochen beim Training – zählen dazu.

Bei der Implementierung dieser Arbeit wurde die Definition der Hyperparameter aus dem Programmcode selbst ausgelagert. Es können sogenannte Hyperparameter-Dateien im JSON-Dateiformat definiert werden, die dann vom Programm geladen werden. Das vereinfacht das Training und das Evaluieren von Netzen mit unterschiedlichen Hyperparameter-Konfigurationen. Einzelne Parameter aus den Dateien können per Kommandozeilenparameter überschrieben werden. Ein Beispiel für eine solche Hyperparameter-Datei ist in Listing 4.1 zu sehen. Die Bedeutung der einzelnen Parameter wird im Folgenden erklärt. Sollte es für einen Parameter eine begrenzte Menge an zulässigen Strings geben, so können diese aus dem Begleitdokument entnommen werden.

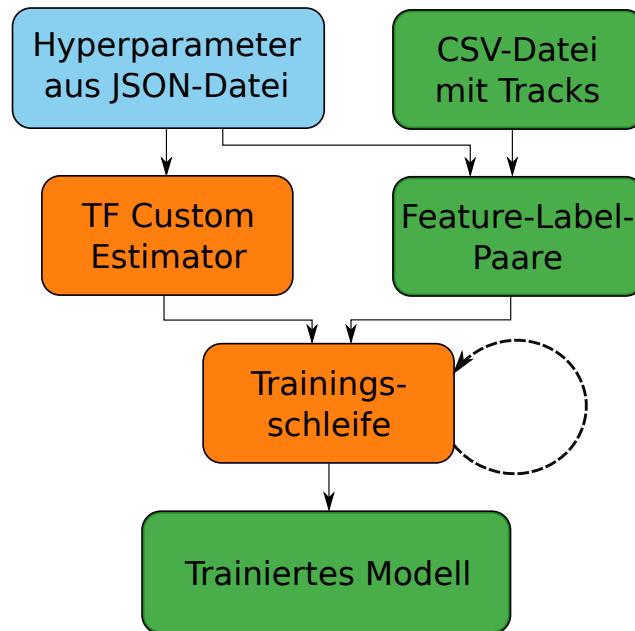


Abbildung 4.1: Skizziert Trainingsablauf eines neuronalen Netzes.

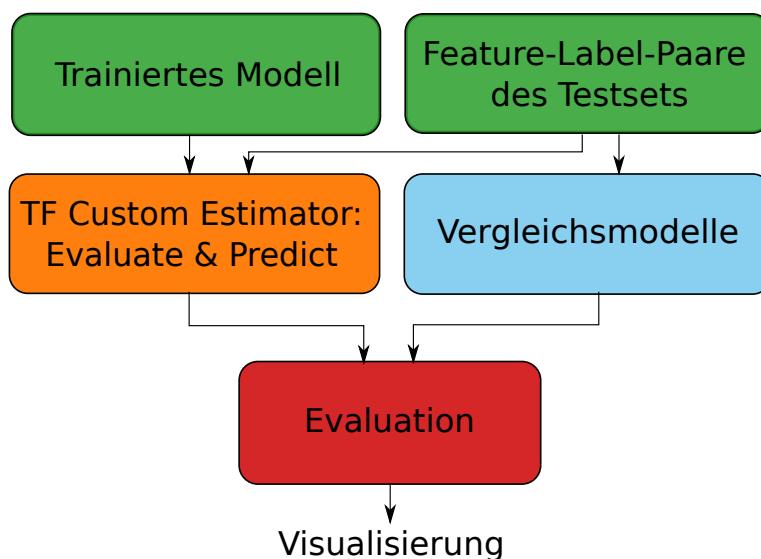


Abbildung 4.2: Skizzierte Ablauf der Evaluation eines neuronalen Netzes.

```
1
2      {
3          "arch": {
4              "dropoutRate": 0.0,
5              "hiddenLayers": [16, 16, 16],
6              "featureSize": 5,
7              "activation": "leaky_relu",
8              "regularization": "no"
9          },
10         "problem": {
11             "dataPath": "/home/hornberger/MasterarbeitTobias/data/
12                         selbstgesammelteDaten2/Kugeln-Band-Juli/",
13             "modelBasePath": "/home/hornberger/MasterarbeitTobias/
14                         models/real/NextStep/NextStep-SpheresReal",
15             "imagePath": "/home/hornberger/MasterarbeitTobias/images/
16                         RealSpheres-NextStep-45kDecaySteps",
17             "separator": 0,
18             "separatorPosition": 1550,
19             "thresholdPoint": 1200,
20             "predictionCutOff": 1500
21
22         },
23         "train": {
24             "batchSize": 500,
25             "epochs": 3000,
26             "stepsPerEpoch": 5000,
27             "learningRate": 0.005,
28             "decaySteps": 45000,
29             "optimizer": "Adam"
30         },
31         "data": {
32             "testSize": 0.1,
33             "augmentMidpoint": 1123,
34             "augmentRange": 1000,
35             "direction": "x",
36             "unitLoc": "px",
37             "unitTime": "1/100 Frames",
38             "limits": [0, 2350, 0, 1750]
39         }
40     }
```

**Listing 4.1:** Beispiel einer Hyperparameter-Datei in JSON.

**arch**

<b>dropoutRate</b>	Wahrscheinlichkeit für das zufällige Ausschalten von einzelnen Neuronen beim Training, entsprechend der Beschreibung in Unterabschnitt 2.1.5.
<b>hiddenLayers</b>	Ein eindimensionales Array an Zahlen, das die Architektur der Hidden Layers repräsentiert. Jede Zahl repräsentiert ein Fully-Connected Layer mit der entsprechenden Anzahl Neuronen.
<b>featureSize</b>	Anzahl der letzten Positionen des Partikels, die das Netz als Eingabe bekommt. Siehe Kapitel 3.
<b>activation</b>	Legt die Aktivierungsfunktionen für die Neuronen der Hidden Layers fest. Valide Optionen sind ReLU, Leaky ReLU und lineare Aktivierungsfunktionen.

**problem**

<b>dataPath</b>	Ort im Dateisystem, wo die CSV-Dateien liegen, in denen die Tracks gespeichert sind.
<b>modelBasePath</b>	Ort im Dateisystem, an dem das Modell des Netzes und alle damit verbundenen Dateien gespeichert wird, beziehungsweise woher es geladen wird.
<b>imagePath</b>	Ort im Dateisystem, wo Schaubilder, Visualisierungen oder Ähnliches gespeichert werden sollen.
<b>separator</b>	Hyperparameter, der festlegt, für welche Art von Aufgabe das Netz trainiert werden soll. 0 bedeutet es wird ein NextStep-Netz trainiert. 1 bedeutet es wird ein Separator-Netz trainiert.
<b>separatorPosition</b>	Koordinate des Düsenbalken und Ziel der Prädiktion entlang der Bewegungsrichtung des Förderbands.
<b>thresholdPoint</b>	Koordinate des Punkts, nach dem von der nächsten Beobachtung prädiziert wird.
<b>predictionCutOff</b>	Koordinate des Punkts, ab dem die Tracks beim Laden abgeschnitten werden.

## train

<b>batchSize</b>	Die Anzahl der Feature-Label-Paare, die in einer Iteration betrachtet werden.
<b>epochs</b>	Die Anzahl der Epochen, nach denen das Training beendet wird.
<b>stepsPerEpoch</b>	Die Anzahl der Iterationen, die in einer Epoche durchgeführt werden.
<b>learningRate</b>	Anfängliche maximale Lernrate, mit der die Gewichte geändert werden
<b>decaySteps</b>	Parameter, der festlegt, wie schnell die maximale Lernrate reduziert wird. Wie dieser Parameter verwendet wird, wird im weiteren Kapitel erklärt.
<b>optimizer</b>	Der Optimierer, der für das Training verwendet wird. Zulässig sind Adams, Adagrad und Gradient Descent

## data

<b>testSize</b>	Parameter, der die Aufteilung zwischen Trainings- und Testdaten festlegt. Ein Wert von 0.1 würde einen 90:10 Split Training zu Test bedeuten.
<b>augmentMidpoint</b>	Koordinate der Spiegelachse, an der für die Datenaugmentation gespiegelt wird.
<b>augmentRange</b>	Maximale Distanz eines Feature-Label-Paars zur Spiegelachse, bis wohin die Spiegelung angewendet werden soll. Feature-Label-Paare außerhalb des Bandes werden ignoriert.
<b>direction</b>	Bewegungsrichtung der Partikel. "x" bei simulierten und "y" bei selbst gesammelten Daten.
<b>unitLoc</b>	Einheit des Orts in der Visualisierung. "m" beziehungsweise Meter bei simulierten Daten, "px" beziehungsweise Pixel bei selbst gesammelten Daten.
<b>unitTime</b>	Einheit der Zeit in der Visualisierung. "Frames" beziehungsweise "1/100 Frames" für die hier verwendeten Daten.
<b>limits</b>	Bereich, der in der Visualisierung dargestellt wird ([0.388, 0.788, 0, 0.18] bei simulierten Daten und [0, 2350, 0, 1750] bei selbst gesammelten Daten).

## 4.4 Hyperparameter-Tuning

Als Hyperparameter-Optimierung oder auch Hyperparameter-Tuning bezeichnet man den Vorgang, das am besten geeignete Set an Hyperparametern für einen Lernalgorithmus zu finden.

In Rahmen dieser Arbeit wurden die Hyperparameter für die verschiedenen Szenarien manuell angepasst und verglichen. Da es zu zeitintensiv wäre, diesen Vorgang für jedes einzelne Szenario, bestehend aus dem verwendeten Schüttgut und der Art der Aufgabe, durchzuführen, wurden insgesamt nur zwei Sets an Hyperparametern gesucht. Eines davon wurde für NextStep-Netze angepasst und das andere für Separator-Netze. Diese wurden beide auf dem DEM-Kugel-Datensatz optimiert und dann auf die anderen Datensätze angewendet. Von dieser Betrachtung ausgenommen wurden Hyperparameter, die das Lernen nicht beeinflussen. Dies sind die Parameter der Kategorien **problem**, in der Dateipfade und Problemdefinitionen zu finden sind, und **data**, in der unter anderem die relative Größe des Testdatensets festgelegt wird.

Für beide Arten von Netzen hat sich gezeigt, dass eine Regularisierung mittels Dropout nicht nur keine Verbesserung mit sich bringt, sondern tatsächlich die Qualität der Ausgabe merklich reduziert. Deshalb wurde für die letztendlich verwendete Trainingskonfiguration die Dropout Rate für alle Szenarien auf 0.0 gesetzt. Auch bezüglich der Aktivierungsfunktionen und der Optimierer zeigen die Beobachtungen keinen Unterschied zwischen den beiden Aufgaben. In beiden Fällen haben sich Leaky ReLU und der Adam Optimizer als beste Option hervorgetan.

Eine während des Trainings sinkende Lernrate hat einen positiven Einfluss auf die Güte der Ausgabe der Netze gezeigt. Es wurde eine Technik namens *exponential learning rate decay* eingesetzt, die die Lernrate, die an den Optimierer übergeben wird, in Abhängigkeit der absolvierten Trainingsschritte reduziert. Die verwendete Lernrate entspricht dabei der folgenden Formel:

$$\text{aktuelle Lernrate} = \text{Basislernrate} \cdot \lambda^{\frac{\text{globaler Trainingsschritt}}{\text{Zerfallschritte}}}$$

Die Zerfallskonstante  $\lambda$  wurde als 0.96 festgelegt, während die Basislernrate und die Zerfallschritte anpassbare Hyperparameter sind.

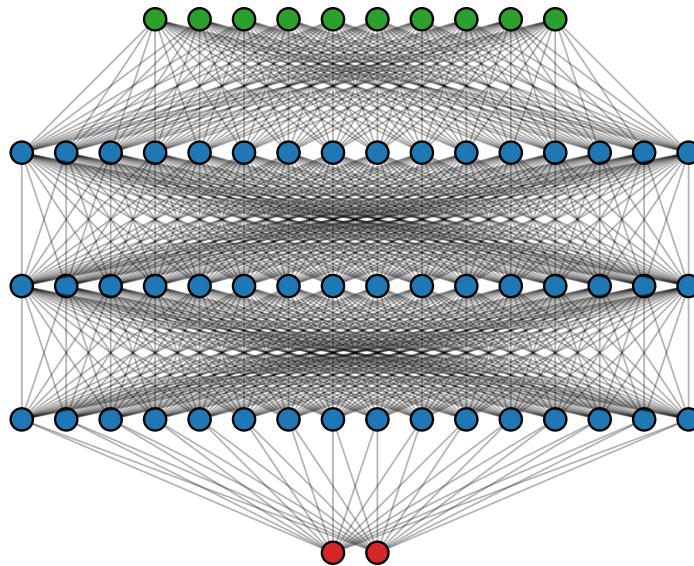
Das Ergebnis des Hyperparameter-Tunings bezüglich der Netzarchitektur für die NextStep-Netze ist in Abbildung 4.3 zu sehen. Auf den Testdaten produzierte von den erprobten Konfigurationen eine FeatureSize von 5 in Kombination mit 3 Hidden Layers mit jeweils 16 Neuronen die besten Ergebnisse. Weder  $L_1$ - noch  $L_2$ -Regularisierung zeigen einen positiven Effekt auf die Trainingsergebnisse, weshalb für die NextStep-Netze darauf verzichtet wurde.

Was die Lernparameter angeht, so sieht das Ergebnis des Hyperparameter-Tunings folgendermaßen aus:

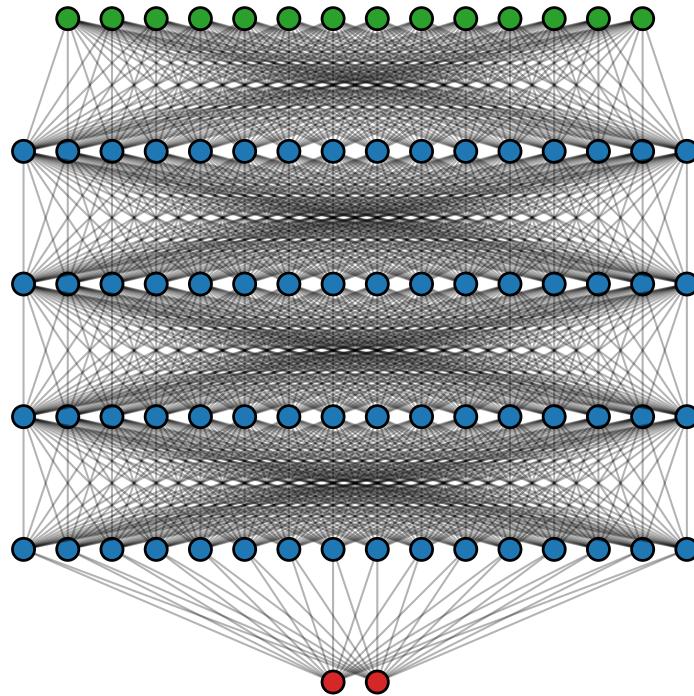
- **batchSize** von 500
- Training über insgesamt 3000 Epochen mit jeweils 5000 Iterationen
- Basislernrate von 0.005 und 45 000 Zerfallsschritte

Die Netzarchitektur, die für die Separator-Netze ermittelt wurde, ist in Abbildung 4.4 zu sehen. Hier sorgt eine FeatureSize von 7 für bessere Ergebnisse. Dies könnte zumindest teilweise damit erklärt werden, dass für die Separator-Netze im Gegensatz zu den NextStep-Netzen eine höhere FeatureSize nicht mit einer Reduktion der Anzahl an Trainingsbeispielen einhergeht. Des Weiteren wurde bei 4 Layers mit jeweils 16 Neuronen die besten Ausgaben von den erprobten Konfigurationen erzielt. Im Gegensatz zu den NextStep-Netzen hat die  $L_1$ -Regularisierung bei den Separator-Netzen die Güte der Ergebnisse auf den Testdaten verbessert. Das Hyperparameter-Tuning hat für die restlichen Hyperparameter die folgenden Werte ergeben:

- **batchSize** von 100
- Training über insgesamt 1000 Epochen mit jeweils 5000 Iterationen
- Basislernrate von 0.005 und 60 000 Zerfallsschritte



**Abbildung 4.3:** Architektur eines neuronales Netzes für die NextStep-Prädiktion. Die grün markierten Neuronen sind das Input Layer, die Neuronen der verschiedenen Hidden Layers sind blau markiert. Die Ausgabe des neuronalen Netzes erfolgt über die rot markierten Neuronen.



**Abbildung 4.4:** Architektur eines neuronales Netzes für die Separator-Prädiktion. Die grün markierten Neuronen sind das Input Layer, die Neuronen der verschiedenen Hidden Layers sind blau markiert. Die Ausgabe des neuronalen Netzes erfolgt über die rot markierten Neuronen.



## KAPITEL 5

# Evaluation

Im vorhergegangenen Kapitel wurde die Implementierung der neuronalen Netze beschrieben. Nun wird in diesem Kapitel betrachtet, wie gut die Ergebnisse sind, die von diesen Netzen geliefert werden. Dazu wird zunächst beschrieben, auf was für einem System das Training und die Evaluation durchgeführt wurde. Es werden mehrere, bereits aus dem Stand der Technik bekannte Modelle beschrieben, die dann mit den Ergebnissen der neuronalen Netze verglichen werden. Anschließend werden diese Ergebnisse diskutiert.

Alle in dieser Arbeit vorgestellten Netze wurden auf einem Ubuntu 18.04 Linux System trainiert und evaluiert. Dieses verfügt über einen Intel i7-7700k CPU mit 4.20 GHz, 32 GB RAM und eine NVIDIA GeForce 1080Ti Grafikkarte mit 11 GB GDDR5X.

## 5.1 Vergleichsmodelle

In diesem Abschnitt sollen einige der existierenden Modelle detaillierter beschrieben werden, mit denen die Ergebnisse der neuronalen Netze nun verglichen werden. Diese Modelle wurden schon in Abschnitt 2.3 erwähnt, dort aber ohne die Berechnung zu erklären. Mit Ausnahme des *Average Acceleration* Modells stammen sie alle aus [Pfa18] und sowohl Definition als auch Notation wurden von dort übernommen. Dabei seien  $x$  die Achse entlang der Bewegungsrichtung des Förderbands und  $y$  die Achse orthogonal zur Bewegungsrichtung des Förderbands. Zeitdiskrete Messungen entlang der einzelnen Achsen werden als  $x_t$  beziehungsweise  $y_t$  dargestellt. Die daraus rekonstruierten zeitkontinuierlichen Positionsgleichungen werden als  $x(t)$  beziehungsweise  $y(t)$  bezeichnet. Sei  $t^{\text{Last}}$  der Zeitpunkt der Beobachtung des aktuellsten Features und  $x^{\text{Last}}$  und  $y^{\text{Last}}$  die dazugehörigen Positionen entlang der beiden Achsen. Sei  $x^{\text{PredTo}}$  die Position des Druckluftdüsenarrays entlang der  $x$ -Achse. Der Zeitpunkt, an dem ein Partikel das Druckluftdüsenarray passiert, wird als  $t^{\text{Pred}}$  bezeichnet. Sei  $y^{\text{Pred}} = y(t^{\text{Pred}})$  die Position entlang der  $y$ -Achse, an dem der Partikel

den Druckluftdüsenarray passiert. Die Zeit, die der Partikel noch benötigt um das Druckluftdüsenarray zu erreichen  $\Delta t = t^{\text{Pred}} - t^{\text{Last}}$  und die Position an der er es passiert  $y^{\text{Pred}}$  sind die Labels der einzelnen Feature-Label-Paare für das Separator-Netz.  $x(t^{\text{Last}} + 1)$  und  $y(t^{\text{Last}} + 1)$ , also jeweils einen diskreten Zeitschritt in die Zukunft, sind die Labels der Feature-Label-Paare für das NextStep-Netz. Die verschiedenen Modelle können nun ebenso wie die Ergebnisse der verschiedenen Netze bewertet werden, indem man die Abweichung zwischen dem Ergebnis in dem Modell und der Ground Truth in den Feature-Label-Paaren bestimmt.

Für Modelle, die unabhängig von der Beschleunigung der Teilchen sind, ist der Zustandsvektor als

$$\underline{x}(t) = \begin{bmatrix} x(t) \\ \dot{x}(t) \\ y(t) \\ \dot{y}(t) \end{bmatrix}$$

definiert. Für Modelle, die die Beschleunigung der Teilchen mit einbeziehen, ist der Zustandsvektor folgendermaßen definiert:

$$\underline{x}(t) = \begin{bmatrix} x(t) \\ \dot{x}(t) \\ \ddot{x}(t) \\ y(t) \\ \dot{y}(t) \\ \ddot{y}(t) \end{bmatrix} .$$

**Constant Velocity Modell** Das Constant Velocity (CV) Modell arbeitet unter der Annahme, dass sich Partikel, abgesehen von einem Rauschterm, mit einer konstanten Geschwindigkeit bewegen. Es kann mittels folgender Differenzialgleichung dargestellt werden.

$$\dot{\underline{x}}(t) = \mathbf{A}\underline{x}(t), \quad \mathbf{A} = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} .$$

Daraus folgen die Positionsgleichungen

$$x(t) = x^{\text{Last}} + (t - t^{\text{Last}})\dot{x}^{\text{Last}},$$

$$y(t) = y^{\text{Last}} + (t - t^{\text{Last}})\dot{y}^{\text{Last}}$$

entlang der einzelnen Achsen. Für das NextStep-Szenario ergibt sich die Prädiktionen mittels des CV Modells also aus

$$\begin{aligned} \mathbf{x}(t^{\text{Last}} + 1) &= \mathbf{x}^{\text{Last}} + \dot{\mathbf{x}}^{\text{Last}}, \\ \mathbf{y}(t^{\text{Last}} + 1) &= \mathbf{y}^{\text{Last}} + \dot{\mathbf{y}}^{\text{Last}}. \end{aligned} \quad (5.1)$$

Für das Separator-Szenario wird die Gleichung

$$\mathbf{x}^{\text{PredTo}} = \mathbf{x}^{\text{Last}} + (t - t^{\text{Last}})\dot{\mathbf{x}}^{\text{Last}}$$

nach  $t$  gelöst um  $t^{\text{Pred}}$  und damit  $\Delta t$  zu erhalten. Durch das Einsetzen von  $t^{\text{Pred}}$  in Gleichung (5.1) ergibt sich  $\mathbf{y}^{\text{Pred}}$ .

**Constant Acceleration Modell** Im Constant Acceleration (CA) Modell wird davon ausgegangen, dass das Teilchen mit einer konstanten Beschleunigung schneller wird. Es kann mittels folgender Differenzialgleichung dargestellt werden.

$$\dot{\underline{\mathbf{x}}}(t) = \mathbf{A}\underline{\mathbf{x}}(t), \quad \mathbf{A} = \begin{bmatrix} \mathbf{A}_x & \mathbf{0} \\ \mathbf{0} & \mathbf{A}_y \end{bmatrix}, \quad \mathbf{A}_x = \mathbf{A}_y = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}.$$

Analog zum Constant Velocity Modell können daraus die Positionsgleichungen

$$\mathbf{x}(t) = \mathbf{x}^{\text{Last}} + (t - t^{\text{Last}})\dot{\mathbf{x}}^{\text{Last}} + \frac{1}{2}(t - t^{\text{Last}})^2 \ddot{\mathbf{x}}^{\text{Last}}, \quad (5.2)$$

$$\mathbf{y}(t) = \mathbf{y}^{\text{Last}} + (t - t^{\text{Last}})\dot{\mathbf{y}}^{\text{Last}} + \frac{1}{2}(t - t^{\text{Last}})^2 \ddot{\mathbf{y}}^{\text{Last}} \quad (5.3)$$

abgeleitet werden. Nun wird wie beim Constant Velocity Modell vorgegangen. Im NextStep-Fall werden die Gleichungen (5.2) und (5.3) für  $t = t^{\text{Last}} + 1$  gelöst. Im Separator-Fall wird  $\Delta t = t^{\text{Pred}} - t^{\text{Last}}$  aus

$$\mathbf{x}^{\text{Pred}} = \mathbf{x}^{\text{Last}} + (t - t^{\text{Last}})\dot{\mathbf{x}}^{\text{Last}} + \frac{1}{2}(t - t^{\text{Last}})^2 \ddot{\mathbf{x}}^{\text{Last}},$$

errechnet und durch Einsetzen in Gleichung (5.3)  $\mathbf{y}^{\text{Pred}}$  bestimmt.

**Bias-Corrected Constant Velocity Modell** In [Pfa18] wurden weitere szenariospezifische Bewegungsmodelle beschrieben, die insbesondere die Qualität der zeitlichen Prädiktion für den Separator-Fall verbessern. Das erste von diesen Modellen, das hier zum Vergleich mit den Ergebnissen der neuronalen Netze betrachtet werden soll, ist eine Verbesserung des Constant Velocity Modells und wird als Bias-Corrected Constant Velocity (CVBC) Modell bezeichnet. Durch das Bestimmen des Bias bezüglich der Ankunftszeit der Partikel am Druckluftdüsenarray in den Trainingsdaten

und das Abziehen desselben von der Prädiktion der Testdaten kann die Qualität dieser Prädiktion verbessert werden. Dieser neue Wert kann nun für die Ortsprädiktion benutzt werden und diese tendenziell verbessern. Damit ergibt sich für die vorhergesagte Ankunftszeit

$$t^{\text{Pred,CVBC}} = t^{\text{Pred,CV}} - t^{\text{Bias}},$$

wobei  $t^{\text{Bias}}$  den Bias bezüglich der Ankunftszeit auf den Trainingsdaten bezeichnet. Analog zum unveränderten Constant Velocity Modell erhält man nun durch das Einsetzen von  $t^{\text{Pred,CVBC}}$  in (5.1) erneut  $y^{\text{Pred,CVBC}}$ . Die Verbesserung der prädizierten Zeit führt tendenziell ebenfalls zu einer Verbesserung des prädizierten Orts.

**Average Acceleration Modell** Das Average Acceleration (AA) Modell ist eine Erweiterung des CVBC-Modells. Anstatt die durchschnittliche Abweichung der prädizierten Zeit in den Trainingsdaten auf die prädizierte Zeit zu addieren, wird angenommen, dass diese Abweichung aus einer nicht betrachteten Beschleunigung resultiert. Diese Beschleunigung wird mutmaßlich vom Band verursacht werden und alle Partikel ortsunabhängig mehr oder weniger ähnlich betreffen. Deshalb wird die Beschleunigung des Partikels in allen Feature-Label-Paaren des Trainingssets bestimmt und von diesen der Median  $\ddot{x}^{\text{Median}}$  gewählt als eine einheitliche Beschleunigung, die zum CV Modell hinzugefügt wird. Es folgt die Positionsgleichung

$$\mathbf{x}(t) = \mathbf{x}^{\text{Last}} + (t - t^{\text{Last}}) \dot{\mathbf{x}}^{\text{Last}} + \frac{1}{2}(t - t^{\text{Last}})^2 \ddot{\mathbf{x}}^{\text{Median}},$$

die nach  $t$  für  $\mathbf{x}(t) = \mathbf{x}^{\text{PredTo}}$  gelöst wird.

**Identical Acceleration Modell** Das Identical Acceleration (IA) Modell ist ebenfalls eine Verbesserung des CVBC-Modells. Bei diesem werden die Korrekturterme, die als Beschleunigung auf die Positionsgleichungen addiert werden, nicht unabhängig von der letzten Position des Partikels bestimmt, sondern beziehen diese mit ein. Wie oben wird hierbei die Annahme getroffen, dass die zusätzliche Beschleunigung, die für die zeitliche Abweichung sorgt, für alle Partikel ungefähr gleich ist. Die Bestimmung dieser Korrekturterme ist jedoch unterschiedlich. Für die Feature-Label-Paare des Trainingssets hat man Zugang zu der Ground Truth, wann die Partikel das Druckluftdüsenarray passieren.

Dementsprechend wird für jedes Partikel  $i$  aus dem Trainingsset die Gleichung

$$\mathbf{x}^{\text{PredTo}} = \mathbf{x}^{\text{Last},i} + (t^{\text{GT},i} - t^{\text{Last},i}) \dot{\mathbf{x}}^{\text{Last},i} + \frac{1}{2}(t^{\text{GT},i} - t^{\text{Last},i})^2 \ddot{\mathbf{x}}^{\text{Optimal},i}$$

gelöst, um herauszufinden, mit welcher zusätzlichen Beschleunigung  $\ddot{x}^{\text{Optimal},i}$  es optimal die Zeit, die es noch braucht, vorhersagen würde. Nun sei  $\ddot{x}^{\text{Avg}}$  der Durchschnitt von allen  $\ddot{x}^{\text{Optimal},i}$ . Für die Partikel des Testsets werden die Zeit und der Ort des Passierens des Druckluftdüsenarrays nun basierend auf deren beobachteter Geschwindigkeiten  $\dot{x}^{\text{Last}}$  und der errechneten Beschleunigungen  $\ddot{x}^{\text{Avg}}$  berechnet. Die Zeitprädiktion  $t^{\text{Pred}}$  wird, bestimmt indem wir

$$x(t) = x^{\text{Last}} + (t - t^{\text{Last}}) \dot{x}^{\text{Last}} + \frac{1}{2}(t - t^{\text{Last}})^2 \ddot{x}^{\text{Avg}}$$

nach  $t$  lösen.

In [Pfa18] werden zusätzlich zu den hier aufgeführten Modellen noch zwei Modelle vorgestellt, die sich speziell mit der Prädiktion der Orthogonalbewegung beschäftigen. Im Rahmen dieser Arbeit wurden diese nicht berücksichtigt und sich stattdessen auf die Prädiktion des Zeitkomponente konzentriert.

## 5.2 Next Step

In dieser Sektion sollen die Ergebnisse der NextStep-Netze in verschiedenen Szenarien betrachtet werden. Der Vergleich zwischen den Ergebnissen der unterschiedlichen Modelle wird mittels sogenannter Boxplots visualisiert. Die fünf relevanten Charakteristiken, die in einem Boxplot dargestellt werden sind der Median, das untere und obere Quartil sowie zwei sogenannte „Antennen“ oder auch „Whisker“, die die Positionen der äußersten Datenpunkte innerhalb des 1.5-fachen Interquartilsabstands beschreiben. Die Position des Medians wird durch eine rote Linie verdeutlicht. Die namensgebende Box ist zwischen dem unteren und dem oberen Quartil aufgespannt. Für die Darstellung in dieser Arbeit wurde darauf verzichtet Ausreißer außerhalb der Antennen abzubilden. Als Evaluationskriterium für die NextStep-Netze wurde die Euklidische Distanz zwischen der Prädiktion des Modell und der Ground Truth gewählt. Der Gesamtfehler  $\varepsilon^{\text{Total}}$  ist also durch

$$\begin{aligned} x^{\text{Err}} &= x^{\text{Pred}} - x^{\text{GT}}, \\ y^{\text{Err}} &= y^{\text{Pred}} - y^{\text{GT}}, \\ \varepsilon^{\text{Total}} &= \sqrt{x^{\text{Err}}{}^2 + y^{\text{Err}}{}^2} \end{aligned}$$

definiert. Verglichen wird das NextStep-Netz mit einem Constant Velocity Modell und einen Constant Acceleration Modell, jeweils ohne Berücksichtigung von Rauschen.

Repräsentativ für ihre jeweiligen Szenariokategorien sind in Abbildung 5.1a die Boxplots für die selbst aufgenommenen Kugeln auf dem Förderband, und in Abbildung 5.1b die Boxplots für die mittels DEM simulierten Kugeln zu sehen. In beiden

Fällen sind die Ergebnisse des neuronalen Netzes besser als die der Vergleichsmodelle. Sowohl der Median als auch die Quartile sind für die Ergebnisse des neuronalen Netzes geringer. Die durchschnittliche Abweichung der Ergebnisse ist kleiner und weniger weit gestreut als die der beiden Vergleichsmodelle. Es ist auffällig, dass bei den simulierten Daten das CA-Modell besser als das CV-Modell ist, während es auf den Realdaten umgekehrt ist. Das könnte auf die höhere Bandgeschwindigkeit bei der Simulation zurückzuführen sein. In Abbildung 5.2 sieht man das Fehlerhistogramm, das zu Abbildung 5.1a gehört. Die Boxplots von den hier vorgestellten und allen restlichen Szenarien sind im Anhang A zu finden.

### 5.3 Separator

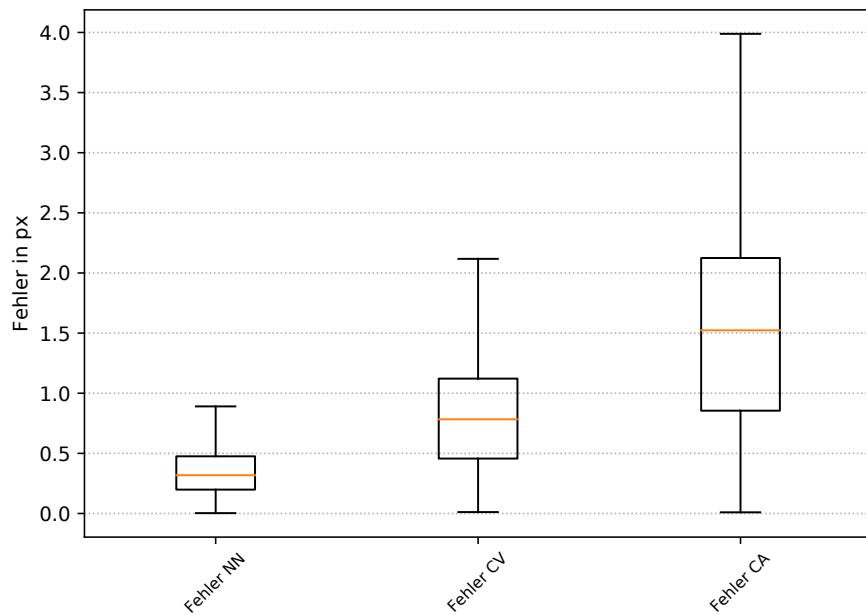
In diesem Abschnitt sollen nun die Ergebnisse der Separator-Netze in verschiedenen Szenarien betrachtet werden. Hier wird die zeitliche Abweichung vom prädizierten Zeitpunkt, an dem das Druckluftdüsenarray passiert wird, und die örtliche Abweichung des Schnittpunkts der Bahn des Partikels mit dem Druckluftdüsenarray separat betrachtet. Wie bei den NextStep-Netzen werden ein Constant Velocity- und ein Constant Acceleration Modell als Vergleichsmodelle benutzt. Zusätzlich werden noch mehr Vergleichsmodelle hinzugezogen. Das Bias-Corrected Constant Velocity Modell liefert sowohl eine Prädiktion für die Zeit als auch für den Ort. Die Average Acceleration und Identical Acceleration Modelle sind nur für die zeitliche Prädiktion ausgelegt und werden dementsprechend nur dort zum Vergleich herangezogen.

Die Evaluation wurde auf folgendem Szenario durchgeführt. Als Trainingsdaten wurden nur das jeweils letzte Feature-Label-Paar eines Tracks benutzt, bevor das entsprechende Partikel die Prädiktionsphase verlässt. Für die DEM-Datensätze wurde von  $x \approx 0.55$  m nach  $x = 0.70$  m prädiziert, also ca. 15 cm nach vorne. Da der gesamte Bildausschnitt der selbst aufgenommenen Daten weniger als 15 cm entlang der Bewegungsrichtung misst, musste diese Distanz reduziert werden. Die auf den selbst gesammelten Daten trainierten Netze prädizieren von  $y \approx 800$  px nach  $y = 1550$  px, also eine Distanz von ungefähr 750 px.

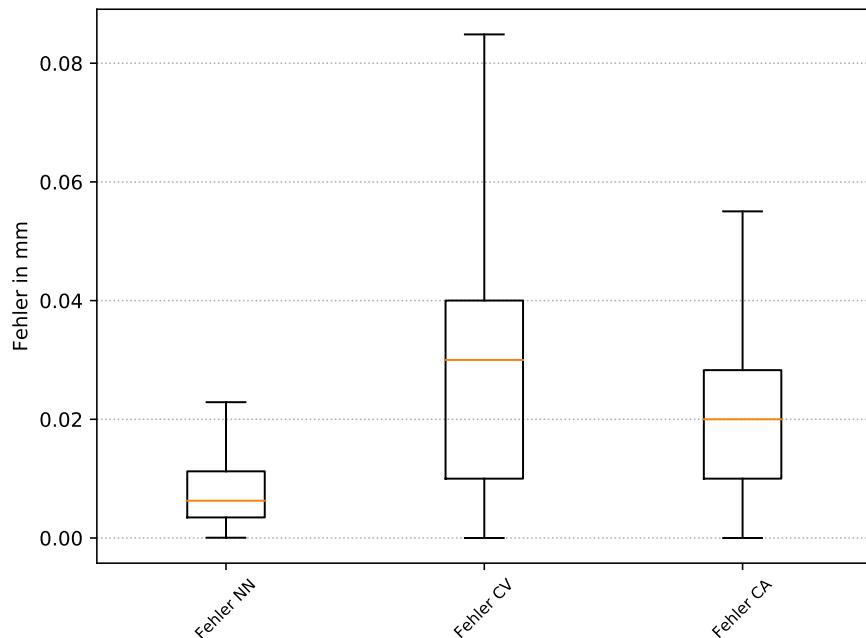
Die Ergebnisse für den Separator-Fall werden als

$$\begin{aligned} t^{\text{Err}} &= t^{\text{Pred}} - t^{\text{GT}}, \\ y^{\text{Err}} &= y^{\text{Pred}} - y^{\text{GT}} \end{aligned}$$

definiert. Im Gegensatz zu dem NextStep-Fall ist es nur bedingt sinnvoll diese Fehler zu einem Gesamtfehler zu kombinieren. Zusätzlich ist das Vorzeichen der Fehler für die einzelnen Partikel hier relevant. Für die zeitlichen Fehler bedeutet ein positiver

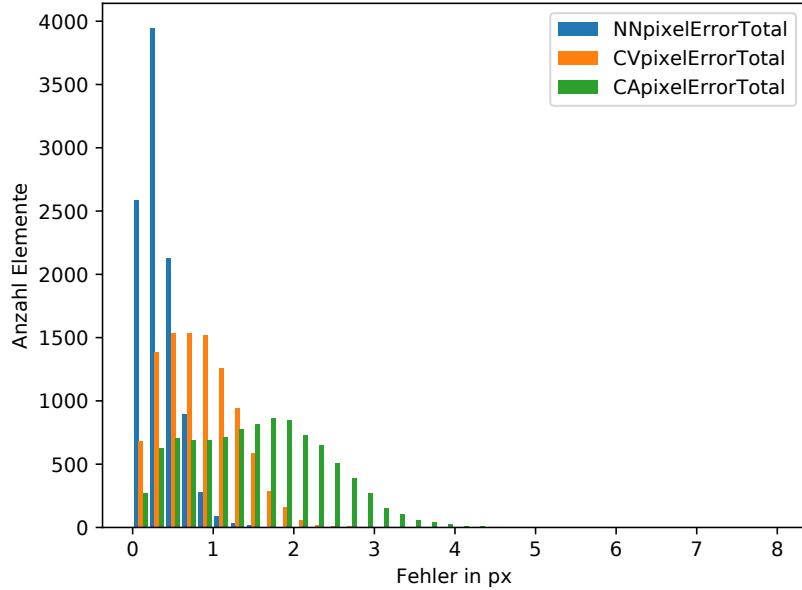


(a) Boxplots für die NextStep-Ergebnisse der selbst aufgenommenen Kugeln auf dem Förderband.



(b) Boxplots für die NextStep-Ergebnisse der Kugeln aus dem DEM-Datensatz.

**Abbildung 5.1:** Visualisierung der Ergebnisse für die realen und simulierten Kugeln mit NextStep-Netzen. Kleinere Werte sind besser.



**Abbildung 5.2:** Fehlerhistogramm für die NextStep-Ergebnisse der selbst aufgenommenen Kugeln auf dem Förderband.

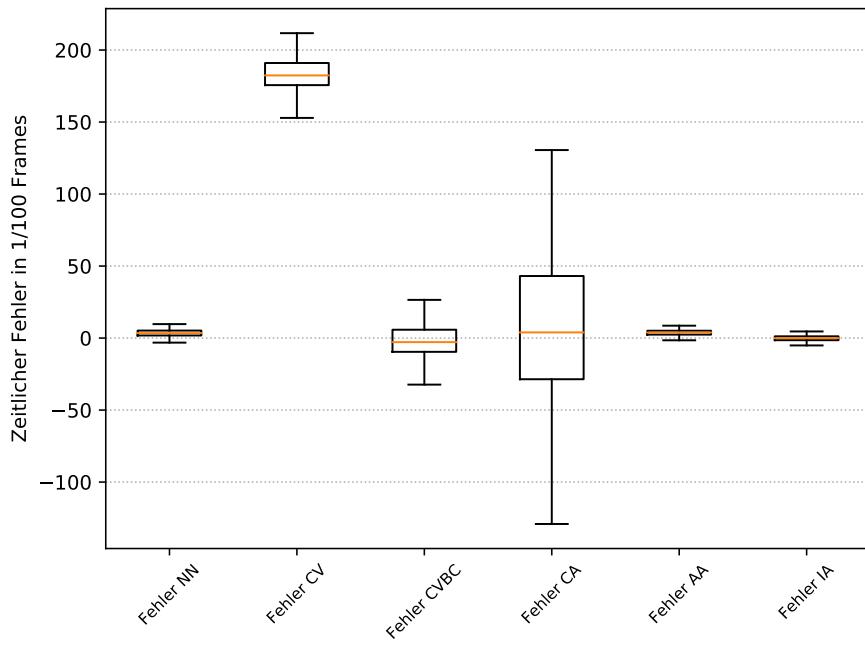
Wert, dass das Teilchen früher den Druckluftdüsenarray passiert hat als von dem Modell vorhergesagt.

Die Ergebnisse der neuronalen Netze für die Separator-Prädiktion sind auf allen Datensätzen besser als das CV-Modell, das CV-Modell und das CVBC-Modell. Auf den beiden simulierten Datensätzen sind die Ergebnisse marginal schlechter als das IA-Modell, aber deutlich besser als die der grundlegenden Modelle und des CVBC-Modells. Dies ist in Abbildung 5.3 exemplarisch durch die Boxplots der simulierten Plättchen dargestellt. Zunächst soll der zeitliche Fehler betrachtet werden. Obwohl der Median des Prädiktionsfehlers des neuronalen Netzes einen kleinen, positiven Bias hat und das untere Quartil größer als 0 ist, sind die Ergebnisse deutlich besser als die des CVBC-Modells. Für die Ergebnisse des neuronalen Netzes liegt der Bereich zwischen den Quartilen komplett innerhalb des entsprechenden Bereichs von dem CVBC-Modell. Das CV- und das CA-Modell sind beide noch einmal bedeutend schlechter als das CVBC-Modell. Das CV-Modell ist bezüglich seiner Verteilung erwartungsgemäß identisch zum CVBC-Modell, hat aber einen Bias von beinahe zwei ganzen Zeitschritten. Im Vergleich dazu ist das CA-Modell zwar etwa genauso biasfrei wie das neuronale Netz, hat aber die mit Abstand größte Standardabweichung von allen Modellen. Der Interquartilsabstand des CA-Modells ist größer als der Abstand zwischen den Whiskers der restlichen Modelle. Das beste Modell in diesem Szenario ist das IA-Modell. Es ist beinahe komplett biasfrei und

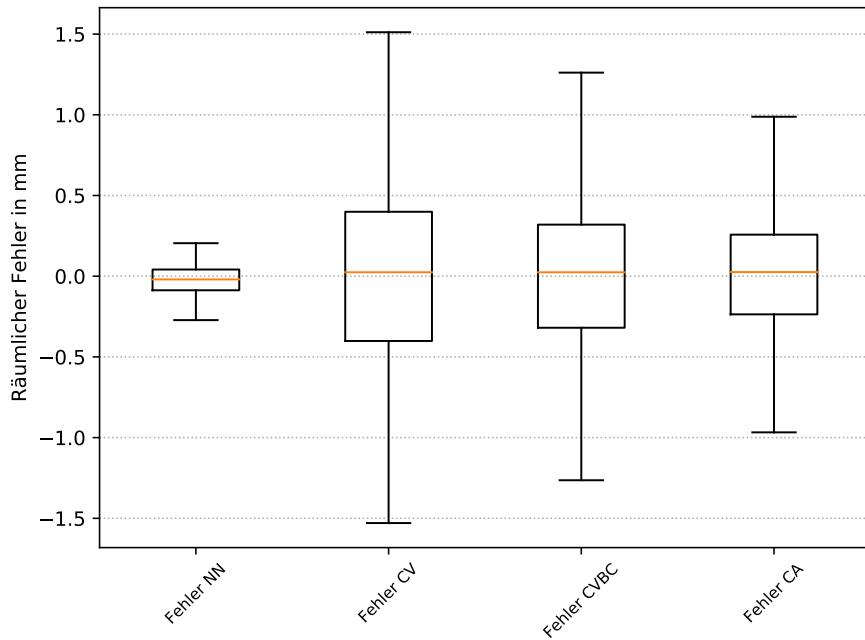
hat die geringste Standardabweichung von allen Modellen. Bei der Betrachtung des örtlichen Fehlers ist das CA-Modell tatsächlich besser als das CV- und das CVBC-Modell, aber dennoch deutlich schlechter als das neuronale Netz. Alle diese Modelle sind beinahe biasfrei, aber der Interquartilsabstands der Ausgabe des neuronalen Netzes ist deutlich geringer.

Im Vergleich dazu sind die Unterschiede zwischen den verschiedenen Modellen auf den selbst aufgenommenen Daten deutlich kleiner. Das Constant Velocity Modell schneidet oft beinahe so gut, und bei den Weizenkörnern sogar besser, ab als das Identical Acceleration Modell. Auf den selbst gesammelten Daten schneidet von den bestehenden Modellen das Bias-Corrected Constant Velocity Modell am besten ab. Die neuronalen Netze sind jedoch noch einmal besser. Wenn man die Boxplots der zeitlichen Fehler der verschiedenen Modelle auf dem Weizenkörner-Datensatz der selbst aufgenommenen Daten, dargestellt in Abbildung 5.4a, im Detail betrachtet gibt es einige Auffälligkeiten. Im Gegensatz zu dem Szenario, das in Abbildung 5.3a dargestellt ist, zeigt der zeitliche Fehler des CV-Modells nur einen geringen Bias, der sogar eher negativ ist. Während es bei den simulierten Plättchen so ist, dass der Interquartilsabstand des CV-Modells um Faktoren größer ist als der des IA-Modells, ist er hier fast gleich groß. Tatsächlich unterscheiden sich die Ergebnisse der CV-, CVBC-, AA- und IA-Modelle fast nur in ihrem Bias. Dem gegenüber stehen die Ergebnisse des neuronalen Netzes, die fast komplett biasfrei sind und einen merklich kleineren Interquartilsabstand haben als jedes der bestehenden Modelle. Ähnlich ist es beim örtlichen Fehler, der in Abbildung 5.4b dargestellt ist. Die Ergebnisse des neuronalen Netzes einen kleinen Bias haben, der Bereich zwischen ihrem oberen und unteren Quartil wird jedoch immer noch komplett überdeckt von der Box des CVBC-Modells, das das Beste der Vergleichsmodelle ist.

Die Qualität der Resultate der bestehenden Modelle hängt höchstwahrscheinlich mit der niedrigeren Bandgeschwindigkeit und dem kürzeren Prädiktionsabstand zusammen. Auch könnten die unterschiedlichen Verfahren unterschiedlich anfällig gegen das Messrauschen sein, das auf den simulierten Daten nicht existiert. Für die bestehenden Modelle gilt, dass eine relative Verbesserung der zeitlichen Prädiktion zu einer Verbesserung der örtlichen Prädiktion führt, da die zeitliche Prädiktion benutzt wird, um die örtliche zu bestimmen. Das ist besonders gut in Abbildung 5.3 zu erkennen. Die Verbesserung der zeitlichen Prädiktion zwischen dem CV- und dem CVBC-Modell, zu sehen in Abbildung 5.3a, sorgt auch direkt für eine Verbesserung der örtlichen Prädiktion, zu sehen in Abbildung 5.3b. Für die Ausgabe der neuronalen Netze gilt das jedoch nicht. Hier werden beide Ausgaben gemeinsam bestimmt. Wie für die NextStep-Netze sind die Boxplots aller Szenarien im Anhang A zu finden.

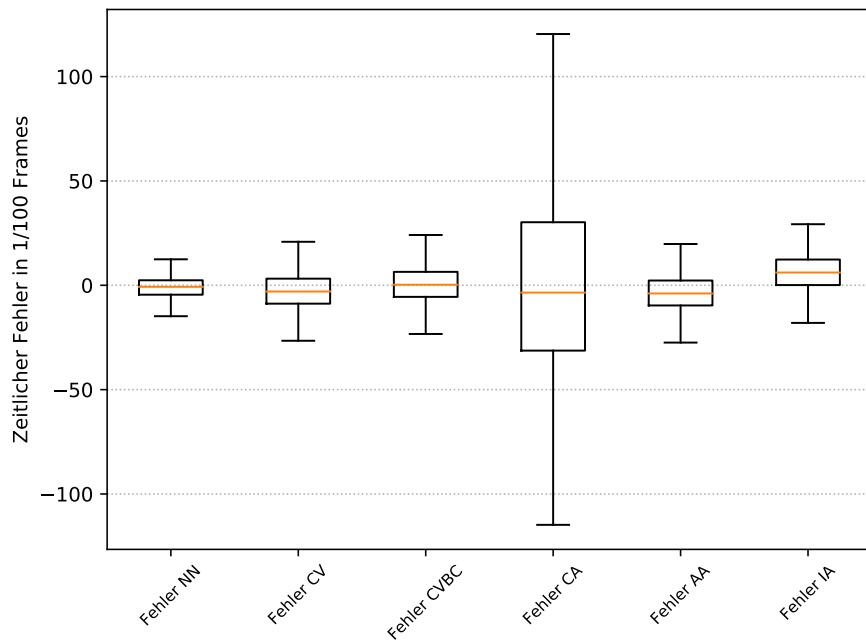


(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse der Plättchen aus dem DEM-Datensatz.

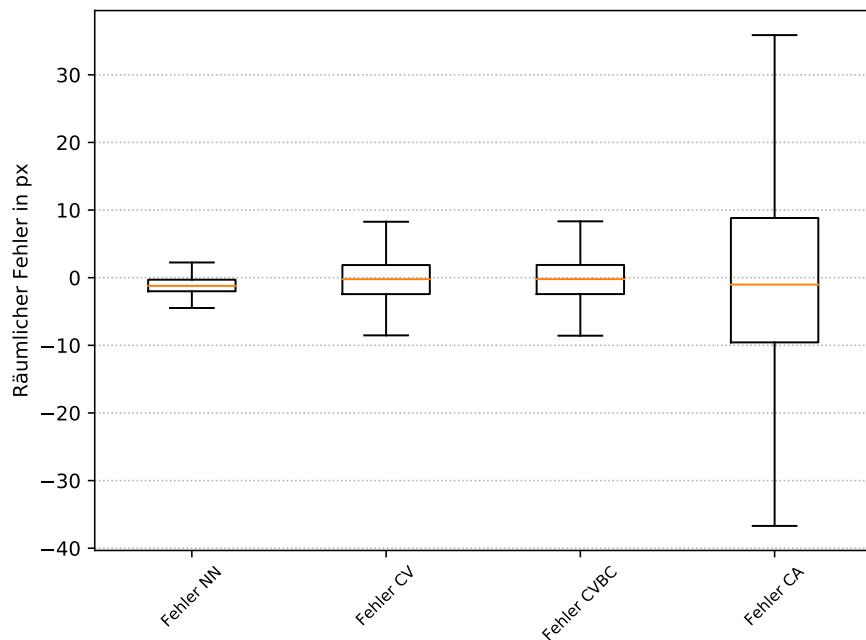


(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse der Plättchen aus dem DEM-Datensatz.

**Abbildung 5.3:** Visualisierung der Ergebnisse für die Plättchen aus der DEM-Simulation. Ein betragsmäßig kleinerer Median und eine möglichst kleine Streuung sind besser.



(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse des Weizenkörnern-Datensatz von den selbst gesammelten Daten.



(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse des Weizenkörnern-Datensatz von den selbst gesammelten Daten.

**Abbildung 5.4:** Visualisierung der Ergebnisse für den Weizenkörnern-Datensatz von den selbst gesammelten Daten. Ein betragsmäßig kleinerer Median und möglichst kleine Streuung sind besser.

## 5.4 Zusammenfassung und Diskussion

Die Tatsache, dass die Separator-Netze auf den DEM-Datensätzen, im Gegensatz zu allen anderen Szenarien, hinter dem aktuellen Stand der Technik zurückbleiben könnte darauf zurückzuführen sein, dass dort verhältnismäßig wenig Trainingsdaten zur Verfügung standen. Wie bereits in Kapitel 3 erwähnt, haben DEM-Datensätze im Vergleich zu den selbst aufgenommenen Daten weniger, aber dafür deutlich längere Tracks. Für die NextStep-Netze sorgt die größere Länge dazu, dass sogar mehr Feature-Label-Paare aus den DEM-Daten extrahiert werden können als aus den selbst aufgenommenen. Für die Separator Netze ist die Länge der Tracks jedoch unerheblich. Aus einem Track entsteht nur ein einzelnes Feature-Label-Paar. Es konnten mit den aufgenommenen Daten und der verwendeten Datenaugmentierung Ergebnisse erzielt werden, die an den aktuellen Stand der Technik herankommen. Um diesen zu übertreffen scheint es so, als ob mehr Trainingsdaten benötigt werden.

In der Zukunft wäre es wünschenswert, ein präziseres Hyperparameter-Tuning für mehr Szenarien durchzuführen. Wie in Abschnitt 4.3 beschrieben, wurden nur zwei Hyperparameter-Konfigurationen optimiert, was jeweils auf dem DEM-Kugel-Datensatz durchgeführt wurde. Diese Konfigurationen, eine für NextStep-Netze und eine für Separator-Netze, wurden dann für alle verschiedenen Szenarien benutzt. Auch wenn es ein beträchtlicher Zeitaufwand wäre, hätte individuelles Hyperparameter-Tuning für die einzelnen Schüttgutsorten wahrscheinlich einen positiven Effekt auf die Güte der Ergebnisse. Insbesondere ist es so, dass das Ergebnis für die Separator-Netze nicht gut auf die Rutschenkonfiguration des *TableSort*-Systems anwendbar war. Die Partikel bewegen sich in dieser Konfiguration deutlich schneller als auf dem Förderband, weshalb weniger Beobachtungen pro Track im Sichtbereich der Kamera gemacht werden. Eine FeatureSize von 7, wie von der Hyperparameter-Konfiguration für Separator-Netze vorgesehen, ist bei einer durchschnittlichen Tracklänge von 10 nicht sinnvoll.

Es konnte beobachtet werden, dass bei mehrmaligem Trainieren eines Netzes mit identischen Hyperparametern und Daten unterschiedliche Ergebnisse mit einem ähnlichen MSE insgesamt aber einer Verschiebung zwischen dem Mittelwert und der Standardabweichung an dessen Ende standen. Für Separator-Netze kam es sogar zu Verschiebungen zwischen der örtlichen und der zeitlichen Prädiktion. Das Fehlermaß, nach der die neuronalen Netze optimiert worden sind, ist der MSE, wonach zwei Ergebnisse mit identischem MSE gleichwertig sind, egal wie dieser zustande kommt. Dies ist auf verschiedene stochastische Vorgänge während dem Training zurückzuführen, wie die Initialisierung der Gewichte zwischen den Neuronen und die Reihenfolge beziehungsweise das Batching der Trainingsbeispiele. Der Einsatz einer

#### 5.4. Zusammenfassung und Diskussion

anderen Fehlerfunktion, zum Beispiel einer, die tatsächlich den Anteil der korrekt separierten Teilchen bewertet, könnte dieses Problem beheben. Für die Zukunft könnte im Separator-Fall das Auftrennen der zeitlichen und der örtlichen Prädiktion in unterschiedliche Netze sinnvoll sein.



## KAPITEL 6

# Fazit und Ausblick

Im Rahmen dieser Arbeit wurde betrachtet, ob neuronale Netze ein Werkzeug sind, das für die Bewegungsprädiktion von Schüttgutpartikeln eingesetzt werden kann. Dazu wurden zunächst beinahe 250 000 Bilder von verschiedenen Schüttgütern auf dem *TableSort*-Schüttgutsortierer aufgenommen und eine Pipeline entwickelt, mit der die relevanten Features aus solchen Bildern extrahiert werden können. Zusätzlich wurde eine einfache Form der Datenaugmentierung implementiert, die die Menge an verfügbaren Trainingsdaten für die jeweiligen Datensets beinahe verdoppelt. Es wurde mit Hilfe des TensorFlow Frameworks eine Implementierung erarbeitet, mit der verschiedene neuronale Netze trainiert werden können. Mit dieser Implementierung wurden mehrere Netze auf verschiedenen Datensets trainiert – den selbst aufgenommenen und bereits existierenden, mittels DEM simulierten – und deren Ergebnisse evaluiert. Es wurde festgestellt, dass die Bewegungsprädiktion von Schüttgutpartikeln eine Aufgabe ist, für die neuronale Netze geeignet sind. Es konnte gezeigt werden, dass sowohl NextStep-, als auch Separator-Netze gut in der Lage sind, die an sie gestellten Probleme zu lösen. In jedem Szenario konnten Ergebnisse erzielt werden, die besser als die der zwei grundlegenden Bewegungsmodelle und vergleichbar mit dem aktuellen Stand der Technik waren. Insbesondere auf den Datensätzen, die auf realen Aufnahmen basieren, wurden die Ergebnisse des aktuellen Stands der Technik übertroffen.

In dieser Arbeit wurde nur ein Ansatz für den Einsatz von neuronalen Netzen für die Bewegungsprädiktion von Schüttgutpartikeln erprobt. Obwohl positive Ergebnisse erzielt wurden, gibt es noch viele weitere vielversprechende Ansätze, die es wert sind, betrachtet zu werden. Naheliegende Ideen wären zum Beispiel alternative Modellierungen, wie die Verwendung relativer Positionen als Eingabe statt absoluter, oder zusätzliche Features, die zu den existierenden Objektmittelpunkten hinzugekommen. Beispielsweise ein zusätzliches Feature, das die Orientierung des Partikels beschreibt, würde speziell bei den Schüttgutsorten Zylinder und Weizenkörner Sinn ergeben. Auch ist denkbar, dass der Einsatz anderer Netzwerkarchitekturen für Verbesserungen

sorgen könnte. Rekurrente neuronale Netze sind besonders gut dafür geeignet, Daten, bei denen die zeitliche Abfolge wichtig ist, sequenziell zu verarbeiten.

Maschinelles Lernen allgemein und neuronale Netze im Besonderen sind ein Feld, auf dem momentan sehr schnell große Fortschritte gemacht werden, die in naher Zukunft vielleicht ganz neue Möglichkeiten eröffnen werden. Heutige Möglichkeiten sind auch noch nicht ausgereizt. Ein Aspekt, in dem neuronale Netze schon jetzt beindruckende Ergebnisse liefern, ist das Extrahieren von Informationen direkt aus Bildern. Es gibt bereits heute Multi-Object-Tracking Verfahren, die sehr gute Ergebnisse erzielen. Beispiele hierfür sind [MRD+16], [SBCH17] und [NZH+17]. Deshalb liegt es nahe, dass es möglich sein sollte, auf den Bildern direkt Ende-zu-Ende zu trainieren. Das könnte dabei helfen Ungenauigkeiten und Fehler, die während der in Abschnitt 3.2 beschriebenen Datenpipeline entstehen, zu vermeiden.

Sowohl im aktuellen Stand der Technik als auch bei den im Rahmen dieser Arbeit trainierten Netzen werden alle Schüttgutpartikel individuell betrachtet. Dies führt dazu, dass Kollisionen zwischen Partikeln, die diese von ihrer Bahn ablenken höchstens detektiert, aber nicht sinnvoll in die Modelle miteinbezogen werden können. Ein Ansatz, der mehrere Partikel simultan betrachtet, könnte insbesondere für Schüttgüter mit einer starken Querbewegung zu einer Verbesserung der Sortierqualität führen.

# Literatur

- [Sch09] D. Schulze, *Pulver und Schüttgüter: Fließeigenschaften und Handhabung*, 2., bearb. Aufl, Ser. Verfahrenstechnik. Berlin: Springer, 2009, 520 S., OCLC: 304395912, ISBN: 978-3-540-88449-1 978-3-540-88448-4.
- [UC18] United Nations Conference on Trade and Development und CNUCED, „Review of Maritime Transport 2018“, 2018, OCLC: 7898712265, ISSN: 0566-7682.
- [Dur12] J. Duran, *Sands, Powders, and Grains: An Introduction to the Physics of Granular Materials*. Springer Science & Business Media, 2012.
- [Pfa18] F. Pfaff, „Multitarget Tracking Using Orientation Estimation for Optical Belt Sorting“, Verteidigt am 13.11.2018, Dissertation, Karlsruher Institut für Technologie, Karlsruhe, 2018.
- [GBC16] I. Goodfellow, Y. Bengio und A. Courville, *Deep Learning*. MIT Press, 2016, <http://www.deeplearningbook.org>.
- [Mur12] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*. The MIT Press, 2012, ISBN: 0-262-01802-0 978-0-262-01802-9.
- [Nie15] M. A. Nielsen, *Neural Networks and Deep Learning*. Determination press USA, 2015, Bd. 25.
- [MP43] W. S. McCulloch und W. Pitts, „A Logical Calculus of the Ideas Immanent in Nervous Activity“, *The Bulletin of Mathematical Biophysics*, Jg. 5, Nr. 4, S. 115–133, 1943.
- [Ros58] F. Rosenblatt, „The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain.“, *Psychological Review*, Jg. 65, Nr. 6, S. 386, 1958.
- [WAZ11] Wikimedia Commons, Alisneaky und Zirguezi, „Kernel Machines Are Used to Compute Non-Linearly Separable Functions into a Higher Dimension Linearly Separable Function.“, 17. Apr. 2011. Adresse: [https://commons.wikimedia.org/wiki/File:Kernel\\_Machine.svg](https://commons.wikimedia.org/wiki/File:Kernel_Machine.svg) (besucht am 12.12.2018).

- [KSH12] A. Krizhevsky, I. Sutskever und G. E. Hinton, „ImageNet Classification with Deep Convolutional Neural Networks“, in *Advances in Neural Information Processing Systems 25*, F. Pereira, C. J. C. Burges, L. Bottou und K. Q. Weinberger, Hrsg., Curran Associates, Inc., 2012, S. 1097–1105. Adresse: <http://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf>.
- [SHK+14] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever und R. Salakhutdinov, „Dropout: A Simple Way to Prevent Neural Networks from Overfitting“, *Journal of Machine Learning Research*, Jg. 15, S. 1929–1958, 2014. Adresse: <http://jmlr.org/papers/v15/srivastava14a.html>.
- [Dol15] F. Doll, „Konzeption, Planung, Konstruktion Und Integration Eines Miniaturisierten, Modularen Schüttgutsortierers“, KIT, Aug. 2015.
- [Fra17] Fraunhofer IOSB, *TableSort Schüttgutsortierer*, 19. Mai 2017.
- [PKP+17] F. Pfaff, G. Kurz, C. Pieper, G. Maier, B. Noack, H. Kruggel-Emden, R. Gruna, U. D. Hanebeck, S. Wirtz, V. Scherer, T. Langle und J. Beyerer, „Improving Multitarget Tracking Using Orientation Estimates for Sorting Bulk Materials“, IEEE, Nov. 2017, S. 553–558, ISBN: 978-1-5090-6064-1.
- [All14] Allied Vision Technologies GmbH, *User Manual for Bonito CL-400 200 Fps High Speed Camera*. Nov. 2014, Rev. I.
- [WC06] Wikimedia Commons und Cburnett, „A Bayer Pattern on a Sensor in Isometric Perspective/Projection“, 26. Dez. 2006. Adresse: [https://commons.wikimedia.org/wiki/File:Bayer\\_pattern\\_on\\_sensor.svg](https://commons.wikimedia.org/wiki/File:Bayer_pattern_on_sensor.svg) (besucht am 27.11.2018).
- [PKEW+16] C. Pieper, H. Kruggel-Emden, S. Wirtz, V. Scherer, F. Pfaff, B. Noack, U. D. Hanebeck, G. Maier, R. Gruna, T. Längle und J. Beyerer, „Numerical Investigation of Optical Sorting Using the Discrete Element Method“, in *Proceedings of the 7th International Conference on Discrete Element Methods (DEM7)*, Dalian, China, Aug. 2016.
- [PPM+17] C. Pieper, F. Pfaff, G. Maier, H. Kruggel-Emden, S. Wirtz, B. Noack, R. Gruna, V. Scherer, U. D. Hanebeck, T. Längle und others, „Numerical Modelling of an Optical Belt Sorter Using a DEM–CFD Approach Coupled with Particle Tracking and Comparison with Experiments“, 2017.

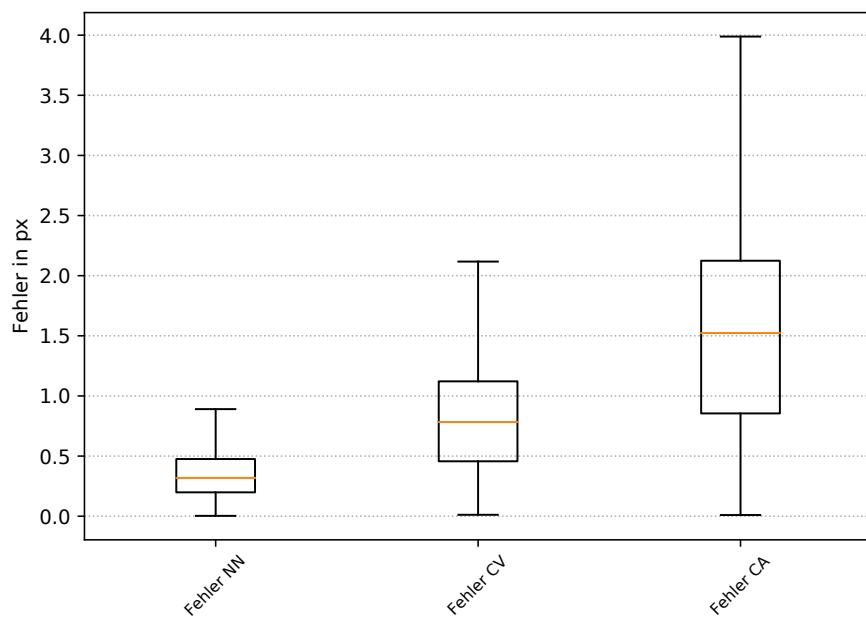
- [MRD+16] A. Milan, S. H. Rezatofighi, A. R. Dick, K. Schindler und I. D. Reid, „Online Multi-Target Tracking Using Recurrent Neural Networks“, *CoRR*, Jg. abs/1604.03635, 2016. arXiv: 1604 . 03635. Adresse: <http://arxiv.org/abs/1604.03635>.
- [SBCH17] J. Son, M. Baek, M. Cho und B. Han, „Multi-Object Tracking with Quadruplet Convolutional Neural Networks“, in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017, S. 5620–5629.
- [NZH+17] G. Ning, Z. Zhang, C. Huang, X. Ren, H. Wang, C. Cai und Z. He, „Spatially Supervised Recurrent Convolutional Neural Networks for Visual Object Tracking“, in *Circuits and Systems (ISCAS), 2017 IEEE International Symposium On*, IEEE, 2017.



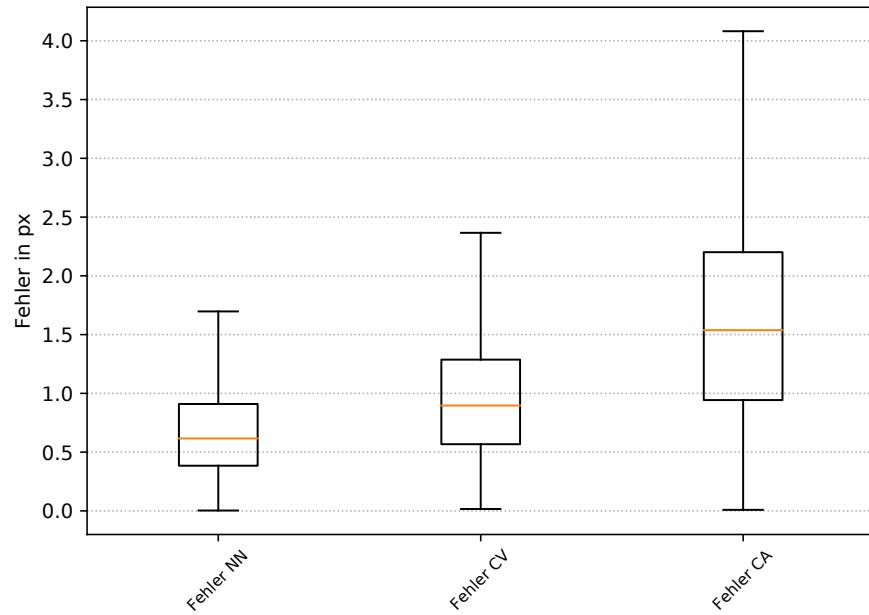
## ANHANG A

# Anhang

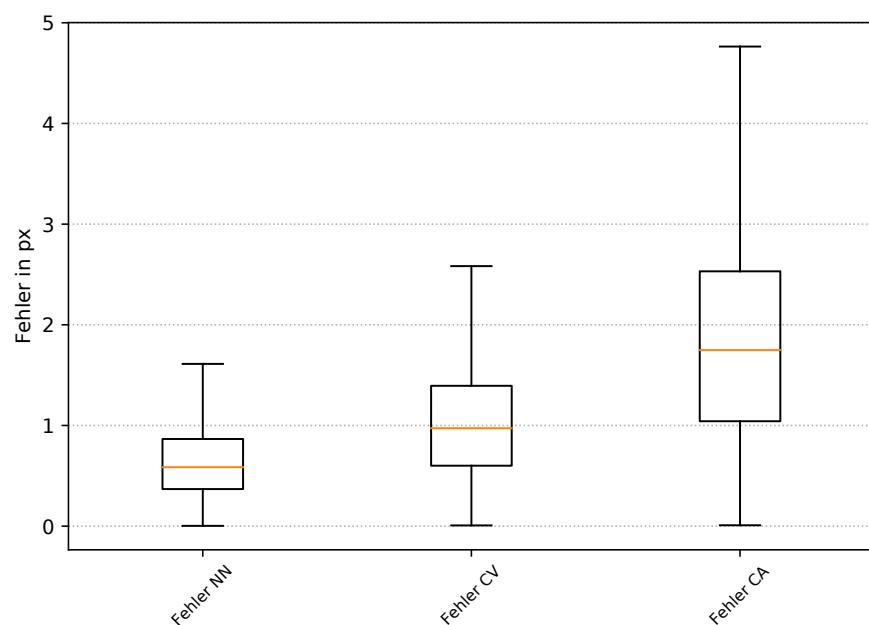
Im Anhang sind die Ergebnisse für die Szenarien zu finden, die nicht in Kapitel 5 betrachtet wurden.



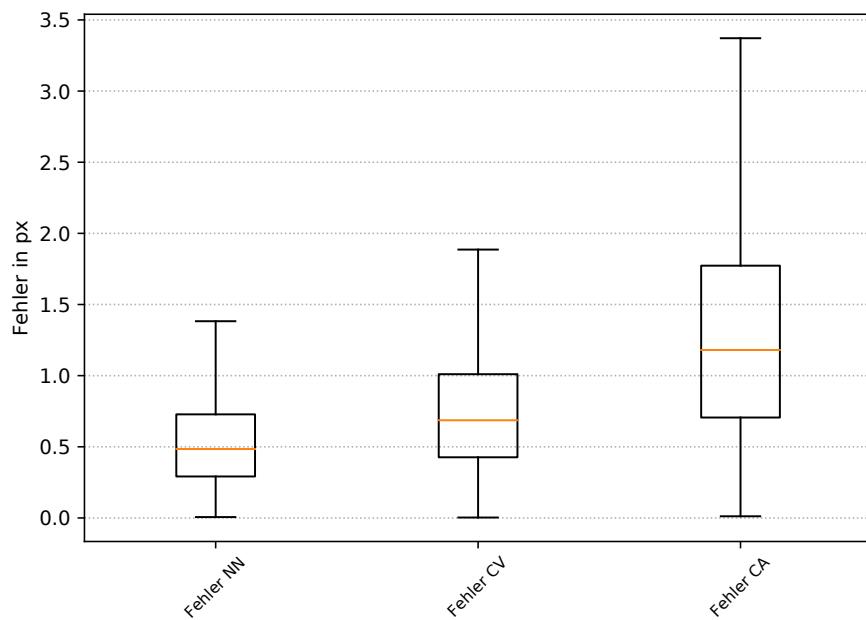
**Abbildung A.1:** Boxplots für die NextStep-Ergebnisse Kugeln auf dem Förderband aus dem selbst aufgenommenen Datensatz.



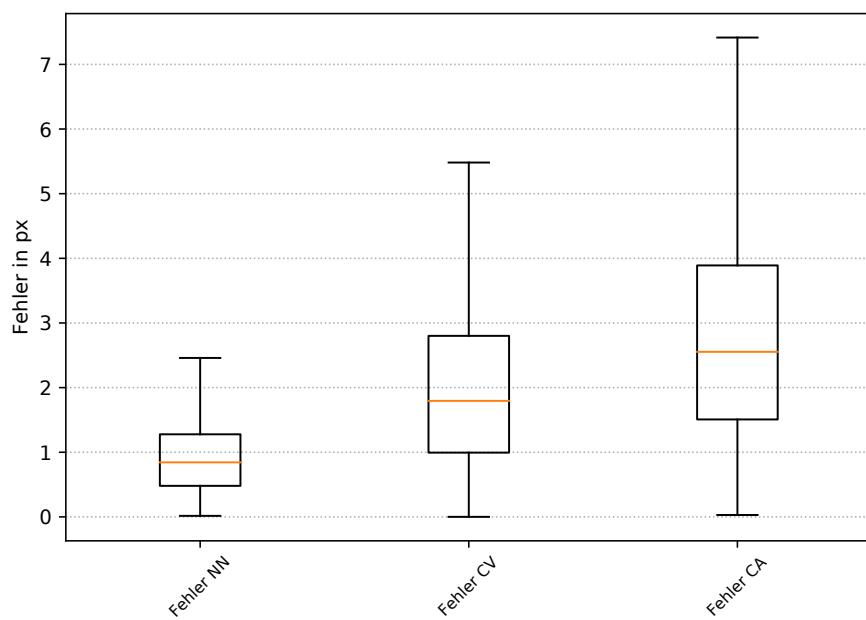
**Abbildung A.2:** Boxplots für die NextStep-Ergebnisse der Pfefferkörner auf dem Förderband aus dem selbst aufgenommenen Datensatz.



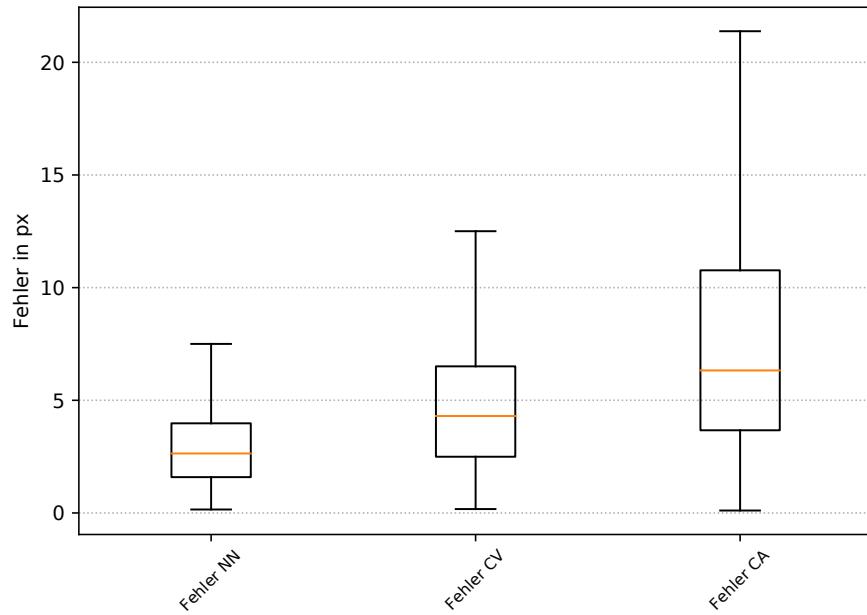
**Abbildung A.3:** Boxplots für die NextStep-Ergebnisse der Zylinder auf dem Förderband aus dem selbst aufgenommenen Datensatz.



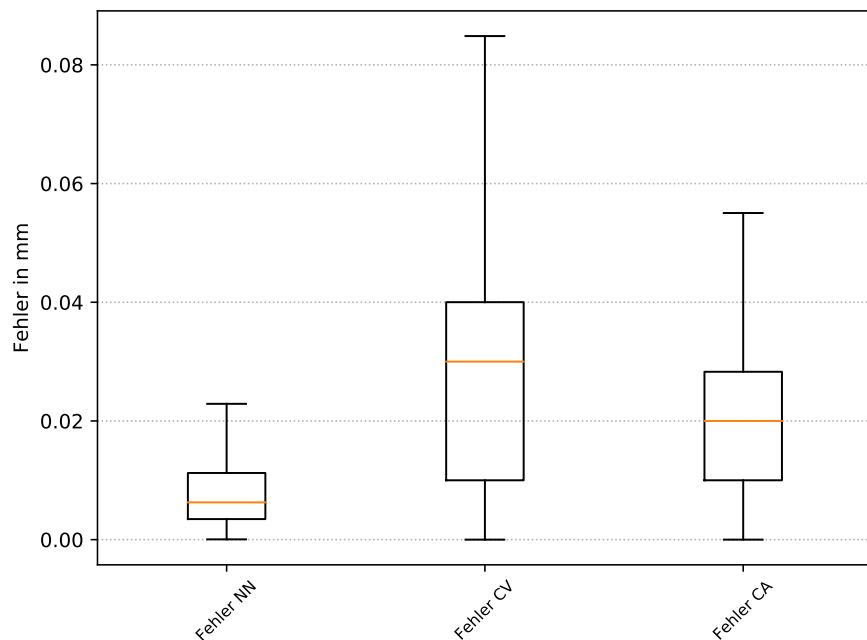
**Abbildung A.4:** Boxplots für die NextStep-Ergebnisse der Zylinder auf dem Förderband aus dem selbst aufgenommenen Datensatz.



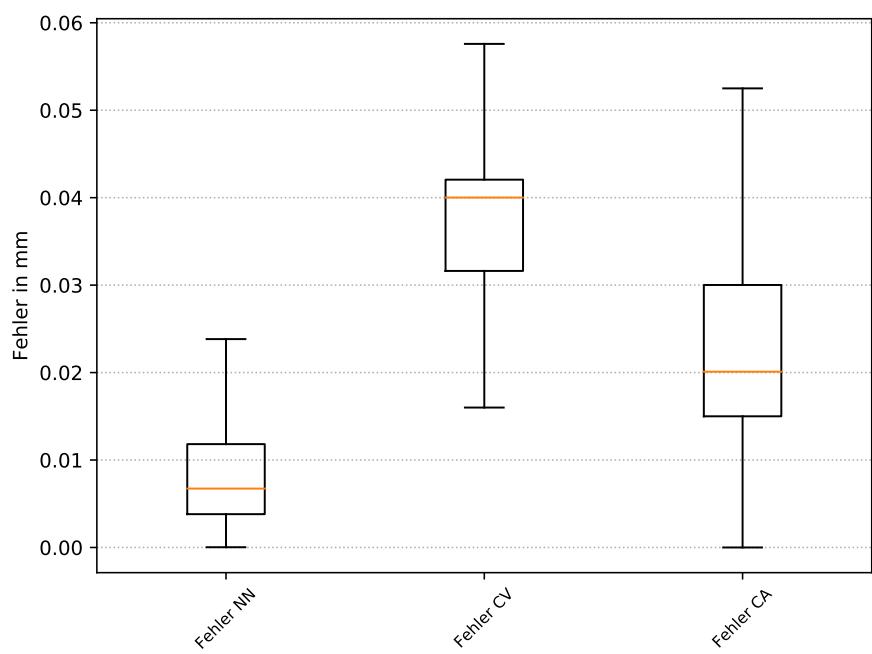
**Abbildung A.5:** Boxplots für die NextStep-Ergebnisse der Kugeln auf der Rutsche aus dem selbst aufgenommenen Datensatz.



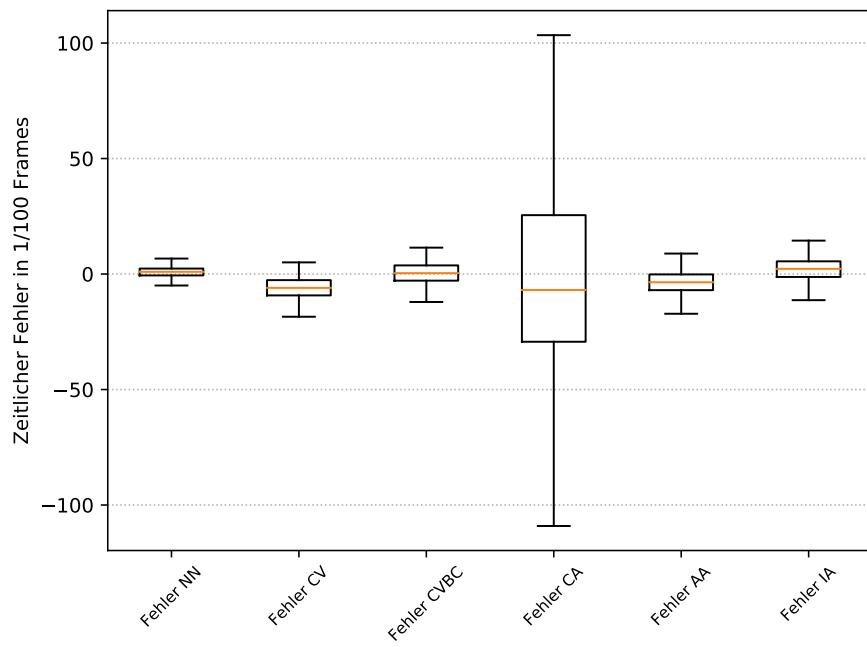
**Abbildung A.6:** Boxplots für die NextStep-Ergebnisse der Pfefferkörner auf der Rutsche aus dem selbst aufgenommenen Datensatz.



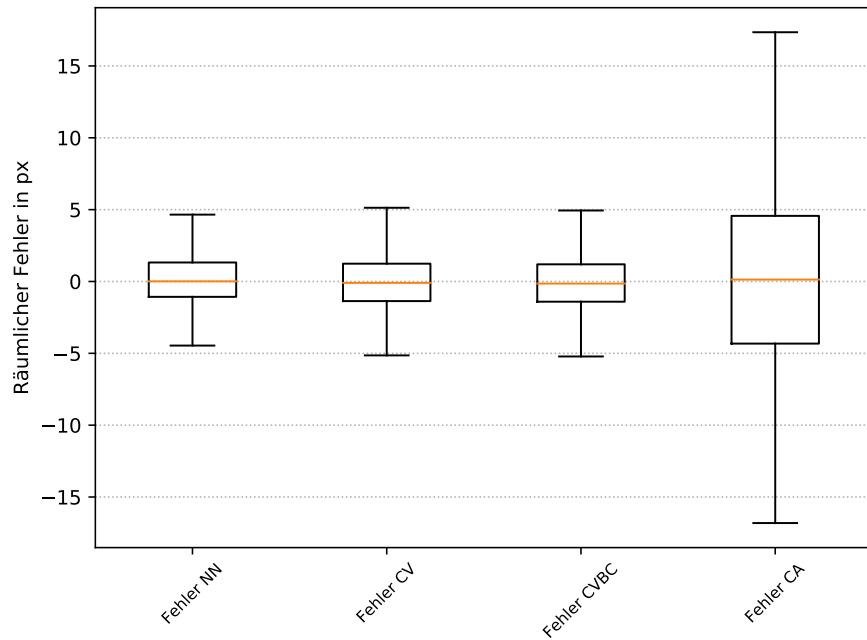
**Abbildung A.7:** Boxplots für die NextStep-Ergebnisse der Kugeln auf dem Förderband aus dem DEM-Datensatz.



**Abbildung A.8:** Boxplots für die NextStep-Ergebnisse der Plättchen auf dem Förderband aus dem DEM-Datensatz.

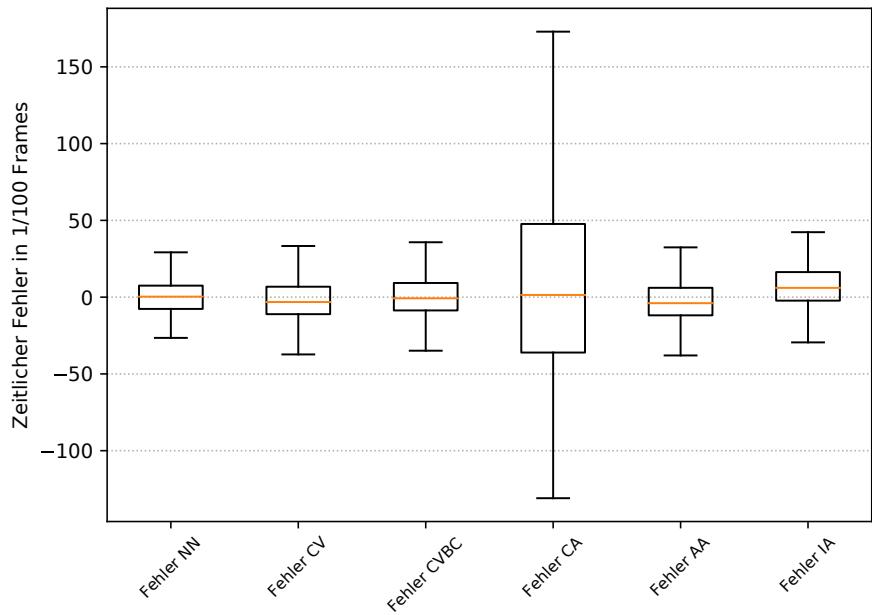


(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse der Kugeln aus dem selbst aufgenommenen Datensatz.

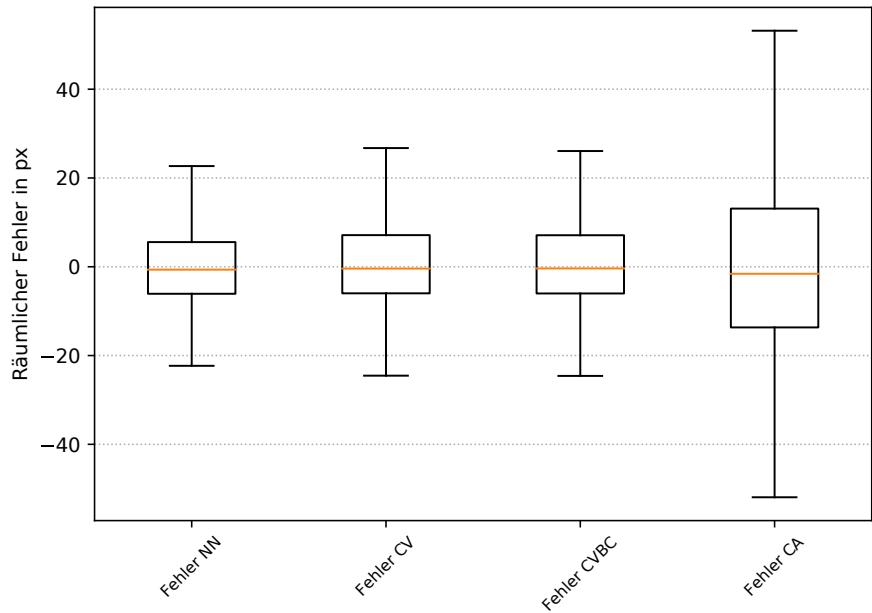


(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse der Kugeln aus dem selbst aufgenommenen Datensatz.

**Abbildung A.9:** Visualisierung der Ergebnisse für die Kugeln aus dem selbst aufgenommenen Datensatz.

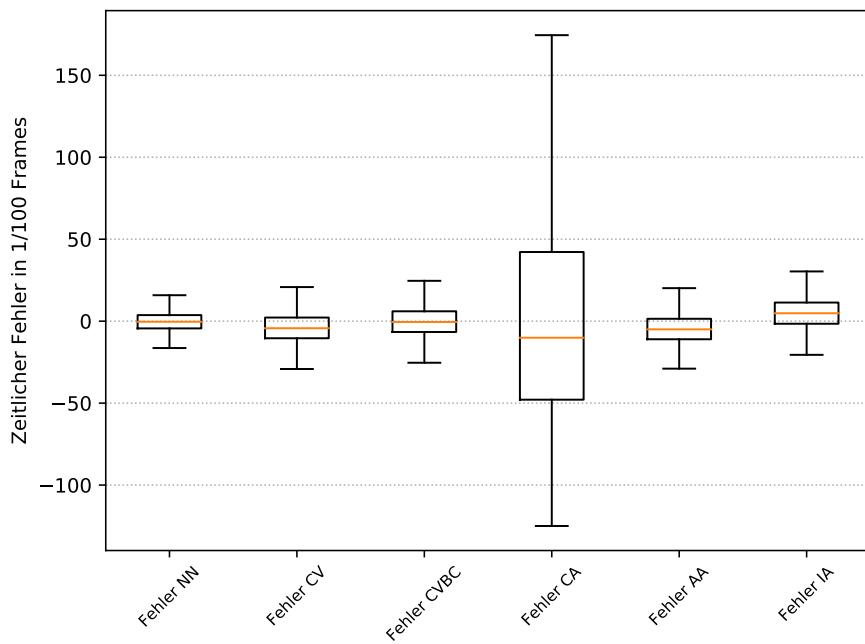


(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse der Pfefferkörner aus dem selbst aufgenommenen Datensatz.

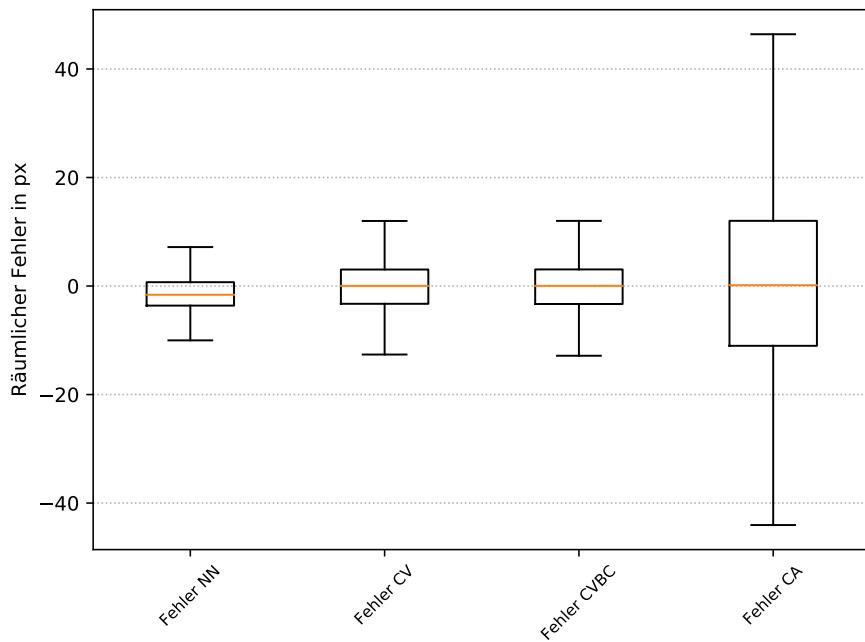


(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse der Pfefferkörner aus dem selbst aufgenommenen Datensatz.

**Abbildung A.10:** Visualisierung der Ergebnisse für die Pfefferkörner aus dem selbst aufgenommenen Datensatz.

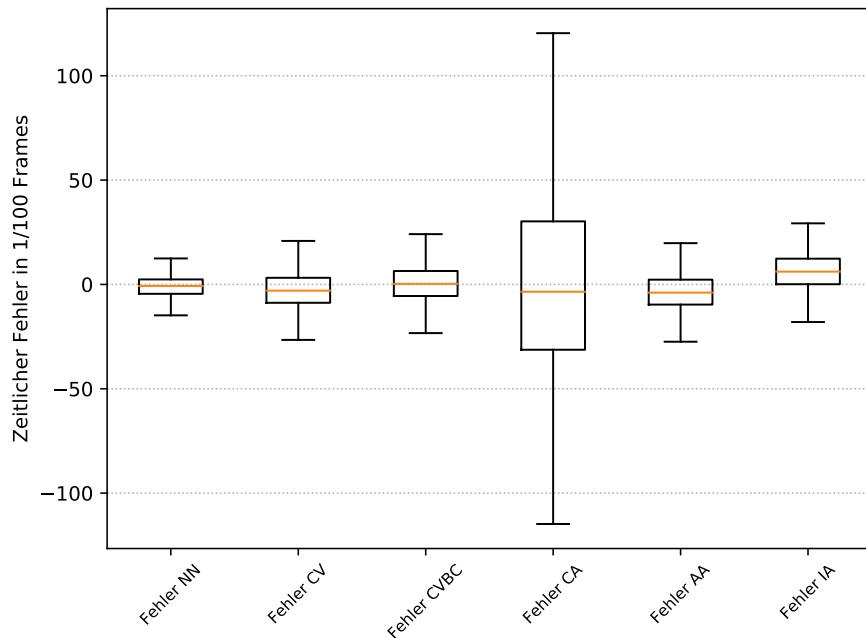


(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse der Zylinder aus dem selbst aufgenommenen Datensatz.

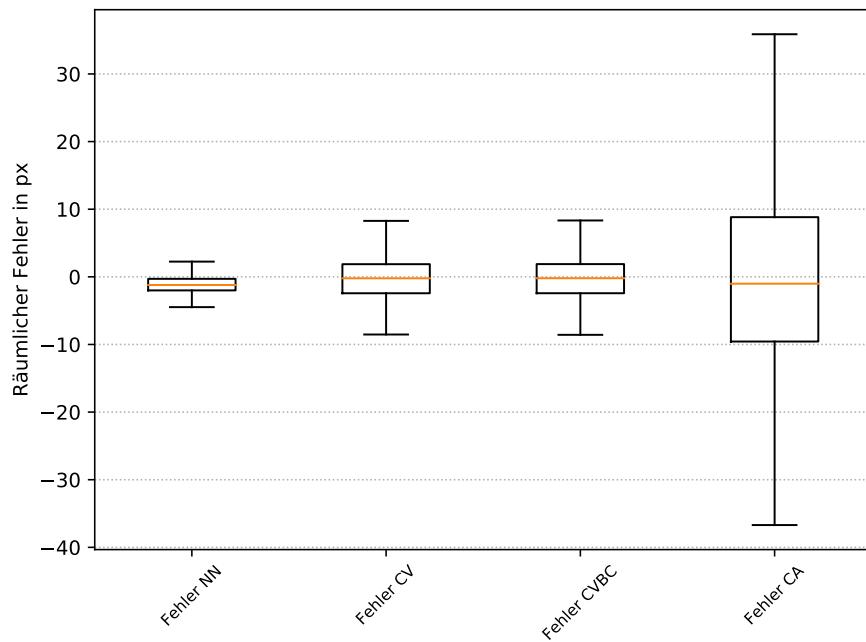


(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse der Zylinder aus dem selbst aufgenommenen Datensatz.

**Abbildung A.11:** Visualisierung der Ergebnisse für die Zylinder aus dem selbst aufgenommenen Datensatz.

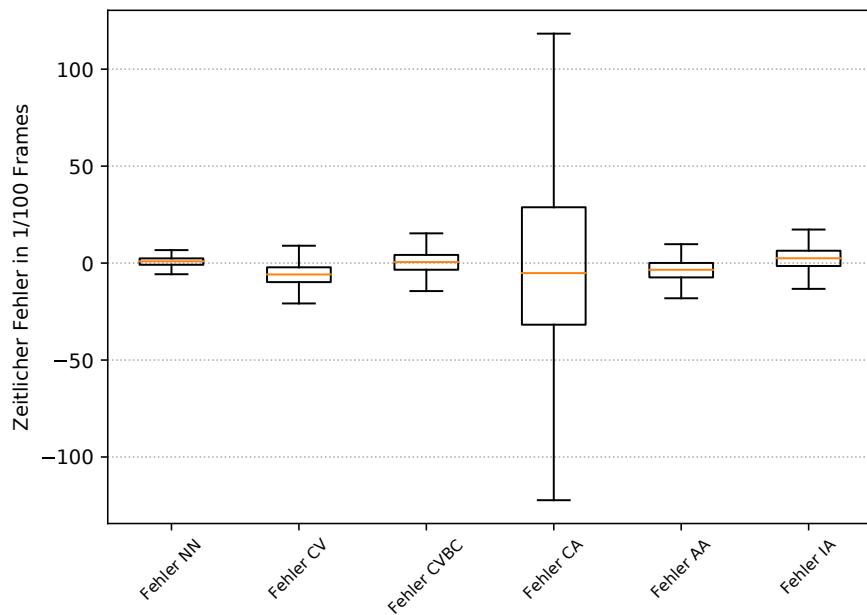


(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse der Weizenkörner aus dem selbst aufgenommenen Datensatz.

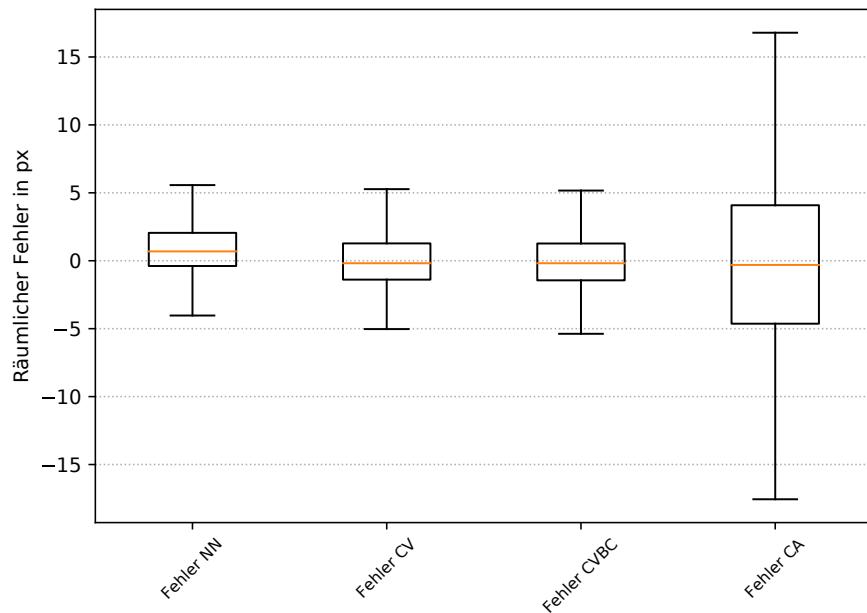


(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse der Weizenkörner aus dem selbst aufgenommenen Datensatz.

**Abbildung A.12:** Visualisierung der Ergebnisse für die Weizenkörner aus dem selbst aufgenommenen Datensatz.

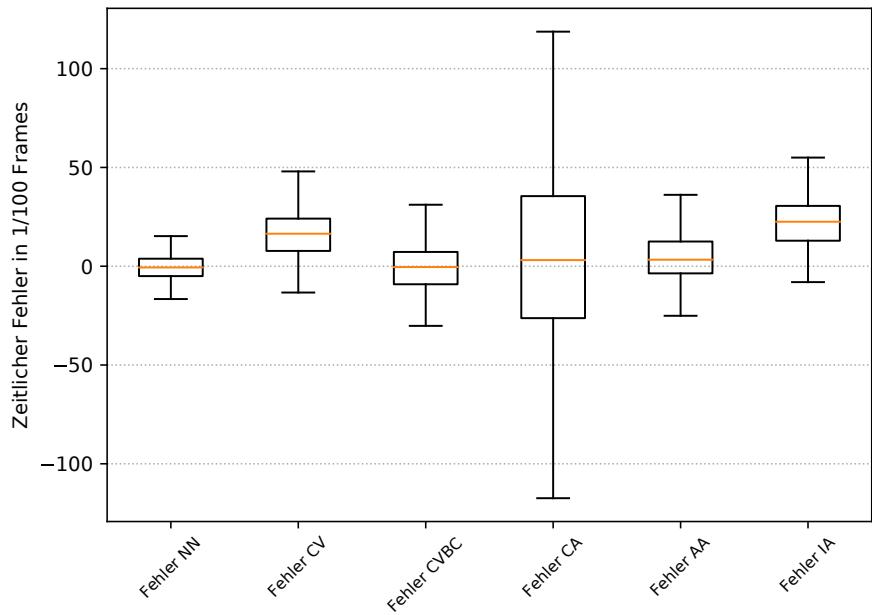


(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse der Kugeln auf der Rutsche aus dem selbst aufgenommenen Datensatz.

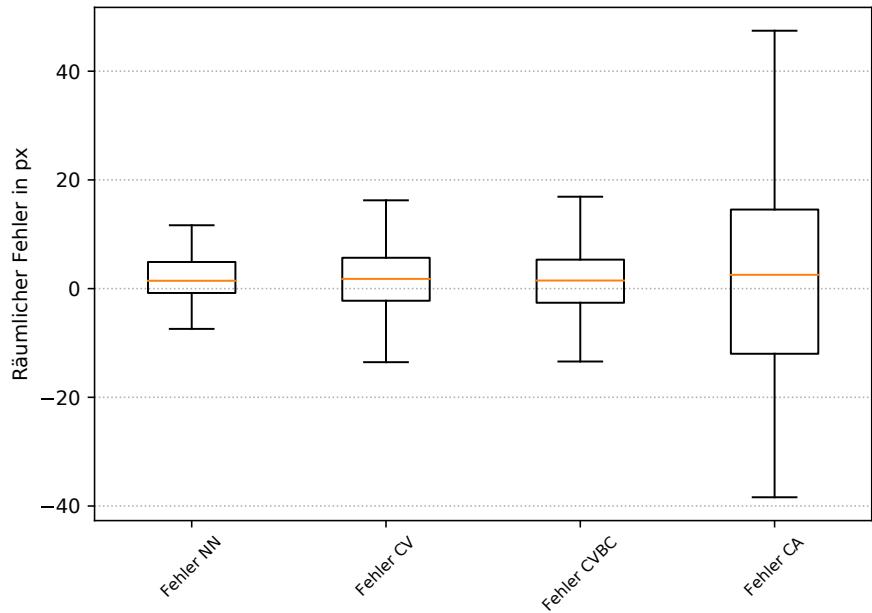


(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse der Kugeln auf der Rutsche aus dem selbst aufgenommenen Datensatz.

**Abbildung A.13:** Visualisierung der Ergebnisse für die Kugeln auf der Rutsche aus dem selbst aufgenommenen Datensatz.

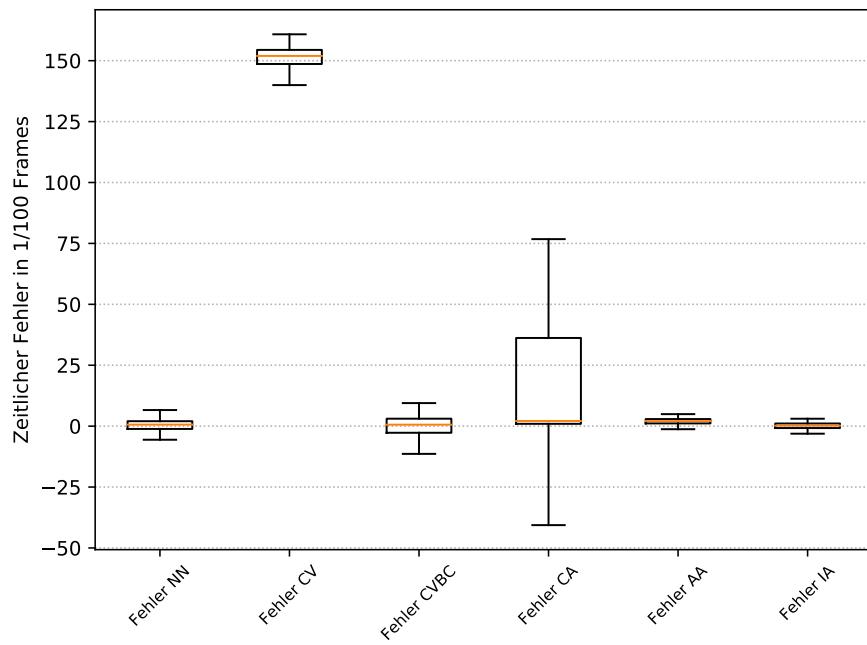


(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse der Pfefferkörner auf der Rutsche aus dem selbst aufgenommenen Datensatz.

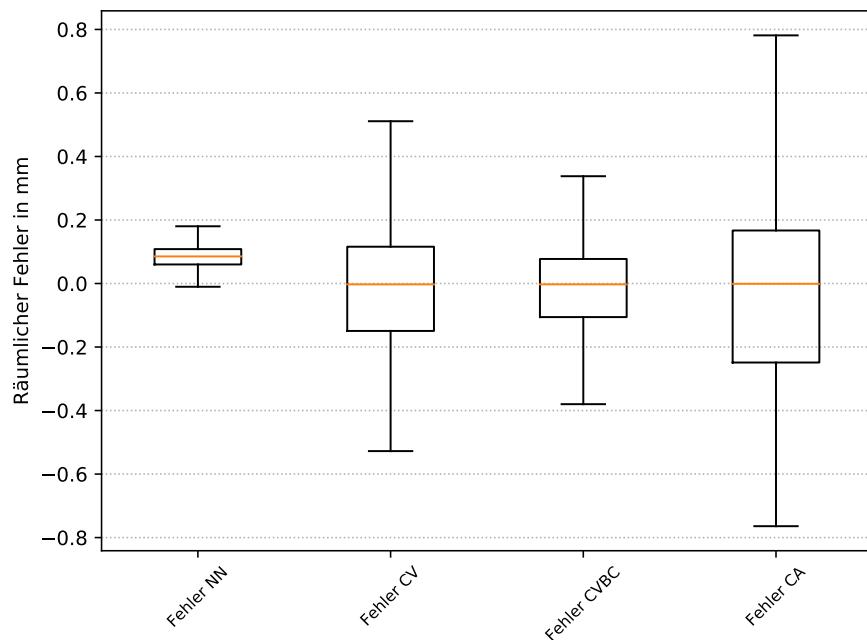


(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse der Pfefferkörner auf der Rutsche aus dem selbst aufgenommenen Datensatz.

**Abbildung A.14:** Visualisierung der Ergebnisse für die Pfefferkörner auf der Rutsche aus dem selbst aufgenommenen Datensatz.

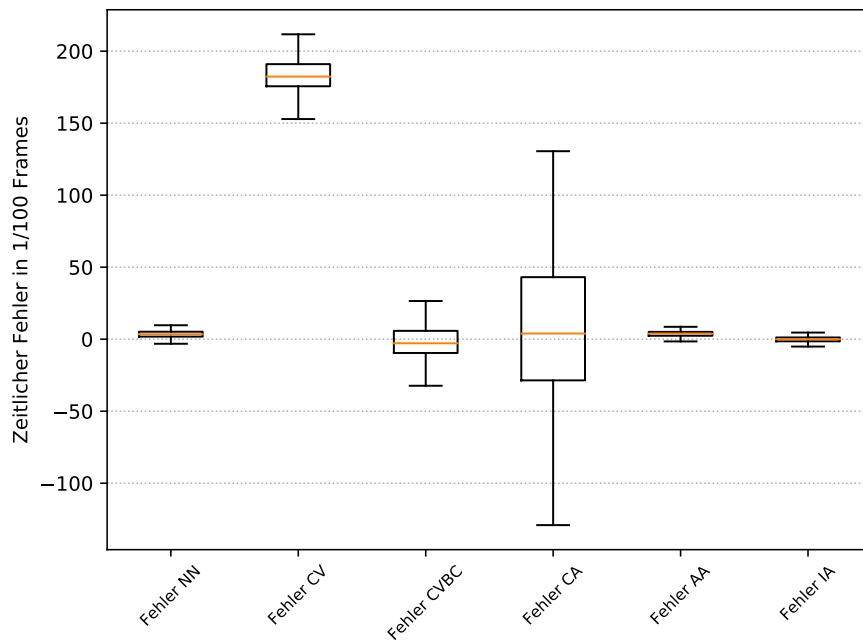


(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse der Kugeln aus dem DEM-Datensatz.

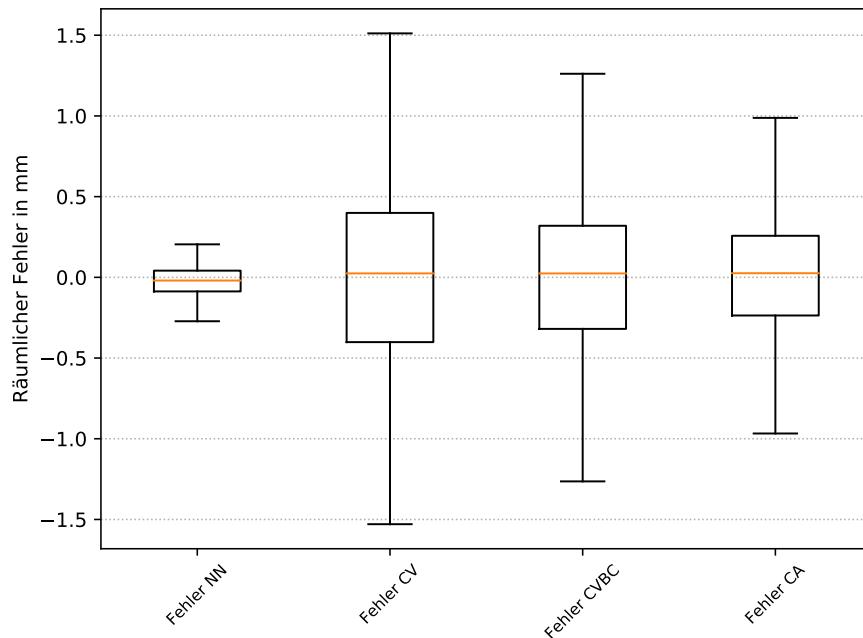


(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse der Kugeln aus dem DEM-Datensatz.

**Abbildung A.15:** Visualisierung der Ergebnisse für die Kugeln aus der DEM-Simulation.



(a) Boxplots des zeitlichen Fehlers für die Separator-Ergebnisse der Plättchen aus dem DEM-Datensatz.



(b) Boxplots des örtlichen Fehlers für die Separator-Ergebnisse der Plättchen aus dem DEM-Datensatz.

**Abbildung A.16:** Visualisierung der Ergebnisse für die Plättchen aus der DEM-Simulation.

**Masterarbeit:**  
**Ableitung von Bewegungsmodellen für Anwendungen in der**  
**Schüttgutsortierung mittels Machine Learning**

Kalman-Filter sind ein mathematisches Verfahren, das in vielen Bereichen Anwendung findet. Es wird unter anderem in optischen Bandsortieranlagen des Fraunhofer IOSBs dazu eingesetzt, Bewegungen einzelner Schüttgutelemente zu prädizieren. Um korrekte Vorhersagen zu erhalten, wird ein Bewegungsmodell sowie akkurate Beschreibungen des Mess- sowie des Systemrauschens benötigt. Ein gutes Bewegungsmodell zu bestimmen ist aufwendig und verschiedene Bewegungsmodelle erreichen bei unterschiedlichen Schüttgütern Ergebnisse mit unterschiedlicher Qualität.

Maschinelle Lernverfahren haben in letzter Zeit durch ihre Fähigkeit, komplexe Muster in Datensätzen zu finden, ohne weitreichende händische Vorgaben machen zu müssen, an Relevanz gewonnen. Speziell neuronale Netze erleben eine Renaissance und werden für eine große Menge an unterschiedlichsten Problemen eingesetzt. Hierfür werden große Mengen an Trainings- und Testdaten benötigt.

Im Rahmen dieser Masterarbeit sollen verschiedene Ansätze untersucht werden, wie neuronale Netze eingesetzt werden können, um die Bewegung von Schüttgutpartikeln zu prädizieren. Dazu müssen vorhandene Daten von der Schüttgutsortierung aufbereitet werden und neue Daten gesammelt werden. Nachdem ein Netzwerk mit Hilfe der Tensorflow-Software-Library modelliert wurde, kann dieses dann mit diesen Daten trainiert werden.

**Aufgaben**

- Datensammlung mittels Schüttgutsortierer des Fraunhofer IOSBs sowie Datenvorverarbeitung
- Data-Augmentation der Schüttgutdaten
- Erproben von verschiedenen Ansätzen für die Bewegungsprädiktion von Schüttgutelementen mittels neuronalen Netzen
  - Modellieren und Trainieren verschiedener Netze
  - Vergleich der verschiedenen Ansätze mit dem State of the Art und gegebenenfalls untereinander

**Bearbeiter:** B.Sc. Tobias Hornberger **Matrikelnummer:** 1697163

**Betr. Mitarbeiter:** Dipl.-Inform. Florian Pfaff, M.Sc. Georg Maier

Dr.-Ing. Benjamin Noack, Dr.-Ing. Robin Gruna

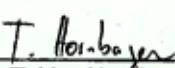
**Referent:** Prof. Dr.-Ing. Uwe D. Hanebeck

**Beginn:** 22. Juni 2018

**Zwischenvortrag:** ≈ 1. September 2018

**Abgabe:** 21. Dezember 2018

Karlsruhe, den 6. Juni 2018

  
\_\_\_\_\_  
Tobias Hornberger

  
\_\_\_\_\_  
Florian Pfaff

  
\_\_\_\_\_  
Uwe D. Hanebeck